

数理统计期末知识点总结

本总结涵盖上海财经大学《数理统计》课程下半学期（第9-15讲）的全部考试内容，同时补充前半学期必要的定理与基础知识。每个知识点下方附有作业中的典型例题与详细解答。

目录

- [前半学期重要基础回顾](#)
- [第九讲：估计的 Rao-Cramer 下界与有效性](#)
- [第十讲：极大似然检验（LRT / Wald / Score）](#)
- [第十一讲：多参数估计与检验](#)
- [第十二讲：充分统计量](#)
- [第十三讲：完备性与指数分布类](#)
- [第十四讲：参数的函数、最小充分性与从属统计量](#)
- [第十五讲：最优假设检验（Neyman-Pearson / UMP）](#)
- [作业精选例题与解答汇总](#)
- [附录：公式速查表](#)

前半学期重要基础回顾

本部分虽然不直接考察，但后半学期大量依赖这些结论，必须熟练掌握。

1. 三大抽样分布

χ^2 分布：设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(0, 1)$ ，则 $Y = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$ 。性质： $E(Y) = n, \text{Var}(Y) = 2n; \chi^2(n) = \Gamma(n/2, 2)$ 。

t 分布：设 $X \sim N(0, 1), Y \sim \chi^2(n)$ ，且独立，则 $T = \frac{X}{\sqrt{Y/n}} \sim t(n)$ 。密度关于0对称， $E(T) = 0$ ($n > 1$) 。

F 分布：设 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$ ，且独立，则 $F = \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$ 。

2. 学生定理 (Student's Theorem, Hogg Theorem 3.6.1)

【极其重要！后续大量引用】

设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ ， $\bar{X} = \frac{1}{n} \sum X_i$ 为样本均值， $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 为样本方差。则：

结论	内容
(a)	$\bar{X} \sim N(\mu, \sigma^2/n)$
(b)	$\bar{X}$ 与 S^2 互相独立

结论	内容
(c)	$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$
(d)	$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$

3. 参数约定（与讲义严格一致）

分布	记号	p.d.f. / p.m.f.	期望	方差
指数分布	$\text{Exp}(\theta)$	$\theta e^{-\theta x}, x > 0$	$1/\theta$	$1/\theta^2$
Gamma 分布	$\Gamma(\alpha, \beta)$	$\frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, x > 0$	$\alpha\beta$	$\alpha\beta^2$
正态分布	$N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)}$	μ	σ^2
均匀分布	$U[a, b]$	$\frac{1}{b-a}, a \leq x \leq b$	$(a+b)/2$	$(b-a)^2/12$
泊松分布	$\text{Po}(\lambda)$	$\frac{\lambda^x e^{-\lambda}}{x!}, x = 0, 1, 2, \dots$	λ	λ
Bernoulli	$\text{Bernoulli}(p)$	$p^x (1-p)^{1-x}, x \in \{0, 1\}$	p	$p(1-p)$
二项分布	$\text{Bin}(n, p)$	$\binom{n}{x} p^x (1-p)^{n-x}$	np	$np(1-p)$

重要关系：

- $\chi^2(n) = \Gamma(n/2, 2)$
- $\text{Exp}(\theta) = \Gamma(1, 1/\theta)$
- 若 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\theta)$, 则 $\sum X_i \sim \Gamma(n, 1/\theta)$

4. 上半学期核心公式

- 样本均值与样本方差：
 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- 上 α 分位数： $\chi^2_\alpha(n), t_\alpha(n), F_\alpha(n_1, n_2), z_\alpha$ (标准正态)
- F 分布分位数关系： $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_\alpha(n_2, n_1)}$
- 区间估计 (σ 未知, 正态总体)： μ 的 $1-\alpha$ CI 为
 $\left(\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right)$

第九讲：估计的 Rao-Cramer 下界与有效性

9.0 极大似然估计回顾

不变性定理 (Hogg Theorem 6.1.2)：设 $\hat{\theta}$ 为 θ 的 MLE。若 $\eta = g(\theta)$ 为 θ 的函数，则 $\hat{\eta} = g(\hat{\theta})$ 为 η 的 MLE。

典型分布的 MLE：

分布	MLE	说明
Bernoulli(θ)	$\hat{\theta} = \bar{X}$	若 $\theta \in [0, 1/3]$, 则 $\hat{\theta} = \min\{\bar{X}, 1/3\}$
Po(θ)	$\hat{\theta} = \bar{X}$	
$N(\theta, \sigma_0^2)$	$\hat{\theta} = \bar{X}$	σ_0^2 已知
拉普拉斯 location family	$\hat{\theta} = Q_2$ (样本中位数)	
Logistic location family	$\hat{\theta} = Q_2$	无显示解，需数值方法
Exp(θ)	$\hat{\theta} = 1/\bar{X}$	rate 参数
$\Gamma(\alpha_0, \beta)$	$\hat{\beta} = \bar{X}/\alpha_0$	α_0 已知
Beta($\theta, 1$)	$\hat{\theta} = -n / \sum_{i=1}^n \ln X_i$	

9.1 Location Family 与 Fisher 信息量

Location Family：若密度函数可写为 $f(x; \theta) = h(x - \theta)$ ，则称该分布族为 location family。此时 Fisher 信息量 $I(\theta)$ 不依赖于 θ (是一个常数)。

例子：拉普拉斯分布 $f(x; \theta) = \frac{1}{2}e^{-|x-\theta|}$ 属于 location family。
$$I(\theta) = E \left[\left(\frac{\partial}{\partial \theta} (-|X - \theta|) \right)^2 \right] = E[1] = 1$$

故 $I(\theta) = 1$ 为常数。

9.2 Fisher 信息量

定义：设总体分布为 $f(x; \theta)$ ，Fisher 信息量定义为：

$$I(\theta) = E \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right]$$

等价表达式：

$$I(\theta) = \text{Var} \left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right) = -E \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right]$$

其中 $\frac{\partial \ln f(X; \theta)}{\partial \theta}$ 称为**得分函数** (score function)。

正则条件 (R0)-(R4)：分布可区分、共同支撑、二次可微、积分与求导可交换。

典型分布的 Fisher 信息量：

分布	$I(\theta)$	说明
Bernoulli(θ)	$\frac{1}{\theta(1-\theta)}$	
Po(θ)	$\frac{1}{\theta}$	
$N(\theta, \sigma_0^2)$	$\frac{1}{\sigma_0^2}$	σ_0^2 已知
Exp(θ)	$\frac{1}{\theta^2}$	rate 参数为 θ
$\Gamma(\alpha_0, \beta)$	$\frac{\alpha_0}{\beta^2}$	α_0 已知, β 未知

9.2 Rao-Cramer 下界 (RCB)

定理 (Hogg Theorem 6.2.1) : 设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta)$, 正则条件成立。若 $Y = u(X_1, \dots, X_n)$ 为 $k(\theta)$ 的无偏估计, 则:

$$\text{Var}(Y) \geq \frac{[k'(\theta)]^2}{nI(\theta)}$$

特别地, 若 $k(\theta) = \theta$:

$$\text{Var}(Y) \geq \frac{1}{nI(\theta)}$$

9.3 Rao-Cramer 下界定理的证明

证明思路: 设 $Y = u(X_1, \dots, X_n)$ 为 $k(\theta)$ 的无偏估计, 即 $E(Y) = k(\theta)$ 。

对 $E(Y) = \int \cdots \int u(x_1, \dots, x_n) f(x_1; \theta) \cdots f(x_n; \theta) dx_1 \cdots dx_n = k(\theta)$ 两边对 θ 求导:

$$k'(\theta) = \int \cdots \int u(x) \sum_{i=1}^n \frac{\partial \ln f(x_i; \theta)}{\partial \theta} \cdot f(x_1; \theta) \cdots f(x_n; \theta) dx_1 \cdots dx_n = E \left[Y \sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta} \right]$$

注意到 $E \left[\sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta} \right] = n \cdot E \left[\frac{\partial \ln f(X; \theta)}{\partial \theta} \right] = 0$ (正则条件), 所以:

$$k'(\theta) = \text{Cov} \left(Y, \sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta} \right)$$

由 Cauchy-Schwarz 不等式:

$$\begin{aligned} [k'(\theta)]^2 &= \left\{ \text{Cov} \left(Y, \sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta} \right) \right\}^2 \leq \text{Var}(Y) \cdot \text{Var} \left(\sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta} \right) \\ &= \text{Var}(Y) \cdot nI(\theta) \end{aligned}$$

$$\text{故 } \text{Var}(Y) \geq \frac{[k'(\theta)]^2}{nI(\theta)}.$$

9.4 有效估计量

定义: 若 Y 为 θ 的无偏估计, 且 $\text{Var}(Y) = \frac{1}{nI(\theta)}$ (达到 RCB), 则称 Y 为**有效估计量** (efficient estimator)。

有效性 (efficiency) : $\text{eff}(Y) = \frac{1/[nI(\theta)]}{\text{Var}(Y)}$ 。

重要例子:

- Bernoulli(θ): $\hat{\theta} = \bar{X}$, $\text{Var}(\bar{X}) = \frac{\theta(1-\theta)}{n} = \frac{1}{nI(\theta)}$, 有效。
- Po(θ): $\hat{\theta} = \bar{X}$, $\text{Var}(\bar{X}) = \frac{\theta}{n} = \frac{1}{nI(\theta)}$, 有效。
- $N(\theta, \sigma_0^2)$: $\hat{\theta} = \bar{X}$, $\text{Var}(\bar{X}) = \frac{\sigma_0^2}{n} = \frac{1}{nI(\theta)}$, 有效。
- $\Gamma(\alpha_0, \beta)$ (α_0 已知, 估计 β): $\hat{\beta} = \bar{X}/\alpha_0$, $\text{Var}(\hat{\beta}) = \frac{\beta^2}{n\alpha_0} = \frac{1}{nI(\beta)}$, 有效。
- Beta($\theta, 1$): 纠偏后 $\tilde{\theta} = \frac{n-1}{n}\hat{\theta}$ 不是有效估计, $\text{eff}(\tilde{\theta}) = \frac{n-2}{n} \rightarrow 1$ (渐近有效)。

【作业例题】Ass5 Problem 2: Exp(θ) 的 Fisher 信息量与有效性

题目: 设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\theta)$, p.d.f. 为 $f(x; \theta) = \theta e^{-\theta x}$, $x > 0$ 。

1. 用三种方法计算 $I(\theta)$
2. 找出 θ 的 MLE $\hat{\theta}$, 并证明其无偏性
3. 判断 $\hat{\theta}$ 是否达到 RCB

解答:

(1) 计算 Fisher 信息量

对数密度: $\ln f(x; \theta) = \ln \theta - \theta x$

一阶和二阶导数:

$$\frac{\partial \ln f}{\partial \theta} = \frac{1}{\theta} - x, \quad \frac{\partial^2 \ln f}{\partial \theta^2} = -\frac{1}{\theta^2}$$

已知 $E[X] = 1/\theta$, $\text{Var}(X) = 1/\theta^2$, $E[X^2] = 2/\theta^2$ 。

- 方法一 (定义法):

$$I(\theta) = E\left[\left(\frac{1}{\theta} - X\right)^2\right] = E\left[\left(X - \frac{1}{\theta}\right)^2\right] = \text{Var}(X) = \frac{1}{\theta^2}$$
- 方法二 (二阶导数法):

$$I(\theta) = -E\left[-\frac{1}{\theta^2}\right] = \frac{1}{\theta^2}$$
- 方法三 (方差法):

$$I(\theta) = \text{Var}\left(\frac{1}{\theta} - X\right) = \text{Var}(X) = \frac{1}{\theta^2}$$

(2) MLE 与无偏性

对数似然: $l(\theta) = n \ln \theta - \theta \sum X_i$

求导: $\frac{dl}{d\theta} = \frac{n}{\theta} - \sum X_i = 0 \Rightarrow \hat{\theta} = \frac{n}{\sum X_i} = \frac{1}{\bar{X}}$

注意: $E[\hat{\theta}] \neq \theta$ (实际上 $\hat{\theta}$ 是有偏的)。

讲义勘误说明: 原题可能设的是 $\text{Exp}(1/\theta)$ (即均值为 θ 的参数化)。若 $f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}$, 则 $\hat{\theta} = \bar{X}$, $E[\hat{\theta}] = \theta$ (无偏)。

(3) RCB 检验

若采用 $f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}$ (均值为 θ):

$$\text{RCB} = \frac{1}{nI(\theta)} = \frac{\theta^2}{n}$$

$\text{Var}(\hat{\theta}) = \text{Var}(\bar{X}) = \frac{\theta^2}{n}$, 达到 RCB, 为有效估计。

【作业例题】 Ass5 Problem 5: 正态分布 $N(\mu_0, \theta)$ 的 Fisher 信息量

题目: 设 $X_1, \dots, X_n \sim N(\mu_0, \theta)$, μ_0 已知, θ 为方差。

1. 计算 $I(\theta)$
2. 证明 θ 的 MLE 为有效估计量
3. 求 S^2 的有效性

解答:

(1) $I(\theta) = \frac{1}{2\theta^2}$

(2) MLE 为 $\hat{\theta} = \frac{1}{n} \sum (X_i - \mu_0)^2$ 。由 $\sum (X_i - \mu_0)^2 / \theta \sim \chi^2(n)$, 得 $E[\hat{\theta}] = \theta$, 且 $\text{Var}(\hat{\theta}) = \frac{2\theta^2}{n} = \frac{1}{nI(\theta)}$, 达到 RCB。

(3) $\text{Var}(S^2) = \frac{2\theta^2}{n-1}$, 有效性 = $\frac{2\theta^2/n}{2\theta^2/(n-1)} = \frac{n-1}{n}$

【作业例题】 Ass5 Problem 6: 泊松分布 $g(\theta) = \theta^2$ 的无偏估计与有效性

题目: 设 $X_1, X_2 \sim \text{Po}(\theta)$ 。

1. 证明 $X_1 X_2$ 为 θ^2 的无偏估计
2. 计算其有效性

解答:

(1) $E[X_1 X_2] = E[X_1]E[X_2] = \theta \cdot \theta = \theta^2$, 故无偏。

(2) $\text{Var}(X_1 X_2) = E[X_1^2]E[X_2^2] - \theta^4 = (\theta + \theta^2)^2 - \theta^4 = 2\theta^3 + \theta^2$

Fisher 信息量: $I_1(\theta) = \frac{1}{\theta}$, $k(\theta) = \theta^2$, $k'(\theta) = 2\theta$

RCB = $\frac{(2\theta)^2}{nI_1(\theta)} = \frac{4\theta^2}{2 \cdot (1/\theta)} = 2\theta^3$ ($n = 2$)

有效性 = $\frac{2\theta^3}{2\theta^3 + \theta^2} = \frac{2\theta}{2\theta + 1}$

【作业例题】 Ass5 Problem 7: 一般分布的 Fisher 信息量

题目: 设 $f(x; \theta) = \frac{4\theta^4}{(x+\theta)^5}$, $x > 0$ 。

1. 证明 $\hat{\theta} = 3\bar{X}$ 是 θ 的无偏估计
2. 求 $I(\theta)$
3. 计算有效性

解答:

(1) $E[X] = \int_0^\infty x \cdot \frac{4\theta^4}{(x+\theta)^5} dx$ 。令 $u = x/\theta$, 则

$E[X] = 4\theta \int_0^\infty \frac{u}{(1+u)^5} du = 4\theta \cdot \frac{1}{12} = \frac{\theta}{3}$

故 $E[3\bar{X}] = 3 \cdot \frac{\theta}{3} = \theta$ 。

(2) $I(\theta) = \frac{2}{3\theta^2}$

$$(3) \text{Var}(\hat{\theta}) = \frac{9}{n} \text{Var}(X) = \frac{9}{n} \cdot \frac{2\theta^2}{9} = \frac{2\theta^2}{n}$$

$$\text{RCB} = \frac{3\theta^2}{2n}, \text{ 有效性} = \frac{3/2}{2} = \frac{3}{4}$$

第十讲：极大似然检验 (LRT / Wald / Score)

10.0 MLE 的相合性

定理 (Hogg Theorem 6.1.1) : 设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta)$, θ_0 为参数真值, $\hat{\theta}$ 为 MLE。则在适当正则条件下, $\hat{\theta}$ 是 θ 的相合估计, 即:

$$\hat{\theta} \xrightarrow{P} \theta_0$$

直观理解: 当样本量增大时, MLE 依概率收敛到参数真值。这保证了在 H_0 下 $\hat{\theta}$ 不会偏离 θ_0 太远。

10.1 似然比检验 (LRT)

背景: 检验 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$ 。

定义: 似然比检验统计量:

$$\Lambda = \frac{L(\theta_0)}{L(\hat{\theta})}$$

其中 $\hat{\theta}$ 为 MLE。显然 $\Lambda \leq 1$ 。

拒绝域: $\{\Lambda \leq c\}$, 其中 c 满足 $P_{\theta_0}(\Lambda \leq c) = \alpha$ 。

典型例子:

- $\text{Exp}(\theta)$: $\{\Lambda \leq c\}$ 等价于 $\{2n\theta_0\bar{X} \leq c_1\} \cup \{2n\theta_0\bar{X} \geq c_2\}$, 其中 $2n\theta_0\bar{X} \sim \chi^2(2n)$
- $N(\theta, \sigma_0^2)$: $\Lambda \leq c$ 等价于 $|\bar{X} - \theta_0| \geq c' \frac{\sigma_0}{\sqrt{n}}$, 即 $|Z| \geq z_{\alpha/2}$

10.2 $-2 \ln \Lambda$ 的渐近分布

定理 (Hogg Theorem 6.3.1) : 在正则条件下, $H_0: \theta = \theta_0$ 成立时:

$$-2 \ln \Lambda \xrightarrow{d} \chi^2(1)$$

令 $\chi_L^2 = -2 \ln \Lambda$, 则渐近水平 α 的拒绝域为 $\{\chi_L^2 \geq \chi_\alpha^2(1)\}$ 。

证明思路 (两个引理 + Taylor 展开)

引理 1 (MLE 的相合性) : $\hat{\theta} \xrightarrow{P} \theta_0$ 。

引理 2 (MLE 的渐近正态性) :

$$\sqrt{n I_1(\theta_0)} (\hat{\theta} - \theta_0) \xrightarrow{d} N(0, 1)$$

等价地: $\hat{\theta} - \theta_0 = O_P(1/\sqrt{n})$ 。

Taylor 展开证明: 对 $l(\theta_0)$ 在 $\hat{\theta}$ 处 Taylor 展开:

$$l(\theta_0) = l(\hat{\theta}) + l'(\hat{\theta})(\theta_0 - \hat{\theta}) + \frac{1}{2}l''(\xi)(\theta_0 - \hat{\theta})^2$$

由于 $l'(\hat{\theta}) = 0$ (MLE 的极值条件), 故:

$$-2 \ln \Lambda = -2[l(\theta_0) - l(\hat{\theta})] = -l''(\xi)(\theta_0 - \hat{\theta})^2$$

其中 ξ 介于 θ_0 和 $\hat{\theta}$ 之间。由相合性, $\xi \xrightarrow{P} \theta_0$ 。

注意到 $-l''(\xi)/n \xrightarrow{P} I_1(\theta_0)$ (Fisher 信息量), 且 $\sqrt{nI_1(\theta_0)}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, 1)$, 故:

$$-2 \ln \Lambda = \left[\sqrt{nI_1(\theta_0)}(\hat{\theta} - \theta_0) \right]^2 \cdot \left[-\frac{l''(\xi)}{nI_1(\theta_0)} \right] \xrightarrow{d} Z^2 \cdot 1 = \chi^2(1)$$

其中 $Z \sim N(0, 1)$ 。

10.3 Wald 型检验

统计量:

$$\chi_W^2 = nI(\hat{\theta})(\hat{\theta} - \theta_0)^2 \xrightarrow{d} \chi^2(1)$$

等价标准正态形式: $Z_W = \sqrt{nI(\hat{\theta})}(\hat{\theta} - \theta_0)$

10.4 得分型检验 (Score Test)

统计量:

$$\chi_R^2 = \frac{[l'(\theta_0)]^2}{nI(\theta_0)} \xrightarrow{d} \chi^2(1)$$

等价形式: $Z_R = \frac{l'(\theta_0)}{\sqrt{nI(\theta_0)}}$

直观比较: LRT 比较 $l(\hat{\theta})$ 与 $l(\theta_0)$ 的差距; Wald 看 $\hat{\theta}$ 离 θ_0 多远; Score 看 $l'(\theta_0)$ 离 0 多远。

【作业例题】Ass5 Problem 8: 瑞利分布的 LRT

题目: 设 $X_1, \dots, X_n$ 来自瑞利分布 $f(x; \sigma) = \frac{x}{\sigma^2} e^{-x^2/(2\sigma^2)}, x > 0$ 。

1. 证明 Λ 可表示为 $W = \frac{1}{\sigma_0^2} \sum X_i^2$ 的函数

2. 求 W 在 H_0 下的分布及拒绝域

解答:

(1) MLE: $\hat{\sigma}^2 = \frac{1}{2n} \sum X_i^2$ 。似然比:

$$\Lambda = \left(\frac{W}{2n} \right)^n e^{n-W/2}$$

(2) 令 $Y_i = X_i^2/\sigma_0^2$, 则 $Y_i \sim \chi^2(2) = \text{Exp}(1/2)$, 故 $W = \sum Y_i \sim \chi^2(2n)$ 。

$\Lambda(W)$ 先增后减, 拒绝域为:

$$\{W \leq \chi_{1-\alpha/2}^2(2n)\} \cup \{W \geq \chi_{\alpha/2}^2(2n)\}$$

【作业例题】Ass5 Problem 10: Bernoulli 分布的三种检验

题目: 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$, 检验 $H_0: \theta = 1/3$ vs $H_1: \theta \neq 1/3$ 。

解答:

$$\hat{\theta} = \bar{X}, Y = \sum X_i.$$

- (a) LRT: $\Lambda = \frac{(1/3)^Y (2/3)^{n-Y}}{\hat{\theta}^Y (1-\hat{\theta})^{n-Y}}$
- (b) Wald: $I(\theta) = \frac{1}{\theta(1-\theta)}, \chi_W^2 = \frac{n(\bar{X}-1/3)^2}{\bar{X}(1-\bar{X})}$
- (c) Score: $l'(\theta) = \frac{Y}{\theta} - \frac{n-Y}{1-\theta}, I(\theta_0) = \frac{9}{2}$
 $\chi_R^2 = \frac{[Y/\theta_0 - (n-Y)/(1-\theta_0)]^2}{n \cdot 9/2} = \frac{n(3\bar{X}-1)^2}{2}$

【作业例题】Ass5 Problem 11: 泊松分布的三种检验

题目: 设 $X_1, \dots, X_n \sim \text{Po}(\theta)$, 检验 $H_0: \theta = 5$ vs $H_1: \theta \neq 5$ 。

解答:

- LRT: $-2 \ln \Lambda = 2n \left(\bar{X} \ln \frac{\bar{X}}{5} + 5 - \bar{X} \right) \xrightarrow{d} \chi^2(1)$
- Wald: $I(\theta) = 1/\theta, W = \frac{n(\bar{X}-5)^2}{\bar{X}} \sim \chi^2(1)$
- Score: $I(\theta_0) = 1/5, R = \frac{n(\bar{X}-5)^2}{5} \sim \chi^2(1)$

10.5 拉普拉斯 Location Family 的三种检验

题目: 设 $X_1, \dots, X_n$ 来自拉普拉斯分布 $f(x; \theta) = \frac{1}{2} e^{-|x-\theta|}$ 。检验 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$ 。

分析: 该分布属于 location family, $I(\theta) = 1$ (常数)。

- MLE: $\hat{\theta} = Q_2$ (样本中位数)
- LRT: $\Lambda = \exp \{ -\sum |X_i - \theta_0| + \sum |X_i - Q_2| \}$
- Wald: $\chi_W^2 = n(Q_2 - \theta_0)^2 \xrightarrow{d} \chi^2(1)$
- Score: $l'(\theta_0) = \sum \text{sgn}(X_i - \theta_0), \chi_R^2 = \frac{[\sum \text{sgn}(X_i - \theta_0)]^2}{n}$

10.6 Beta($\theta, 1$) 分布的三种检验

题目: 设 $X_1, \dots, X_n \sim \text{Beta}(\theta, 1)$, p.d.f. 为 $f(x; \theta) = \theta x^{\theta-1}, 0 < x < 1$ 。检验 $H_0: \theta = \theta_0$ 。

解答:

对数似然: $l(\theta) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln X_i$

- MLE: $\hat{\theta} = -n / \sum_{i=1}^n \ln X_i$
- LRT: $-2 \ln \Lambda = 2n \ln \frac{\hat{\theta}}{\theta_0} + 2(\theta_0 - \hat{\theta}) \sum_{i=1}^n \ln X_i \xrightarrow{d} \chi^2(1)$
- Wald: $I(\theta) = 1/\theta^2, \chi_W^2 = n \left(\frac{\hat{\theta} - \theta_0}{\hat{\theta}} \right)^2 = \frac{n(\hat{\theta} - \theta_0)^2}{\hat{\theta}^2}$

- **Score:** $l'(\theta_0) = \frac{n}{\theta_0} + \sum \ln X_i, I(\theta_0) = 1/\theta_0^2$
 $\chi_R^2 = \frac{(n/\theta_0 + \sum \ln X_i)^2}{n/\theta_0^2} = \frac{(n + \theta_0 \sum \ln X_i)^2}{n}$

第十一讲：多参数估计与检验

11.0 一般拉普拉斯分布的 MLE

题目: 设 $X_1, \dots, X_n$ 来自拉普拉斯分布 $f(x; a, b) = \frac{1}{2b} e^{-|x-a|/b}, a \in \mathbb{R}, b > 0$.

解答:

- $\hat{a} = Q_2$ (样本中位数)
- $\hat{b} = \frac{1}{n} \sum_{i=1}^n |X_i - Q_2|$

11.1 Location and Scale Family

Location Family: $f(x; \theta) = h(x - \theta)$, Fisher 信息量 $I(\theta)$ 为常数。

Scale Family: $f(x; \theta) = \frac{1}{\theta} h\left(\frac{x}{\theta}\right), \theta > 0$ 。

Location and Scale Family: $f(x; a, b) = \frac{1}{b} h\left(\frac{x-a}{b}\right)$ 。

正态分布 $N(\theta_1, \theta_2)$ 属于 location and scale family。

11.2 多参数的 MLE 与 Fisher 信息矩阵

设 $\theta = (\theta_1, \dots, \theta_k)^T$ 。

Fisher 信息矩阵: $k \times k$ 矩阵, (i, j) 元素:

$$I_{ij}(\theta) = -E \left[\frac{\partial^2 l}{\partial \theta_i \partial \theta_j} \right]$$

正态分布 $N(\theta_1, \theta_2)$ 的例子:

$$I(\theta_1, \theta_2) = \begin{pmatrix} \frac{1}{\theta_2} & 0 \\ 0 & \frac{1}{2\theta_2^2} \end{pmatrix}$$

多项分布 $(X_1, \dots, X_k) \sim \text{Multinomial}(n; p_1, \dots, p_k)$ 的例子:

$$I(p_1, \dots, p_{k-1}) = n \cdot \text{diag} \left(\frac{1}{p_1}, \dots, \frac{1}{p_{k-1}} \right) + \frac{n}{p_k} \mathbf{1}\mathbf{1}^T$$

其逆矩阵为:

$$[I(p_1, \dots, p_{k-1})]^{-1} = \frac{1}{n} (\text{diag}(p_1, \dots, p_{k-1}) - \mathbf{p}\mathbf{p}^T)$$

其中 $\mathbf{p} = (p_1, \dots, p_{k-1})^T$ 。

11.2 多参数的 Rao-Cramer 下界

若 $\mathbf{Y}$ 为 θ 的无偏估计：

$$\text{Cov}(\mathbf{Y}) \geq \frac{1}{n} [I(\theta)]^{-1}$$

11.3 多参数的极大似然检验

设 $\theta \in \Omega \subset \mathbb{R}^p$ ，检验 $H_0: \theta = \theta_0$ (或一般地 $H_0: g(\theta) = 0$)。下面三个大样本检验统计量在 H_0 下都渐近服从卡方分布，**右尾拒绝**——统计量越大越偏离 H_0 。

⚠ r 与 k 是什么？二者都是卡方自由度 = H_0 施加的独立约束个数，本质是同一个量，只是不同检验沿用了不同记号：

- $r = H_0$ 的约束条件个数 (即把参数空间从 Ω 降到 H_0 子空间所减少的自由维数，Hogg Thm 6.5.1 中记作 q)。
- $k =$ 被检验/被约束的参数个数 (这里写法默认 $H_0: \theta = \theta_0$ 把整个 p 维向量都定死，故 $k = p$)。
- 当 H_0 完全指定整个参数向量时 $r = k = p$ ，三个检验自由度相同；当 H_0 只约束其中一部分 ($r < p$ 个约束) 时，三者自由度统一为 r 。

(1) 似然比检验 LRT

$$\Lambda = \frac{L(\hat{\theta}^{(0)})}{L(\hat{\theta})}, \quad -2 \ln \Lambda \xrightarrow{d} \chi^2(r)$$

其中 $\hat{\theta}^{(0)}$ 为 H_0 约束下的 MLE， $\hat{\theta}$ 为无约束 MLE， r 为约束条件个数。

★ 拒绝域： $-2 \ln \Lambda \geq \chi_\alpha^2(r)$ (等价地 $\Lambda \leq c$)。

(2) Wald 检验

$$\chi_W^2 = n(\hat{\theta} - \theta_0)^T I(\hat{\theta})(\hat{\theta} - \theta_0) \xrightarrow{d} \chi^2(k)$$

其中 $I(\cdot)$ 为单个观测的 Fisher 信息矩阵 (故乘以 n 得样本总信息)，在 MLE $\hat{\theta}$ 处估计。

★ 拒绝域： $\chi_W^2 \geq \chi_\alpha^2(k)$ 。

💡 直觉：度量 MLE $\hat{\theta}$ 离 θ_0 有多远 (以信息为尺度)，只需拟合无约束模型。

(3) Score (Rao) 检验

$$\chi_R^2 = \frac{1}{n} [\nabla l(\theta_0)]^T [I(\theta_0)]^{-1} [\nabla l(\theta_0)] \xrightarrow{d} \chi^2(k)$$

其中 $\nabla l(\theta_0)$ 为对数似然在 θ_0 处的 score 向量， $I(\theta_0)$ 为单观测 Fisher 信息阵。

★ 拒绝域： $\chi_R^2 \geq \chi_\alpha^2(k)$ 。

💡 直觉：度量 score 在 θ_0 处偏离 0 多远 (若 θ_0 是真值，score 应近似为 0)，只需在 θ_0 处求导、无需求无约束 MLE。

🎯 三者对比：LRT 需同时拟合约束与无约束两个模型；Wald 只需无约束 MLE；Score 只需在 H_0 点求导。三者大样本下渐近等价，自由度都等于约束个数。

【作业例题】Ass6 Problem 1: 逆高斯分布的 MLE

题目: $f(x; \mu, \lambda) = \sqrt{\frac{\lambda}{2\pi x^3}} \exp\left(-\frac{\lambda(x-\mu)^2}{2\mu^2 x}\right)$, 求 MLE。

解答: $\hat{\mu} = \bar{X}, \hat{\lambda} = \frac{n\bar{X}^2}{\sum \frac{(X_i - \bar{X})^2}{X_i}}$

【作业例题】Ass6 Problem 2: 多项分布的 MLE

题目: $(X_1, X_2, X_3) \sim \text{Multinomial}(n; \theta_1, \theta_2, \theta_3)$, $\theta_3 = 1 - \theta_1 - \theta_2$ 。

解答: $\hat{\theta}_1 = X_1/n, \hat{\theta}_2 = X_2/n, \hat{\theta}_3 = X_3/n$

【作业例题】Ass6 Problem 3: $\Gamma(2, \theta)$ 的 MLE 与有效性

题目: $f(x; \theta) = \frac{1}{\theta^2} x e^{-x/\theta}, x > 0$ 。

解答:

- (a) $E[X] = 2\theta$, MLE $\hat{\theta} = \frac{1}{2}\bar{X}$, $E[\hat{\theta}] = \theta$ (无偏)
 - (b) $I(\theta) = 2/\theta^2$
 - (c) $\text{RCB} = \theta^2/(2n)$, $\text{Var}(\hat{\theta}) = \frac{1}{4} \frac{\text{Var}(X)}{n} = \frac{1}{4} \frac{2\theta^2}{n} = \frac{\theta^2}{2n}$, 达到 RCB
-

11.5 正态分布方差未知时的 LRT (t-检验推导)

题目: 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$, θ_2 未知。检验 $H_0: \theta_1 = \theta_{10}$ vs $H_1: \theta_1 \neq \theta_{10}$ 。

解答:

无约束 MLE: $\hat{\theta}_1 = \bar{X}, \hat{\theta}_2 = \frac{1}{n} \sum (X_i - \bar{X})^2$

H_0 约束 MLE: $\tilde{\theta}_1 = \theta_{10}, \tilde{\theta}_2 = \frac{1}{n} \sum (X_i - \theta_{10})^2$

似然比:

$$\Lambda = \left(\frac{\sum (X_i - \theta_{10})^2}{\sum (X_i - \bar{X})^2} \right)^{-n/2} = \left(1 + \frac{n(\bar{X} - \theta_{10})^2}{\sum (X_i - \bar{X})^2} \right)^{-n/2}$$

$\Lambda \leq c$ 等价于:

$$\frac{|\bar{X} - \theta_{10}|}{S/\sqrt{n}} \geq c'$$

其中 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 。

由学生定理, $\frac{\bar{X} - \theta_{10}}{S/\sqrt{n}} \sim t(n-1)$, 故拒绝域为 $|t| \geq t_{\alpha/2}(n-1)$ 。

结论: 当方差未知时, LRT 等价于 **t-检验**。

11.6 单因素方差分析的 LRT (F-统计量推导)

模型: $X_{ij} \sim N(\theta_i, \sigma^2)$, $i = 1, \dots, k$ (k 组), $j = 1, \dots, n_i$.

检验: $H_0: \theta_1 = \theta_2 = \dots = \theta_k$ vs H_1 : 不全相等。

解答:

H_0 下 MLE: $\hat{\theta} = \bar{X}_{..}$ (总均值), $\hat{\sigma}^2 = \frac{1}{n} \sum_{i,j} (X_{ij} - \bar{X}_{..})^2$

无约束 MLE: $\hat{\theta}_i = \bar{X}_{i.}$ (组均值), $\hat{\sigma}^2 = \frac{1}{n} \sum_{i,j} (X_{ij} - \bar{X}_{i.})^2$

似然比:

$$\Lambda = \left(\frac{\sum_{i,j} (X_{ij} - \bar{X}_{..})^2}{\sum_{i,j} (X_{ij} - \bar{X}_{i.})^2} \right)^{-n/2} = \left(1 + \frac{SSB}{SSW} \right)^{-n/2}$$

其中 $SSB = \sum_{i=1}^k n_i (\bar{X}_{i.} - \bar{X}_{..})^2$ (组间平方和), $SSW = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i.})^2$ (组内平方和)。

$\Lambda \leq c$ 等价于:

$$F = \frac{SSB/(k-1)}{SSW/(n-k)} \geq c'$$

在 H_0 下, $F \sim F(k-1, n-k)$ 。拒绝域为 $F \geq F_\alpha(k-1, n-k)$ 。

结论: LRT 等价于 F-检验 (单因素 ANOVA)。

11.7 总统选举例子 (多项分布检验)

题目: 3 位候选人, n 位投票者。 $(X_1, X_2, X_3) \sim \text{Multinomial}(n; \theta_1, \theta_2, \theta_3)$ 。

(a) 检验 $H_0: (\theta_1, \theta_2, \theta_3) = (1/3, 1/3, 1/3)$

$$\Lambda = \prod_{i=1}^3 \left(\frac{n}{3X_i} \right)^{X_i}$$

$-2 \ln \Lambda \xrightarrow{d} \chi^2(2)$, 拒绝域 $-2 \ln \Lambda \geq \chi_\alpha^2(2)$ 。

(b) 检验 $H_0: \theta_1 - \theta_2 = 0.03$

约束条件 $g(\theta_1, \theta_2) = \theta_1 - \theta_2 - 0.03 = 0$ 。

用 Lagrange 乘子法求约束 MLE, 再构造 LRT。

11.8 Hogg Theorem 6.5.1 (约束条件下 LRT 的渐近分布)

定理: 设 $\theta \in \Omega \subset \mathbb{R}^p$, $H_0: g(\theta) = 0$ (q 个约束条件)。则在正则条件下:

$$-2 \ln \Lambda = -2 \ln \frac{L(\hat{\theta}^{(0)})}{L(\hat{\theta})} \xrightarrow{d} \chi^2(q)$$

其中 q 为约束条件的个数, $\hat{\theta}^{(0)}$ 为约束 MLE, $\hat{\theta}$ 为无约束 MLE。

应用:

- 正态分布 $H_0: \theta_1 = \theta_{10}$ (1 个约束): $q = 1$
- ANOVA $H_0: \theta_1 = \dots = \theta_k$ ($k-1$ 个约束): $q = k-1$

- 多项分布 $H_0 : (p_1, \dots, p_k) = (1/k, \dots, 1/k)$ ($k-1$ 个约束) : $q = k-1$

第十二讲：充分统计量

12.0 MVUE 的定义

定义 (最小方差无偏估计量, Minimum Variance Unbiased Estimator, MVUE) : 设 $Y = u(X_1, \dots, X_n)$ 为 $k(\theta)$ 的无偏估计, 即 $E(Y) = k(\theta)$ 。若对 $k(\theta)$ 的任意无偏估计 Z , 都有:

$$\text{Var}(Y) \leq \text{Var}(Z), \quad \text{对所有 } \theta \in \Omega \text{ 成立}$$

则称 Y 为 $k(\theta)$ 的 **MVUE**。

重要结论: 有效估计量一定是 MVUE, 但 MVUE 不一定是有效估计量 (MVUE 的方差不一定达到 RCB)。

12.1 定义

定义 (Hogg Definition 7.2.1) : 设 $X_1, \dots, X_n$ 有联合分布 $f(x_1, \dots, x_n; \theta)$ 。若给定 $Y = u(X_1, \dots, X_n) = y$ 时, 样本的条件分布不依赖于 θ , 则称 Y 为 θ 的 **充分统计量**。

充分统计量的非唯一性: 若 Y_1 为充分统计量, $Y_2 = g(Y_1)$ 且 g 为一一对应 (双射), 则 Y_2 也是充分统计量。例如 $\sum X_i$ 和 $\bar{X}$ 同时为充分统计量。

12.2 Neyman 分解定理

定理 (Hogg Theorem 7.2.1) : Y 为充分统计量当且仅当:

$$f(x_1, \dots, x_n; \theta) = g[u(x_1, \dots, x_n); \theta] \cdot h(x_1, \dots, x_n)$$

12.3 充分统计量的典型例子

分布	充分统计量	备注
Bernoulli(θ)	$\sum X_i$	$\sim \text{Bin}(n, \theta)$
Po(θ)	$\sum X_i$	$\sim \text{Po}(n\theta)$
$N(\theta, \sigma_0^2)$	$\sum X_i$ (或 $\bar{X}$)	σ_0^2 已知
$N(\theta_1, \theta_2)$	$(\sum X_i, \sum X_i^2)$	或 $(\bar{X}, S^2)$
$U[0, \theta]$	$X_{(n)} = \max\{X_i\}$	
Exp(θ)	$\sum X_i$	$\sim \Gamma(n, 1/\theta)$

12.4 Rao-Blackwell 定理

定理 (Hogg Theorem 7.3.1) : 设 Y 为 $k(\theta)$ 的无偏估计, T 为充分统计量。定义 $\varphi(T) = E[Y|T]$, 则:

1. $\varphi(T)$ 无偏
2. $\text{Var}[\varphi(T)] \leq \text{Var}(Y)$

Rao-Blackwell 定理为什么要求 T 为充分统计量?

因为 $\varphi(T) = E[Y|T]$ 必须是统计量 (不依赖于 θ)。若 T 不是充分的, 则条件分布 $Y|T$ 可能依赖于 θ , $E[Y|T]$ 就不是统计量。

反例: 设 $X_1, X_2 \sim N(\theta, 1)$, $T = X_1 + 2X_2$ (不是充分的), $Y = X_1$ 。则 $E[Y|T]$ 依赖于 θ , 不是统计量。

12.5 MLE 是充分统计量的函数

定理 (Hogg Theorem 7.3.2) : 若 MLE $\hat{\theta}$ 唯一存在, 则 $\hat{\theta}$ 必为充分统计量的函数。

推论: 若 MLE 自身即为充分统计量, 则它必为**最小充分统计量**。

例如:

- $N(\theta, \sigma_0^2)$, σ_0 已知: $\hat{\theta} = \bar{X}$ 为最小充分统计量
- $\text{Po}(\theta)$: $\hat{\theta} = \bar{X}$ 为最小充分统计量
- $U[0, \theta]$: $\hat{\theta} = X_{(n)}$ 为最小充分统计量

12.6 均匀分布 $U[0, \theta]$ 的 Rao-Blackwell 改进

题目: 设 $X_1, \dots, X_n \sim U[0, \theta]$, $Y_1 = X_{(n)}$ 为充分统计量。用 $Y_2 = X_1$ 改进对 θ 的估计。

解答:

$E[X_1] = \theta/2$ 。考虑 $\varphi(Y_1) = E[X_1|Y_1 = y]$:

给定 $Y_1 = y$, X_1 的条件分布: 若 $X_1 = y$, 则 $X_2, \dots, X_n \leq y$; 若 $X_1 < y$, 则 $X_2, \dots, X_n \leq y$ 且至少一个等于 y 。

通过对称性, $E[X_1|Y_1 = y] = \frac{n+1}{n} \cdot \frac{y}{2} + \frac{y}{n} = \frac{n+1}{2n}y$ 。

因此 $\varphi(Y_1) = \frac{n+1}{2n}Y_1$ 。注意到 $E[Y_1] = \frac{n}{n+1}\theta$, 故:

$$E[\varphi(Y_1)] = \frac{n+1}{2n} \cdot \frac{n}{n+1}\theta = \frac{\theta}{2}$$

改进后的估计量为 $\hat{\theta} = \frac{n+1}{n}Y_1 = \frac{n+1}{n}X_{(n)}$, 这是 θ 的**MVUE**。

12.7 指数分布 $\text{Exp}(1/\theta)$ 的 MVUE

题目: 设 $X_1, \dots, X_n \sim \text{Exp}(1/\theta)$, 即 $f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}$, $x > 0$.

解答:

$Y = \sum_{i=1}^n X_i$ 为充分统计量, 且 $Y \sim \Gamma(n, \theta)$.

$\bar{X} = Y/n$, $E[\bar{X}] = \theta$, $\text{Var}(\bar{X}) = \theta^2/n$.

Fisher 信息量: $I(\theta) = 1/\theta^2$, $\text{RCB} = \theta^2/n = \text{Var}(\bar{X})$.

故 $\bar{X}$ 为有效估计量, 也是 MVUE.

12.8 Beta($\theta, 1$) 分布的充分统计量

题目: 设 $X_1, \dots, X_n \sim \text{Beta}(\theta, 1)$, $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$.

解答:

似然函数: $L(\theta) = \theta^n \prod_{i=1}^n X_i^{\theta-1} = \theta^n \exp\{(\theta-1) \sum_{i=1}^n \ln X_i\}$

由 Neyman 分解定理, $Y = \sum_{i=1}^n \ln X_i$ (或等价地 $\prod_{i=1}^n X_i$) 为充分统计量.

【作业例题】Ass6 Problem 5: 均匀分布的充分统计量

题目: 证明 $X_{(n)}$ 是 $U[0, \theta]$ 的充分统计量.

解答:

联合 p.d.f.: $f(x; \theta) = \frac{1}{\theta^n} I(0 \leq x_1, \dots, x_n \leq \theta) = \frac{1}{\theta^n} I(x_{(n)} \leq \theta) \cdot I(x_{(1)} \geq 0)$

$g(x_{(n)}; \theta) = \frac{1}{\theta^n} I(x_{(n)} \leq \theta)$, $h(x) = I(x_{(1)} \geq 0)$. 由分解定理得证.

【作业例题】Ass6 Problem 6: 正态分布的 Rao-Blackwell

题目: $X_1, X_2 \sim N(\theta, 1)$, $Y = X_1$, $T = X_1 + X_2$.

解答:

$E[X_1|T=t] = t/2 = \bar{X}$. 改进后 $\text{Var}(\bar{X}) = 1/2 < \text{Var}(X_1) = 1$.

【作业例题】Ass6 Problem 7: 泊松分布的 Rao-Blackwell

题目: $X_1, X_2, X_3 \sim \text{Po}(\theta)$, 估计 $g(\theta) = e^{-\theta} = P(X_1 = 0)$.

解答:

$Y = I(X_1 = 0)$ 无偏. $T = \sum X_i$ 充分完备.

$\varphi(t) = P(X_1 = 0|T=t) = \frac{P(X_1=0)P(\sum_{i=2}^3 X_i=t)}{P(T=t)} = \left(\frac{2}{3}\right)^t$

MVUE: $\varphi(T) = (2/3)^{\sum X_i}$

第十三讲：完备性与指数分布类

13.1 完备性

定义 (Hogg Definition 7.4.1)：设随机变量 Z 的 p.d.f. 或 p.m.f. 属于分布族 $\{h(z; \theta) : \theta \in \Omega\}$ 。若对任意函数 $u(\cdot)$ ，条件 " $E_\theta[u(Z)] = 0$ 对每个 $\theta \in \Omega$ 成立" 要求 " $u(Z) = 0$ 在除了一个概率为 0 的集合之外都成立" (即 $P_\theta\{u(Z) = 0\} = 1$ 对所有 $\theta \in \Omega$ 成立，或表述为 " $u(Z)$ 几乎必然等于 0")，则称分布族 $\{h(z; \theta) : \theta \in \Omega\}$ 为一个**完备族** (complete family)。

13.2 完备性的典型例子

(1) 指数分布 $\text{Exp}(1/\theta)$ — Laplace 变换论证

设 Z 的 p.d.f. 为 $h(z; \theta) = \frac{1}{\theta} e^{-z/\theta}, z > 0, \theta > 0$ 。

若 $E_\theta[u(Z)] = 0$ 对所有 $\theta > 0$ 成立，则：

$$\int_0^\infty u(z) \cdot \frac{1}{\theta} e^{-z/\theta} dz = 0 \Rightarrow \int_0^\infty u(z) e^{-z/\theta} dz = 0$$

这是 $u(\cdot)$ 的 **Laplace 变换**。只有当 $u(\cdot)$ 几乎必然为 0 时，上式才能对所有 θ 都成立。所以 Z 的分布族为**完备族**。

(2) Poisson 分布 — 系数逐项比较

设 $X_1, \dots, X_n \sim \text{Po}(\theta), Y = \sum X_i \sim \text{Po}(n\theta)$ 。

若 $E_\theta[u(Y)] = 0$ 对所有 $\theta > 0$ 成立，则：

$$\sum_{y=0}^\infty u(y) \frac{(n\theta)^y e^{-n\theta}}{y!} = 0 \Rightarrow u(0) + u(1) \frac{n\theta}{1!} + u(2) \frac{(n\theta)^2}{2!} + \dots = 0$$

令 $\theta \rightarrow 0$ ，得 $u(0) = 0$ 。代回后令 $\theta \rightarrow 0$ ，得 $u(1) = 0$ 。依此类推，可得 $u(0) = u(1) = u(2) = \dots = 0$ 。故 Y 的分布族为**完备族**。

(3) 均匀分布 $U[0, \theta]$ — 证明完备性

设 $X_1, \dots, X_n \sim U[0, \theta], Y = X_{(n)}$ 。

Y 的 p.d.f. 为 $g(y; \theta) = \frac{ny^{n-1}}{\theta^n}, 0 \leq y \leq \theta$ 。

若 $E_\theta[u(Y)] = 0$ 对所有 $\theta > 0$ 成立，则：

$$\int_0^\theta u(t) \cdot \frac{nt^{n-1}}{\theta^n} dt = 0 \Rightarrow \int_0^\theta u(t) t^{n-1} dt = 0$$

对 θ 求偏导 (微积分基本定理)： $u(\theta)\theta^{n-1} = 0$ 。因为 $\theta > 0$ ，所以 $u(\theta) = 0$ 对任意 θ 成立。从而推出 Y 为**完备充分统计量**。

分布	完备充分统计量	是否完备
Bernoulli(θ)	$\sum X_i$	是
Po(θ)	$\sum X_i$	是
$N(\theta, \sigma_0^2)$	$\sum X_i$	是
$N(\theta_1, \theta_2)$	$(\sum X_i, \sum X_i^2)$	是

分布	完备充分统计量	是否完备
$\text{Exp}(1/\theta)$	$\sum X_i$	是
$U[0, \theta]$	$X_{(n)}$	是
$\text{Beta}(\theta, 1)$	$\sum \ln X_i$	是

13.3 正则指数分布类

定义 (Hogg Definition 7.7.1)：考虑一族分布 $\{f(x; \theta) : \theta \in \Omega\}$ ，其中 $\Omega = \{\theta : \gamma < \theta < \delta\}$ ， γ 和 δ 为已知常数（可以为 $\pm\infty$ ）。称 $\{f(x; \theta) : \theta \in \Omega\}$ 属于**正则指数分布类** (regular exponential class)，如果：

$$f(x; \theta) = \exp\{p(\theta)K(x) + H(x) + q(\theta)\}, \quad x \in S$$

并且满足以下条件：

- 1. **支撑集 S 不依赖于 θ**
- 2. **$p(\theta)$ 为 θ 的连续非平凡函数**（即不为常数）
- 3. **若 X 为连续型**： $K'(x) \neq 0$ ，且 $H(x)$ 为 $x \in S$ 的连续函数。**若 X 为离散型**： $K(x)$ 为 $x \in S$ 的非平凡函数

非正则的例子： $U[0, \theta]$ （支撑集 $S = [0, \theta]$ 依赖于 θ ）

典型分布的参数：

分布	$K(x)$	$p(\theta)$	$H(x)$	$q(\theta)$
$\text{Bernoulli}(\theta)$	x	$\ln \frac{\theta}{1-\theta}$	0	$\ln(1 - \theta)$
$\text{Bin}(n, \theta)$ (n 已知)	x	$\ln \frac{\theta}{1-\theta}$	$\ln \binom{n}{x}$	$n \ln(1 - \theta)$
$\text{Po}(\theta)$	x	$\ln \theta$	$-\ln(x!)$	$-\theta$
$N(\theta, \sigma_0^2)$	x	θ/σ_0^2	$-x^2/(2\sigma_0^2)$	$-\frac{\theta^2}{2\sigma_0^2} - \frac{1}{2}\ln(2\pi\sigma_0^2)$
$N(\mu_0, \theta)$ (μ_0 已知)	$(x - \mu_0)^2$	$-\frac{1}{2\theta}$	$-\frac{1}{2}\ln(2\pi)$	$-\frac{1}{2}\ln \theta$
$\text{Exp}(\theta)$	x	$-\theta$	0	$\ln \theta$
$\Gamma(\theta, \beta_0)$ (β_0 已知, 形状参数未知)	$\ln x$	$\theta - 1$	$-x/\beta_0$	$-\ln \Gamma(\theta) - \theta \ln \beta_0$
$\Gamma(\alpha_0, \theta)$ (α_0 已知, 尺度参数未知)	x	$-\frac{1}{\theta}$	$(\alpha_0 - 1) \ln x$	$-\ln \Gamma(\alpha_0) - \alpha_0 \ln \theta$

13.4 正则指数分布的性质

1. $Y = \sum K(X_i)$ 为完备充分统计量
2. 若 $E[\varphi(Y)] = k(\theta)$, 则 $\varphi(Y)$ 为 $k(\theta)$ 的唯一 MVUE

期望与方差 (单个观测 X) :

$$E[K(X)] = -\frac{q'(\theta)}{p'(\theta)}, \quad \text{Var}[K(X)] = \frac{p''(\theta)q'(\theta) - q''(\theta)p'(\theta)}{[p'(\theta)]^3}$$

13.5 Hogg Theorem 7.5.1 (正则指数分布中 Y_1 的分布、期望与方差)

定理: 设样本 $X_1, \dots, X_n$ 的分布属于正则指数分布类, p.d.f. 或 p.m.f. 形如 $f(x; \theta) = \exp\{p(\theta)K(x) + H(x) + q(\theta)\}$ 。考虑统计量 $Y_1 = \sum_{i=1}^n K(X_i)$ 。则:

(1) Y_1 的 p.d.f. 或 p.m.f. 具有如下形式:

$$f_{Y_1}(y_1; \theta) = R(y_1) \exp\{p(\theta)y_1 + nq(\theta)\}, \quad y_1 \in S_{Y_1}$$

其中 $R(y_1)$ 和 S_{Y_1} 都不依赖于 θ 。

(2) $E(Y_1) = -nq'(\theta)/p'(\theta)$

(3) $\text{Var}(Y_1) = n\{p''(\theta)q'(\theta) - q''(\theta)p'(\theta)\}/[p'(\theta)]^3$

✅ 这两式正确 (已数值核验)。因 $Y_1 = \sum_{i=1}^n K(X_i)$ 为 iid 之和, 故 $E(Y_1) = nE[K(X)]$ 、 $\text{Var}(Y_1) = n \text{Var}[K(X)]$, 恰为 13.4 中单观测结果的 n 倍——注意方差分母同为 $[p'(\theta)]^3$ 。

验证 (Poisson(θ)) : $E(Y_1) = -n(-1)/(1/\theta) = n\theta$, $\text{Var}(Y_1) = n \cdot \frac{(-1/\theta^2)(-1)-0}{(1/\theta)^3} = n\theta$; 而 $Y_1 = \sum X_i \sim \text{Po}(n\theta)$, 均值方差皆为 $n\theta$ ✓。

13.6 Hogg Theorem 7.5.2 (完备充分统计量)

定理: 设样本 $X_1, \dots, X_n$ 的分布属于正则指数分布类。则统计量 $Y_1 = \sum_{i=1}^n K(X_i)$ 为 θ 的完备充分统计量。

证明概要:

- **充分性:** 由 Neyman 分解定理直接得到。
- **完备性:** 假设 $E_\theta[u(Y_1)] = 0$ 对所有 θ 成立。根据定理 7.5.1:

$$\int_{y_1 \in S_{Y_1}} u(y_1) R(y_1) \exp\{p(\theta)y_1 + nq(\theta)\} dy_1 = 0$$

进一步得到:

$$\int_{y_1 \in S_{Y_1}} u(y_1) R(y_1) \exp\{p(\theta)y_1\} dy_1 = 0$$

对所有 θ 成立。因为 $p(\theta)$ 非平凡, 上式本质上为 $u(y_1)R(y_1)$ 的 Laplace 变换。于是 $u(y_1)R(y_1) \equiv 0$ 。因为 $R(y_1) > 0$ (由 $f_{Y_1}(y_1; \theta) > 0$ 得到), 故 $u(y_1) \equiv 0$ 。完备性得证。

13.7 Lehmann-Scheffe 定理与 MVUE

定理: 设 T 为完备充分统计量, $\varphi(T)$ 为 $k(\theta)$ 的无偏估计, 则 $\varphi(T)$ 为唯一 MVUE。

求 MVUE 的步骤:

1. 写成正则指数形式 $\Rightarrow$ 找到完备充分统计量 T

2. 找一个无偏估计 U (任意, 形式简单)
3. 应用 Rao-Blackwell: 计算 $\varphi(T) = E[U|T]$
4. $\varphi(T)$ 即为 MVUE

【作业例题】HW7 Problem 2: $\Gamma(4, \theta)$ 的完备充分统计量与 MVUE

题目: $f(x; \theta) = \frac{1}{6\theta^4} x^3 e^{-x/\theta}, x > 0$ 。

解答:

(1) 完备充分统计量

写成指数族形式:

$$f(x; \theta) = \exp \left[-\frac{x}{\theta} + 3 \ln x - \ln(6\theta^4) \right]$$

- $K(x) = x$
- $p(\theta) = -\frac{1}{\theta}$ ($\theta > 0$ 时单调递增)
- $H(x) = 3 \ln x$
- $q(\theta) = -\ln(6\theta^4) = -\ln 6 - 4 \ln \theta$

验证正则条件: 支撑 $\{x : x > 0\}$ 不依赖于 θ ; $p(\theta)$ 连续可导。故为正则指数分布类。

由正则指数分布的性质, 完备充分统计量为:

$$Y = \sum_{i=1}^n X_i$$

(2) θ 的 MVUE

这是 $\Gamma(4, \theta)$ 分布 (形状参数 $\alpha = 4$, 尺度参数 $\beta = \theta$)。

由 Gamma 分布性质: $E[X] = 4\theta, \text{Var}(X) = 4\theta^2$

$E[Y] = \sum E[X_i] = 4n\theta$, 故 $E[Y/(4n)] = \theta$

$\frac{Y}{4n} = \frac{\bar{X}}{4}$ 是完备充分统计量 Y 的函数, 且为无偏估计。

由 Lehmann-Scheffe 定理:

$$\hat{\theta}_{MVUE} = \frac{\sum X_i}{4n} = \frac{\bar{X}}{4}$$

【作业例题】HW7 Problem 3: $N(\mu_0, \theta)$ 的 MVUE 与有效性 (详细解答)

解答:

(1) 完备充分统计量

$$f(x; \theta) = \exp \left[-\frac{1}{2\theta} (x - \mu_0)^2 - \frac{1}{2} \ln(2\pi\theta) \right]$$

正则指数形式, $K(x) = (x - \mu_0)^2, p(\theta) = -\frac{1}{2\theta}$ 。

完备充分统计量: $Y = \sum_{i=1}^n (X_i - \mu_0)^2$

(2) MVUE

$$\frac{Y}{\theta} \sim \chi^2(n), \quad E[Y] = n\theta.$$

$$\hat{\theta} = Y/n = \frac{1}{n} \sum (X_i - \mu_0)^2 \text{ 为 MVUE.}$$

(3) 有效性

$$I(\theta) = \frac{1}{2\theta^2}, \quad \text{RCB} = \frac{2\theta^2}{n}$$

$$\text{Var}(\hat{\theta}) = \frac{\text{Var}(Y)}{n^2} = \frac{2n\theta^2}{n^2} = \frac{2\theta^2}{n} = \text{RCB}$$

故为**有效估计量**。

【作业例题】HW7 Problem 6: 泊松分布 $P(X = k)$ 的 MVUE (详细解答)

题目: $X_1, \dots, X_n \sim \text{Po}(\theta)$, 求 $g(\theta) = P(X_1 = k) = \frac{\theta^k e^{-\theta}}{k!}$ 的 MVUE。

解答:

(a) $f(x; \theta) = \exp(x \ln \theta - \ln(x!) - \theta)$

完备充分统计量: $Y_1 = \sum X_i \sim \text{Po}(n\theta)$

(b) $U = I(X_1 = k), E[U] = P(X_1 = k) = g(\theta)$, 无偏。

(c) Rao-Blackwell 改进:

$$\begin{aligned} \varphi(t) &= E[I(X_1 = k) | Y_1 = t] = \frac{P(X_1 = k) P(\sum_{i=2}^n X_i = t - k)}{P(Y_1 = t)} \\ &= \frac{\frac{\theta^k e^{-\theta}}{k!} \cdot \frac{((n-1)\theta)^{t-k} e^{-(n-1)\theta}}{(t-k)!}}{\frac{(n\theta)^t e^{-n\theta}}{t!}} = \binom{t}{k} \left(\frac{1}{n}\right)^k \left(1 - \frac{1}{n}\right)^{t-k} \end{aligned}$$

MVUE:

$$\binom{\sum X_i}{k} \left(\frac{1}{n}\right)^k \left(1 - \frac{1}{n}\right)^{\sum X_i - k}$$

【作业例题】HW7 Problem 8: 逆高斯分布的完备充分统计量 (详细解答)

题目: $f(x; \theta_1, \theta_2) = \sqrt{\frac{\theta_1}{2\pi x^3}} \exp\left(-\frac{\theta_1(x - \theta_2)^2}{2\theta_2^2 x}\right)$

解答:

$$f(x; \theta_1, \theta_2) = \exp\left(-\frac{\theta_1}{2\theta_2^2}x - \frac{\theta_1}{2} \cdot \frac{1}{x} + \frac{\theta_1}{\theta_2} + \frac{1}{2} \ln \frac{\theta_1}{2\pi x^3}\right)$$

双参数正则指数分布:

- $K_1(x) = x, p_1 = -\frac{\theta_1}{2\theta_2^2}$
- $K_2(x) = 1/x, p_2 = -\frac{\theta_1}{2}$

完备充分统计量:

$$T_1 = \sum_{i=1}^n X_i, \quad T_2 = \sum_{i=1}^n \frac{1}{X_i}$$

第十四讲：参数的函数、最小充分性与从属统计量

14.0 求参数函数 $g(\theta)$ 的 MVUE — 两种方法

问题：如何找到参数 θ 的一个函数 $g(\theta)$ 的 MVUE?

方法一 (Lehmann-Scheffe 定理)：直接计算完备充分统计量 Y_1 的某一函数的期望值，有必要的话再纠偏。

方法二 (Rao-Blackwell 定理)：先找到一个无偏统计量 Y_2 ，再计算 $E(Y_2|Y_1)$ 。

14.1 参数函数的估计 — 具体例子

例 1: Bernoulli(θ) 中 $g(\theta) = \theta(1 - \theta)$ 的 MVUE

方法一 (Lehmann-Scheffe)：

完备充分统计量 $Y = \sum X_i \sim \text{Bin}(n, \theta)$ 。 $\theta(1 - \theta)$ 的 MLE 为 $\tilde{\delta} = \bar{X}(1 - \bar{X})$ 。

$$\begin{aligned} E[\tilde{\delta}] &= E\left[\frac{Y}{n}\left(1 - \frac{Y}{n}\right)\right] = \frac{1}{n}E[Y] - \frac{1}{n^2}E[Y^2] \\ &= \theta - \frac{1}{n^2}\{n\theta(1 - \theta) + (n\theta)^2\} = \theta - \frac{\theta(1 - \theta)}{n} - \theta^2 = \frac{n-1}{n}\theta(1 - \theta) \end{aligned}$$

纠偏后： $\hat{\delta} = \frac{n}{n-1}\tilde{\delta} = \frac{n}{n-1}\bar{X}(1 - \bar{X}) = \frac{Y(n-Y)}{n(n-1)}$ 为 MVUE。

方法二 (Rao-Blackwell)：

$X_1 + X_2 \sim \text{Bin}(2, \theta)$ ，故 $P(X_1 + X_2 = 1) = 2\theta(1 - \theta)$ 。

令 $Y_2 = I\{X_1 + X_2 = 1\}/2$ ，则 Y_2 为 $\theta(1 - \theta)$ 的无偏估计。

计算 $E[Y_2|Y = y]$ ：

$$E[Y_2|Y = y] = \frac{P(X_1 + X_2 = 1, Y = y)}{2P(Y = y)} = \frac{y(n-y)}{n(n-1)}$$

两种方法得到一致的结果。

例 2: $N(\theta, 1)$ 中 $g(\theta) = \theta^2$ 的 MVUE

方法一 (Lehmann-Scheffe)：

$\bar{X}$ 为完备充分统计量， $\bar{X} \sim N(\theta, 1/n)$ 。

$$E[\bar{X}^2] = (E\bar{X})^2 + \text{Var}(\bar{X}) = \theta^2 + 1/n。$$

故 $\bar{X}^2 - 1/n$ 为 θ^2 的 MVUE。

方法二 (Rao-Blackwell)：

$Y_2 = X_1^2 - 1$ 为无偏估计 (因为 $E[X_1^2] = \theta^2 + 1$)。

计算 $E[Y_2|\bar{X}]$ ：($X_1, \bar{X}$) 为二元正态，给定 $\bar{X} = \bar{x}$ 时：

$$X_1|\bar{X} = \bar{x} \sim N(\bar{x}, (n-1)/n)$$

$$\text{故 } E[X_1^2|\bar{X} = \bar{x}] = \bar{x}^2 + (n-1)/n, \quad E[Y_2|\bar{X} = \bar{x}] = \bar{x}^2 - 1/n。$$

MVUE 为 $\bar{X}^2 - 1/n$ (与方法一一致)。

例 3: $N(\theta, 1)$ 中 $g(\theta) = P(X \leq c) = \Phi(c - \theta)$ 的 MVUE

$\bar{X}$ 为完备充分统计量。令 $u(X_1) = I\{X_1 \leq c\}$, 则 $E[u(X_1)] = \Phi(c - \theta)$, 无偏。

给定 $\bar{X} = \bar{x}$, $X_1 | \bar{X} = \bar{x} \sim N(\bar{x}, (n-1)/n)$ 。

$$E[u(X_1) | \bar{X} = \bar{x}] = P(X_1 \leq c | \bar{X} = \bar{x}) = \Phi\left(\sqrt{\frac{n}{n-1}}(c - \bar{x})\right)$$

MVUE 为 $\Phi\left(\sqrt{\frac{n}{n-1}}(c - \bar{X})\right)$ 。

例 4: 单样本 $\text{Po}(\theta)$ 中 $g(\theta) = e^{-2\theta}$ 的 MVUE

仅有一个样本 $X_1 \sim \text{Po}(\theta)$, X_1 自身为完备充分统计量。

令 $Y_2 = (-1)^{X_1}$, 则:

$$E[Y_2] = \sum_{x=0}^{\infty} (-1)^x \frac{\theta^x e^{-\theta}}{x!} = e^{-\theta} \sum_{x=0}^{\infty} \frac{(-\theta)^x}{x!} = e^{-\theta} \cdot e^{-\theta} = e^{-2\theta}$$

故 $Y_2 = (-1)^{X_1}$ 为 $e^{-2\theta}$ 的 MVUE。

注: 此估计量虽然无偏且为 MVUE, 但表现可能不好 (仅取 ± 1)。这说明 MVUE 不一定是最优估计量。

例 5: $U[0, \theta]$ 中 $g(\theta)$ 的一般 MVUE

$Y = X_{(n)}$, p.d.f. $f_Y(y; \theta) = \frac{ny^{n-1}}{\theta^n}, 0 \leq y \leq \theta$ 。

希望找到 $u(\cdot)$ 使得 $E[u(Y)] = g(\theta)$:

$$\int_0^\theta u(y) \cdot \frac{ny^{n-1}}{\theta^n} dy = g(\theta) \Rightarrow \int_0^\theta u(y) ny^{n-1} dy = \theta^n g(\theta)$$

两边对 θ 求导:

$$u(\theta) \cdot n\theta^{n-1} = n\theta^{n-1}g(\theta) + \theta^n g'(\theta)$$

$$u(\theta) = g(\theta) + \frac{\theta g'(\theta)}{n}$$

$$g(\theta) \text{ 的 MVUE 为: } \boxed{u(Y) = g(Y) + \frac{Yg'(Y)}{n}}$$

例如 $g(\theta) = \theta$: $u(Y) = Y + Y/n = \frac{n+1}{n}Y = \frac{n+1}{n}X_{(n)}$ 。

14.2 多参数情形 — 联合充分统计量

定义 (联合充分统计量, jointly sufficient statistics): 假设 $X_1, \dots, X_n$ 有 p.d.f. 或 p.m.f. $f(x; \theta)$, $\theta \in \Omega \subset \mathbb{R}^p$ 。设 $\mathbf{Y} = (Y_1, \dots, Y_m)^\top$ 为 m 维统计量, 其中 $Y_i = u_i(X_1, \dots, X_n)$ 。称 $\mathbf{Y}$ 为 θ 的**联合充分统计量**, 如果:

$$\prod_{i=1}^n f(x_i; \theta) = f_{\mathbf{Y}}(\mathbf{y}; \theta) \cdot H(x_1, \dots, x_n)$$

其中 $H(x_1, \dots, x_n)$ 不依赖于 θ 。

Neyman 分解定理 (多参数情形): $\mathbf{Y}$ 为联合充分统计量, 当且仅当:

$$\prod_{i=1}^n f(x_i; \theta) = k_1(\mathbf{y}; \theta) \cdot k_2(x_1, \dots, x_n)$$

其中 k_2 不依赖于 θ 。

例子: 设 $X_1, \dots, X_n \sim N(\theta, \theta^2)$, $\theta \in \mathbb{R}$ 。

似然函数: $L(\theta) = (2\pi\theta^2)^{-n/2} \exp\left\{-\frac{1}{2\theta^2} \sum X_i^2 + \frac{1}{\theta} \sum X_i - \frac{n}{2}\right\}$

联合充分统计量: $(\sum X_i^2, \sum X_i)^\top$ (或等价地 $(\bar{X}, S^2)$)。

14.3 最小充分统计量

定义: 若一组联合充分统计量总是可以表示为其余任何一组联合充分统计量的函数, 则称其为**最小充分统计量** (minimal sufficient statistic)。

Lehmann-Scheffe 判定: $T(X)$ 为最小充分统计量, 当且仅当对任意样本 x, y , 比值 $\prod f(x_i; \theta) / \prod f(y_i; \theta)$ 与 θ 无关 $\Leftrightarrow T(x) = T(y)$ 。

重要结论:

- 完备充分统计量必然是最小充分统计量, 反之不一定。
- MLE 唯一存在时, 它是充分统计量的函数。若 MLE 自身即为充分统计量, 则它必为最小充分统计量。

例子: $X_1, \dots, X_n$ 服从 $[\theta - 1, \theta + 1]$ 上的均匀分布, p.d.f. $f(x; \theta) = \frac{1}{2} I_{\{x \in [\theta-1, \theta+1]\}}$ 。

似然函数: $L(\theta) = \frac{1}{2^n} I_{\{\min X_i \geq \theta-1\}} \cdot I_{\{\max X_i \leq \theta+1\}}$

$(\min X_i, \max X_i)^\top$ 为联合充分统计量, 不可能再减少。

但 $(\min X_i, \max X_i)^\top$ **不是完备的**: 令 $u(y_1, y_2) = \frac{y_2 - y_1}{2} - \frac{n-1}{n+1}$, 则 $E[u(\min X_i, \max X_i)] = 0$ 但 $u \not\equiv 0$ 。

问题: 对于参数 $\theta \in \mathbb{R}^k$, 最小充分统计量的维度是否一定为 k ?

答案: 不一定。上例中 $\theta \in \mathbb{R}$ (1 维), 但最小充分统计量为 2 维。

14.4 从属统计量与 Basu 定理

定义: 统计量 A 为**从属的** (ancillary), 若其分布不依赖于 θ 。

Basu 定理: 若 T 为完备充分统计量, A 为从属统计量, 则 T 与 A **独立**。

例子 1: $X_1, \dots, X_n \sim N(\theta, 1)$, θ 未知。

- $T = \bar{X}$ 完备充分
- $A_1 = S^2$ (样本方差), $A_2 = X_1 - \bar{X}$, $A_3 = (X_1 - \bar{X}, \dots, X_n - \bar{X})^\top$ 均为从属统计量
- 由 Basu 定理: $\bar{X} \perp S^2$, $\bar{X} \perp (X_1 - \bar{X})$, $\bar{X} \perp (X_1 - \bar{X}, \dots, X_n - \bar{X})^\top$

例子 2: $X_1, \dots, X_n \sim N(0, \sigma^2)$, σ^2 未知。

- $T = \sum X_i^2$ 完备充分
- $A_1 = X_1/X_2$, $A_2 = X_1/|X_1|$ 均为从属统计量 (分布不依赖于 σ^2)

例子 3: $X_1, \dots, X_n \sim \text{Po}(\theta)$ 。

- $T = \sum X_i$ 完备充分
- $A = X_1/T$ 为从属统计量
- 由 Basu 定理: $\sum X_i \perp X_1 / \sum X_i$

14.4 多参数 MVUE

对于多参数正则指数分布：

$$f(x; \theta) = \exp \left[\sum_{j=1}^k p_j(\theta) K_j(x) + S(x) + q(\theta) \right]$$

完备充分统计量： $(\sum K_1(X_i), \dots, \sum K_k(X_i))$ 。

第十五讲：最优假设检验 (Neyman-Pearson / UMP)

15.1 基本概念

假设的分类

- 简单假设**：参数完全确定 ($H_0 : \theta = \theta_0$)
- 复合假设**：参数不确定 ($H_0 : \theta \in \Omega_0$)

设样本 $\mathbf{X} = (X_1, \dots, X_n)$ 有 p.d.f. 或 p.m.f. $f(\mathbf{x}; \theta)$, $\theta \in \Omega$ 。假设 ω_0 和 ω_1 为 Ω 的不相交子集, 且 $\omega_0 \cup \omega_1 = \Omega$ 。考虑检验问题：

$$H_0 : \theta \in \omega_0 \quad \text{vs} \quad H_1 : \theta \in \omega_1$$

拒绝域 (Critical Region)

定义：样本空间 $\mathbb{R}^n$ 的一个子集 $C \subset \mathbb{R}^n$ 称为**拒绝域** (或**临界域**)。若观测值 $\mathbf{X} \in C$, 则拒绝 H_0 ; 若 $\mathbf{X} \in C^c$ (接受域), 则不拒绝 H_0 。

显著性水平 (Significance Level / Test Size)

定义：对于拒绝域为 C 的检验, 其**显著性水平** (或**检验水平**) 定义为：

$$\alpha = \max_{\theta \in \omega_0} P_{\theta}(\mathbf{X} \in C)$$

功效函数 (Power Function)

定义：拒绝域为 C 的检验的**功效函数**定义为：

$$\gamma_C(\theta) = P_{\theta}(\mathbf{X} \in C), \quad \theta \in \omega_1$$

当 $\theta \in \omega_1$ 时, $\gamma_C(\theta)$ 表示正确拒绝 H_0 的概率。

两类错误

	H_0 为真 ($\theta \in \omega_0$)	H_1 为真 ($\theta \in \omega_1$)
拒绝 H_0 ($\mathbf{X} \in C$)	第一类错误 (概率 α)	正确 (概率 = 功效)
不拒绝 H_0 ($\mathbf{X} \in C^c$)	正确	第二类错误 (概率 β)

15.2 最优拒绝域 (Best Critical Region)

定义

先考虑 H_0 与 H_1 都为简单假设的情形: $\omega_0 = \{\theta'\}, \omega_1 = \{\theta''\}, \Omega = \{\theta', \theta''\}$ 。检验问题为:

$$H_0: \theta = \theta' \quad \text{vs} \quad H_1: \theta = \theta''$$

定义 (最优拒绝域, best critical region): 称 C 为以上检验问题的显著性水平为 α 的**最优拒绝域**, 如果:

- (a) $P_{\theta'}(\mathbf{X} \in C) = \alpha$ (水平恰好为 α)
- (b) 对每个满足 $P_{\theta'}(\mathbf{X} \in A) = \alpha$ 的拒绝域 A , 有 $P_{\theta''}(\mathbf{X} \in C) \geq P_{\theta''}(\mathbf{X} \in A)$ (功效最大)

即: 在所有水平为 α 的拒绝域中, C 的功效最大。

15.3 Neyman-Pearson 引理

定理 (Neyman-Pearson, Hogg Theorem 8.1.1): 设 $\mathbf{X} = (X_1, \dots, X_n)$ 有 p.d.f. 或 p.m.f. $f(\mathbf{x}; \theta)$, 其中 $\theta \in \Omega = \{\theta', \theta''\}$ 。用 $L(\theta; \mathbf{X})$ 表示似然函数。对检验问题:

$$H_0: \theta = \theta' \quad \text{vs} \quad H_1: \theta = \theta''$$

若拒绝域 C 及常数 $k > 0$ 满足:

- (a) $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x}) \leq k$, 对每个 $\mathbf{x} \in C$ 成立
- (b) $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x}) \geq k$, 对每个 $\mathbf{x} \in C^c$ 成立 (C^c 为 C 的补集, 即接受域)
- (c) $\alpha = P_{\theta'}(\mathbf{X} \in C)$

则 C 为显著性水平为 α 的**最优拒绝域**。

说明: Neyman-Pearson 定理表示, 条件 (a)(b)(c) 是 C 为最优拒绝域的**充分条件**。还可以证明, 它们也是**必要条件**。

推论: 由条件 (a)(b), 最优拒绝域形如:

$$C = \left\{ \frac{L(\theta'; \mathbf{X})}{L(\theta''; \mathbf{X})} \leq k \right\} = \{L(\theta''; \mathbf{X}) \geq k' \cdot L(\theta'; \mathbf{X})\}$$

即: 似然比在 H_1 下相对较大时拒绝 H_0 。

15.4 无偏性 (Unbiasedness)

定义: 称显著性水平为 α 的拒绝域 C 为**无偏的**, 如果:

$$P_{\theta}(\mathbf{X} \in C) \geq \alpha, \quad \text{对所有 } \theta \in \omega_1 \text{ 都成立}$$

即: 在 H_1 下拒绝 H_0 的概率至少不小于在 H_0 下错误拒绝的概率。

推论 (Hogg Corollary 8.1.1): 对 Neyman-Pearson 定理中的检验问题, 若 C 为显著性水平为 α 的最优拒绝域, 则 C 为**无偏检验**。

证明: 考虑拒绝域 $A = \{W = 1\}$, 其中 W 为另一独立生成的 Bernoulli(α) 随机变量。则 $P_{\theta'}(\mathbf{X} \in A) = \alpha$ 。由于 C 为最优的, 故 $P_{\theta''}(\mathbf{X} \in C) \geq P_{\theta''}(\mathbf{X} \in A) = \alpha$ 。

15.5 充分统计量与最优拒绝域

若存在 θ 的充分统计量 $Y = u(\mathbf{X})$, 根据 Neyman 分解定理:

$$L(\theta'; \mathbf{X}) = k_1(Y, \theta') \cdot k_2(\mathbf{X}), \quad L(\theta''; \mathbf{X}) = k_1(Y, \theta'') \cdot k_2(\mathbf{X})$$

则似然比:

$$\frac{L(\theta'; \mathbf{X})}{L(\theta''; \mathbf{X})} = \frac{k_1(Y, \theta')}{k_1(Y, \theta'')}$$

结论: Neyman-Pearson 定理给出的最优拒绝域 $C = \{L(\theta'; \mathbf{X})/L(\theta''; \mathbf{X}) \leq k\}$ 可以转换为仅关于充分统计量 Y 的区域:

$$C = \left\{ \frac{k_1(Y, \theta')}{k_1(Y, \theta'')} \leq k \right\}$$

若在 H_0 下 Y 的分布已知, 可以根据显著性水平 α 求出临界值。

例子 (正态分布): 假设 $X_1, \dots, X_n \sim N(\theta, 1)$, 检验 $H_0: \theta = 0$ vs $H_1: \theta = 1$ 。

$$\text{似然比: } \frac{L(0; \mathbf{X})}{L(1; \mathbf{X})} = \exp\left(-\sum_{i=1}^n X_i + \frac{n}{2}\right)$$

拒绝域 $C = \{L(0; \mathbf{X})/L(1; \mathbf{X}) \leq k\}$ 可转化为 $C = \{\sum_{i=1}^n X_i \geq c_1\}$ 。

15.6 一致最优势检验 (UMP)

UMP 拒绝域的定义

定义 (一致最大功效拒绝域, uniformly most powerful (UMP) critical region) : 对检验问题:

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta \in \omega_1$$

若显著性水平为 α 的拒绝域 C 满足: 对任意 $\theta_1 \in \omega_1$, C 为检验问题 $H_0: \theta = \theta_0$ vs $H_1: \theta = \theta_1$ 的最优拒绝域, 则称 C 为原检验问题的一致最大功效 (UMP) 拒绝域。

单调似然比 (MLR)

定义: 称似然函数 $L(\theta; \mathbf{X})$ 具有关于统计量 $Y = u(\mathbf{X})$ 的**单调似然比** (monotone likelihood ratio, MLR), 如果对于 $\theta_1 < \theta_2$, 似然比 $L(\theta_1; \mathbf{X})/L(\theta_2; \mathbf{X})$ 为 Y 的单调函数。

Karlin-Rubin 定理

定理: 若似然函数有关于 Y 的单调似然比, 则检验问题 $H_0: \theta = \theta' \text{ vs } H_1: \theta > \theta'$ 具有 UMP 拒绝域。对于 $\theta' < \theta''$:

- 1. 若似然比 $L(\theta'; \mathbf{X})/L(\theta''; \mathbf{X})$ 关于 Y **单调递增**, 则 UMP 拒绝域形如 $C = \{Y \leq c_1\}$, 其中 c_1 满足 $P_{\theta'}(Y \leq c_1) = \alpha$ 。
- 2. 若上述似然比关于 Y **单调递减**, 则 UMP 拒绝域形如 $C = \{Y \geq c_1\}$, 其中 c_1 满足 $P_{\theta'}(Y \geq c_1) = \alpha$ 。

更广泛的复合假设

假设似然函数关于 Y 的单调似然比。考虑更广泛的检验问题：

$$H_0 : \theta \leq \theta' \quad \text{vs} \quad H_1 : \theta > \theta'$$

则它也有 UMP 拒绝域。上述结论的理由：只需说明拒绝域 C 的显著水平为 α ，即 $\max_{\theta \leq \theta'} P_{\theta}(\mathbf{X} \in C) = \alpha$ 。

我们已有 $P_{\theta'}(\mathbf{X} \in C) = \alpha$ 。对于 $\theta''' < \theta'$ ，考虑检验问题 $H_0 : \theta = \theta'''$ vs $H_1 : \theta = \theta'$ ，由 Neyman-Pearson 定理， C 亦为此问题的最优拒绝域。其检验水平为 $P_{\theta'''}(\mathbf{X} \in C)$ ，功效为 $P_{\theta'}(\mathbf{X} \in C) = \alpha$ 。根据无偏性推论， $P_{\theta'''}(\mathbf{X} \in C) \leq \alpha$ 。因此：

$$\max_{\theta \leq \theta'} P_{\theta}(\mathbf{X} \in C) = \alpha$$

正则指数分布类中的 MLR

若总体分布属于正则指数分布类：

$$f(x; \theta) = \exp\{p(\theta)K(x) + H(x) + q(\theta)\}$$

假设 $p(\theta)$ 为 θ 的单调增函数。则对 $\theta' < \theta''$ ，似然比：

$$\frac{L(\theta'; \mathbf{X})}{L(\theta''; \mathbf{X})} = \exp\{[p(\theta') - p(\theta'')] \sum_{i=1}^n K(X_i) + nq(\theta') - nq(\theta'')\}$$

为充分统计量 $Y = \sum_{i=1}^n K(X_i)$ 的单调递减函数（因为 $p(\theta') - p(\theta'') < 0$ ）。故 UMP 拒绝域形如：

$$C = \left\{ \sum_{i=1}^n K(X_i) \geq c_1 \right\}, \quad \text{其中 } c_1 \text{ 满足 } P_{\theta'} \left(\sum_{i=1}^n K(X_i) \geq c_1 \right) = \alpha$$

具有 MLR 的分布族：Bernoulli、Poisson、正态（均值参数）、指数分布、 Γ （形状固定）。

15.7 UMP 检验的典型例子

例 1：正态分布（方差已知）

右尾检验：假设 $X_1, \dots, X_n \sim N(\theta, 1)$ ，检验 $H_0 : \theta = \theta'$ vs $H_1 : \theta > \theta'$ 。

任取 $\theta'' > \theta'$ ，考虑 $H_0 : \theta = \theta'$ vs $H_1 : \theta = \theta''$ 。似然比：

$$\frac{L(\theta'; \mathbf{X})}{L(\theta''; \mathbf{X})} = \exp \left\{ -(\theta'' - \theta') \sum_{i=1}^n X_i + \frac{n(\theta''^2 - \theta'^2)}{2} \right\}$$

由于 $\theta'' > \theta'$ ，拒绝域转化为：

$$C = \left\{ \sum_{i=1}^n X_i \geq c_1 \right\}$$

在 H_0 下， $\sum_{i=1}^n X_i \sim N(n\theta', n)$ 。显著水平为 α 的 UMP 拒绝域为：

$$C = \left\{ \sum_{i=1}^n X_i \geq n\theta' + \sqrt{n} \cdot z_{\alpha} \right\}$$

它与 θ'' 无关，故为 UMP 拒绝域。

左尾检验： $H_0 : \theta = \theta'$ vs $H_1 : \theta < \theta'$ 。同理，UMP 拒绝域为：

$$C = \left\{ \sum_{i=1}^n X_i \leq n\theta' - \sqrt{n} \cdot z_\alpha \right\}$$

例 2：正态分布（均值已知）

假设 $X_1, \dots, X_n \sim N(0, \theta)$, 检验 $H_0 : \theta = \theta' \text{ vs } H_1 : \theta > \theta'$ 。

任取 $\theta'' > \theta'$, 似然比:

$$\frac{L(\theta'; \mathbf{X})}{L(\theta''; \mathbf{X})} = \left(\frac{\theta''}{\theta'} \right)^{n/2} \exp \left\{ -\frac{\theta'' - \theta'}{2\theta'\theta''} \sum_{i=1}^n X_i^2 \right\}$$

拒绝域转化为:

$$C = \left\{ \sum_{i=1}^n X_i^2 \geq c_1 \right\}$$

在 H_0 下, $\sum_{i=1}^n X_i^2 / \theta' \sim \chi^2(n)$ 。UMP 拒绝域为:

$$C = \left\{ \sum_{i=1}^n X_i^2 \geq \theta' \chi_\alpha^2(n) \right\}$$

例 3：指数分布

假设 X_1, X_2 为 $\text{Exp}(1/\theta)$ 的样本, p.d.f. 为 $f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}$, $x > 0$ 。检验 $H_0 : \theta = 2 \text{ vs } H_1 : \theta > 2$ 。

首先对任何 $\theta'' > 2$, 考虑 $H_0 : \theta = 2 \text{ vs } H_1 : \theta = \theta''$ 。最优拒绝域形如:

$$C = \left\{ \frac{e^{-(X_1+X_2)/2}}{2^2} \bigg/ \frac{e^{-(X_1+X_2)/\theta''}}{(\theta'')^2} \leq k \right\}$$

转化为 $C = \{X_1 + X_2 \geq c_1\}$ 。在 H_0 下, $X_1 + X_2 \sim \Gamma(2, 2)$ 。此拒绝域与 θ'' 取值无关, 故为 UMP 拒绝域。

例 4：泊松分布

假设 $X_1, \dots, X_n \sim \text{Po}(\theta)$ 。检验 $H_0 : \theta = \theta' \text{ vs } H_1 : \theta > \theta'$ 。

似然比:

$$\frac{L(\theta'; \mathbf{X})}{L(\theta''; \mathbf{X})} = \left(\frac{\theta'}{\theta''} \right)^{\sum X_i} e^{-n(\theta' - \theta'')} = \left(\frac{\theta' e}{\theta''} \right)^{\sum X_i} \cdot e^{n(\theta'' - \theta')}$$

转化为:

$$C = \left\{ \sum_{i=1}^n X_i \geq c_1 \right\}$$

在 H_0 下, $\sum_{i=1}^n X_i \sim \text{Po}(n\theta')$ 。UMP 拒绝域为:

$$C = \left\{ \sum_{i=1}^n X_i \geq c_1 \right\}, \quad P_{\theta'} \left(\sum_{i=1}^n X_i \geq c_1 \right) = \alpha$$

例 5：Bernoulli 分布

假设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$ 。检验 $H_0 : \theta \leq \theta' \text{ vs } H_1 : \theta > \theta'$ 。

$Y = \sum_{i=1}^n X_i$ 为充分统计量。当 $\theta' < \theta''$ 时, 似然比:

$$\frac{L(\theta'; \mathbf{X})}{L(\theta''; \mathbf{X})} = \left(\frac{\theta'(1-\theta'')}{\theta''(1-\theta')} \right)^{\sum X_i} \left(\frac{1-\theta'}{1-\theta''} \right)^n$$

为 $Y = \sum_{i=1}^n X_i$ 的单调递减函数 (因为 $\frac{\theta'(1-\theta'')}{\theta''(1-\theta')} < 1$)。故 UMP 拒绝域形如:

$$C = \left\{ \sum_{i=1}^n X_i \geq c_1 \right\}, \quad P_{\theta'} \left(\sum_{i=1}^n X_i \geq c_1 \right) = \alpha$$

分布	检验问题	UMP 拒绝域
$N(\theta, \sigma_0^2)$	$H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$	$\{\bar{X} \geq \theta_0 + z_\alpha \sigma_0 / \sqrt{n}\}$
$N(\mu_0, \theta)$	$H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$	$\{\sum (X_i - \mu_0)^2 \geq \theta_0 \chi_\alpha^2(n)\}$
$\text{Exp}(1/\theta)$	$H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$	$\{\sum X_i \geq c\}$
$\text{Po}(\theta)$	$H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$	$\{\sum X_i \geq c\}$
$\text{Bernoulli}(\theta)$	$H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$	$\{\sum X_i \geq c\}$

15.8 不存在 UMP 检验的情形

正态分布双边检验

最后考虑检验问题：

$$H_0: \theta = \theta' \quad \text{vs} \quad H_1: \theta \neq \theta'$$

综合右尾和左尾两种情况：

- 右尾 $H_1: \theta > \theta'$ 的 UMP 拒绝域为 $\{\sum X_i \geq n\theta' + \sqrt{n}z_\alpha\}$
- 左尾 $H_1: \theta < \theta'$ 的 UMP 拒绝域为 $\{\sum X_i \leq n\theta' - \sqrt{n}z_\alpha\}$

两者不同，故此**双边检验问题的 UMP 拒绝域不存在**。

一般结论：对于**双边检验** $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$ ，通常**不存在** UMP 检验。

15.9 广义似然比检验 (GLRT)

对复合假设 $H_0: \theta \in \Omega_0$ vs $H_1: \theta \in \Omega \setminus \Omega_0$ ：

$$\Lambda = \frac{\sup_{\theta \in \Omega_0} L(\theta)}{\sup_{\theta \in \Omega} L(\theta)}, \quad -2 \ln \Lambda \xrightarrow{d} \chi^2(r)$$

其中 $r = \dim(\Omega) - \dim(\Omega_0)$ 。

作业精选例题与解答汇总

Ass4 精选

【Ass4 Problem 1】正态分布的 Z 检验

题目: $\sigma^2 = 100, n = 25, \bar{x} = 13$ 。检验 $H_0: \mu = 10$ vs $H_1: \mu \neq 10, \alpha = 0.05$ 。

解答: $Z = \frac{13-10}{\sqrt{100/25}} = 1.5, |Z| = 1.5 < z_{0.025} = 1.96$, **不拒绝** H_0 。p-value = $2(1 - \Phi(1.5)) = 0.1336$ 。

【Ass4 Problem 2】正态分布的 t 检验

题目: $n = 16, \bar{x} = 41.5, s^2 = 16$ 。检验 $H_0: \mu = 44$ vs $H_1: \mu \neq 44$ 。

解答: $t = \frac{41.5-44}{\sqrt{16/16}} = -2.5, |t| = 2.5 > t_{0.025}(15) = 2.131$, **拒绝** H_0 。

【Ass4 Problem 3】两独立样本 t 检验

题目: 药物组 $n_1 = 9, \bar{x} = 101, s_1^2 = 16$; 安慰剂组 $n_2 = 9, \bar{y} = 105, s_2^2 = 20$ 。

解答: $s_p^2 = \frac{8 \times 16 + 8 \times 20}{16} = 18, t = \frac{101-105}{\sqrt{18(2/9)}} = -2, |t| = 2 < t_{0.025}(16) = 2.120$, **不拒绝** H_0 。

【Ass4 Problem 4】卡方拟合优度检验

题目: 检验骰子是否公平, 观测频数 $(17, 13, 22, 16, 25, 7), n = 100$ 。

解答: $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i} \approx 10.4, \chi_{0.05}^2(5) = 11.07 > 10.4$, **不拒绝** H_0 。

【Ass4 Problem 5】方差齐性 F 检验

题目: $n_A = 16, s_A^2 = 5.4; n_B = 21, s_B^2 = 9.6, \alpha = 0.02$ 。

解答: $F = 9.6/5.4 = 1.78, F_{0.01}(20, 15) = 3.09 > 1.78$, **不拒绝** H_0 。

【Ass4 Problem 6】配对 t 检验

题目: 10 名学生前后测差值 $D_i: (4, -2, -1, 0, 6, -5, 6, 1, 3, -3)$ 。

解答: $\bar{D} = 0.9, S_D^2 = 13.21, t = \frac{0.9}{\sqrt{13.21/10}} = 0.78, t_{0.025}(9) = 2.262 > 0.78$, **不拒绝** H_0 。

【Ass4 Problem 7】单因素 ANOVA

题目: $k = 3, n_1 = n_2 = n_3 = 4$ 。

解答: $SSB = 0.00224, SSW = 0.0162, F = \frac{0.00112}{0.0018} = 0.62, F_{0.05}(2, 9) = 4.26 > 0.62$, **不拒绝** H_0 。

【Ass4 Problem 8】卡方独立性检验

题目: 2×2 列联表, 检验性别与学术表现是否独立。

解答: $\chi^2 \approx 4.57, \chi_{0.05}^2(1) = 3.84 < 4.57$, **拒绝** H_0 。

【Ass4 Problem 9】方差置信区间

题目: $n = 25, s^2 = 12$ 。求 σ^2 的 90% CI。

解答:

$$\left[\frac{24 \times 12}{\chi_{0.05}^2(24)}, \frac{24 \times 12}{\chi_{0.95}^2(24)} \right] = \left[\frac{288}{36.42}, \frac{288}{13.85} \right] = [7.91, 20.79]$$

HW7 完整解答

【HW7 Problem 1】判断正则指数分布类

题目: 判断下列分布是否为正则指数分布类。

解答汇总:

分布	结论	完备充分统计量
(1) 几何分布 $f(x; \theta) = (1 - \theta)^x \theta$	是	$\sum X_i$
(2) 拉普拉斯 $f(x; a, b) = \frac{1}{2b} e^{- x-a /b}, a$ 已知	是	$\sum \ X_i - a\ $
(3) 瑞利分布 $f(x; \theta) = \frac{x}{\theta^2} e^{-x^2/(2\theta^2)}$	是	$\sum X_i^2$
(4) 负二项分布 $f(x; \theta) = \binom{x+r-1}{x} (1-\theta)^r \theta^x$	是	$\sum X_i$
(5) Beta($\theta, 1$) $f(x; \theta) = \theta x^{\theta-1}$	是	$\sum \ln X_i$
(6) 平移指数 $f(x; \theta) = e^{-(x-\theta)}, x > \theta$	否	支撑集依赖于 θ

【HW7 Problem 5】 $g(\theta) = a\theta^2 + b\theta + c$ 的 MVUE

题目: $X_1, \dots, X_n \sim N(\theta, \sigma_0^2), \sigma_0$ 已知。

解答: $\bar{X} \sim N(\theta, \sigma_0^2/n)$ 。

$$\hat{g} = a\bar{X}^2 + b\bar{X} + \left(c - \frac{a\sigma_0^2}{n} \right)$$

【HW7 Problem 7】Bin($2, \theta$) 中 $\theta(1 + \theta)$ 的 MVUE

题目: $X_1, \dots, X_n \sim \text{Bin}(2, \theta)$, 求 $g(\theta) = \theta(1 + \theta)$ 的 MVUE。

解答: $Y_1 = \sum X_i \sim \text{Bin}(2n, \theta)$ 。

通过 $E[Y_1] = 2n\theta$ 和 $E[Y_1^2] = 2n\theta(1 - \theta) + 4n^2\theta^2$ 建立方程:

$$\hat{g} = \frac{Y_1^2}{2n(2n-1)} + \frac{(n-1)Y_1}{n(2n-1)}$$

【HW7 Problem 4】Weibull 分布

题目： $f(x; \theta) = \frac{k_0}{\theta^{k_0}} x^{k_0-1} \exp(-x^{k_0}/\theta^{k_0})$, k_0 已知, $\theta > 0$.

解答：

(a) 令 $Y_i = X_i^{k_0}$, 则 $Y_i \sim \text{Exp}(1/\theta^{k_0}) = \Gamma(1, \theta^{k_0})$ 。

完备充分统计量： $Y = \sum X_i^{k_0}$

(b) $\widehat{\theta^{k_0}} = Y/n$

附录：公式速查表

A.1 常用分布的 Fisher 信息量

分布	参数	$I(\theta)$
Bernoulli(θ)	θ	$\frac{1}{\theta(1-\theta)}$
Po(θ)	θ	$\frac{1}{\theta}$
$N(\theta, \sigma_0^2)$	θ	$\frac{1}{\sigma_0^2}$
$N(\mu_0, \theta)$ (θ 为方差)	θ	$\frac{1}{2\theta^2}$
Exp(θ) (rate 参数)	θ	$\frac{1}{\theta^2}$
$\Gamma(\alpha_0, \beta)$	β	$\frac{\alpha_0}{\beta^2}$

A.2 Rao-Cramer 下界

$$\text{Var}(T) \geq \frac{[k'(\theta)]^2}{nI(\theta)}$$

A.3 三大检验统计量

检验	统计量	渐近分布
LRT	$-2 \ln \Lambda = -2 \ln \frac{L(\theta_0)}{L(\hat{\theta})}$	$\chi^2(1)$
Wald	$nI(\hat{\theta})(\hat{\theta} - \theta_0)^2$	$\chi^2(1)$
Score	$\frac{[l'(\theta_0)]^2}{nI(\theta_0)}$	$\chi^2(1)$

A.4 充分统计量速查

分布	充分统计量
Bernoulli(θ)	$\sum X_i$
Po(θ)	$\sum X_i$
$N(\theta, \sigma_0^2)$	$\sum X_i$
$N(\mu, \sigma^2)$	$(\sum X_i, \sum X_i^2)$
Exp(θ)	$\sum X_i$
$U[0, \theta]$	$X_{(n)}$
$\Gamma(\alpha_0, \beta)$	$\sum X_i$

A.5 正则指数分布类

标准形式： $f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)]$

- 完备充分统计量： $\sum K(X_i)$
- $E[K(X)] = -q'(\theta)/p'(\theta)$

A.6 假设检验速查

问题	检验统计量	分布	拒绝域
$H_0 : \mu = \mu_0 (\sigma \text{ 已知})$	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$N(0, 1)$	$ Z > z_{\alpha/2}$
$H_0 : \mu = \mu_0 (\sigma \text{ 未知})$	$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$t(n - 1)$	$ t > t_{\alpha/2}(n - 1)$
$H_0 : \sigma^2 = \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$	$\chi^2(n - 1)$	双尾
拟合优度	$\chi^2 = \sum \frac{(O-E)^2}{E}$	$\chi^2(k - 1)$	上尾
独立性	$\chi^2 = \sum \frac{(O-E)^2}{E}$	$\chi^2((r - 1)(c - 1))$	上尾

A.7 UMP 检验存在条件

检验问题	是否存在 UMP	条件
$H_0 : \theta = \theta_0 \text{ vs } H_1 : \theta \neq \theta_0$	一般不存在	--
$H_0 : \theta \leq \theta_0 \text{ vs } H_1 : \theta > \theta_0$	存在	MLR
$H_0 : \theta \geq \theta_0 \text{ vs } H_1 : \theta < \theta_0$	存在	MLR

A.8 MVUE 求解步骤

1. 写成正则指数形式 $\Rightarrow$ 找到完备充分统计量 T
2. 找一个无偏估计 U (任意, 形式简单)
3. 应用 Rao-Blackwell: 计算 $\varphi(T) = E[U|T]$
4. $\varphi(T)$ 即为 MVUE

重要定理汇总

定理名称	内容	应用场景
不变性定理	$\widehat{g(\theta)} = g(\hat{\theta})$	MLE 的函数
RCB 定理	$\text{Var}(T) \geq \frac{[k'(\theta)]^2}{nI(\theta)}$	判断有效性
Neyman 分解定理	$f = g(T; \theta)h(x)$	判定充分统计量
Rao-Blackwell 定理	$E[U T]$ 方差不增	改进无偏估计
Lehmann-Scheffe 定理	完备充分统计量的无偏函数 = MVUE	求 MVUE
Neyman-Pearson 引理	LRT 为 MP 检验	简单假设检验
Karlin-Rubin 定理	MLR $\Rightarrow$ UMP 存在	单边复合假设
Basu 定理	完备充分 $\perp$ 从属	独立性证明
χ^2_L 渐近分布	$-2 \ln \Lambda \xrightarrow{d} \chi^2(r)$	大样本检验
学生定理	$\bar{X} \sim N(\mu, \sigma^2/n), \bar{X} \perp S^2, (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$	正态总体推断

复习建议

1. 理解核心概念: 充分性、完备性、MVUE、MLR 等要深入理解
2. 掌握标准方法:
 - Neyman 分解定理判定充分统计量
 - Rao-Blackwell + Lehmann-Scheffe 求 MVUE
 - Neyman-Pearson 引理求 MP/UMP 检验
 - LRT / Wald / Score 三大检验的构造
3. 参数约定统一: 严格按照讲义记号 ($\text{Exp}(\theta)$ 为 rate 参数, $\Gamma(\alpha, \beta)$ 中 $E = \alpha\beta$)
4. 注意区分:
 - 充分 vs 完备 vs 最小充分
 - 简单假设 vs 复合假设
 - UMP 存在 vs 不存在的情形

- 正则指数分布 vs 非正则分布 (支撑集是否依赖参数)

祝考试顺利!