

Midterm Exam

April 23 2023, 1:20 – 3:20pm

考试说明:

1. 试卷包含判断题、单选题、以及计算题。总分100分。
2. 严禁使用一切辅助工具，包括计算器与自带草稿纸。
3. 违反考试纪律的将从严惩罚。
4. 请将所有答案写在答题纸上，并在答题纸上写好姓名。最后只需上交答题纸。
5. 计算题请写清楚解题过程，步骤分将占有重要比例。

一、判断题 (10分)

1. 若 T 为一个统计量， $g(\cdot)$ 为已知函数，则 $g(T)$ 也是统计量。 (**T**)
2. 检验的 p -值一定属于区间 $[0, 1]$ 。 (**T**)
3. 若 X 服从一个 t -分布，则 X^2 服从一个 F -分布。 (**T**)
4. 若 $\hat{\theta}$ 为 θ 的一个无偏估计量， $g(\cdot)$ 为已知函数，则 $g(\hat{\theta})$ 也是 $g(\theta)$ 的无偏估计量。 (**F**)
5. 置信区间的置信水平一定时，区间的期望长度越长越好。 (**F**)

二、单选题 (15分)

1. 假设 $X_1, \dots, X_{n_1}$ 为来自正态总体 $N(\mu_1, \sigma^2)$ 的样本，样本均值记为 $\bar{X}$ ，样本方差记为 S_1^2 。另外 $Y_1, \dots, Y_{n_2}$ 为来自另一个独立正态总体 $N(\mu_2, \sigma^2)$ 的样本，样本均值记为 $\bar{Y}$ ，样本方差记为 S_2^2 。下面说法错误的是 (**D**)

- A. $\bar{X} - \bar{Y}$ 服从正态分布。
- B. S_1^2/S_2^2 服从 F -分布。
- C. $\bar{X}, \bar{Y}, S_1^2, S_2^2$ 均互相独立。
- D. $S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$ 服从 $\chi^2(n_1 + n_2 - 2)$ 分布。

2. 下面估计量，不是无偏的是 (**C**)

- A. 泊松分布 $Po(\theta)$ 中, θ 的极大似然估计量。
- B. 正态分布 $N(\mu, \sigma^2)$ 中, μ, σ 未知时, μ 的极大似然估计量。
- C. 正态分布 $N(\mu, \sigma^2)$ 中, μ, σ 未知时, σ^2 的极大似然估计量。
- D. Bernoulli(θ)分布中, θ 的极大似然估计量。

3. 关于假设检验, 下面说法**正确**的是 (**C**)

- A. 显著水平就是犯第一类错误的概率。
- B. 功效就是犯第二类错误的概率。
- C. 选取拒绝域临界值的一般原则是, 优先控制犯第一类错误的概率不超过某个目标值。。
- D. 一般来说, 拒绝域越大 (指集合的范围越大), 则犯第一类错误的概率越小, 而犯第二类错误的概率越大。

4. 假设总体服从正态分布 $N(\mu, \sigma^2)$, 其中 μ 与 σ^2 均未知。对于给定 σ_0^2 , 要检验

$$H_0: \sigma^2 = \sigma_0^2 \quad \text{v.s.} \quad H_1: \sigma^2 < \sigma_0^2.$$

以下说法**正确**的是 (**D**)

- A. 可以取 $(n-1)S^2/\sigma^2$ 作为检验统计量。
- B. 当 S^2 太大或太小时, 都应该拒绝 H_0 。
- C. 选定显著水平 α 之后, 检验的功效就是一个唯一确定的值。
- D. 其它因素不变, 检验的 p -值随着样本方差 s^2 的增加而增加。

5. 以下关于方差分析的说法, **正确**的是 (**A**)

- A. S_E/σ^2 一定服从 $\chi^2(n-r)$ 分布。(S_E 为组内平方和)
- B. S_A/σ^2 一定服从 $\chi^2(r-1)$ 分布。(S_A 为组间平方和)
- C. S_T/σ^2 一定服从 $\chi^2(n-1)$ 分布。(S_T 为总离差平方和)
- D. 当 S_A/S_E 充分小时, 应该拒绝 H_0 。

三、计算题 (75分)

在计算题中, 可能用到以下的量:

- 1) 标准正态分布 $N(0, 1)$ 的上5%-分位数为 $z_{0.05} = 1.64$, 上2.5%-分位数为 $z_{0.025} = 1.96$.
- 2) 99个自由度的 t -分布 $t(99)$ 的上5%-分位数为 $t_{0.05}(99) = 1.66$, 上2.5%-分位数为 $t_{0.025}(99) = 1.98$.
- 3) $N(0, 1)$ 分布的c.d.f. (累积分布函数) 可以用 $\Phi(\cdot)$ 表示, $t(99)$ 分布的c.d.f. 可以用 $G(\cdot)$ 表示. 需要用到这两个量时, 可以用符号表示, 不必算出结果。

1. (12分) 假设总体 X 的p.d.f. 为

$$f(x; a, b) = \begin{cases} ab^a/x^{a+1}, & x \geq b \\ 0, & \text{其他情况.} \end{cases}$$

其中 $a > 0$ 与 $b > 0$ 均为未知参数。样本为 $X_1, \dots, X_n$. 请找出 a, b 的极大似然估计量。

答案:

首先, 可以写出似然函数

$$L = \frac{a^n b^{na}}{(\prod_{i=1}^n X_i)^{a+1}} I_{\{\min_{1 \leq i \leq n} X_i \geq b\}}.$$

为使得 L 非零, 必须有 $\min_{1 \leq i \leq n} X_i \geq b$ 成立。而 L 剩下的部分是 b 的递增函数, 因此 b 要尽可能取大值。于是 $\hat{b} = \min_{1 \leq i \leq n} X_i$.

在 $\hat{b} = \min_{1 \leq i \leq n} X_i$ 时, 取 L 的对数得到

$$l = n \log a + na \log \hat{b} - (a+1) \sum_{i=1}^n \log X_i.$$

对 a 求偏导, 并令其为0, 得到

$$\frac{\partial l}{\partial a} = \frac{n}{a} + n \log \hat{b} - \sum_{i=1}^n \log X_i = 0.$$

求解得到

$$\hat{a} = \frac{n}{\sum_{i=1}^n \log X_i - n \log \hat{b}}.$$

2. (12分) 假设总体 X 有p.d.f.

$$f(x; \theta) = \begin{cases} c\theta^{-c} x^{c-1} \exp(-x^c/\theta^c), & x > 0, \\ 0, & \text{其他情况,} \end{cases}$$

其中 $c > 0$ 为已知常数, $\theta > 0$ 为未知参数。样本为 $X_1, \dots, X_n$.

- 1) (6分) 试求出 θ 的极大似然估计量 $\hat{\theta}$.
 2) (6分) 试证明, $\hat{\theta}^c$ 为 θ^c 的无偏估计量。

答案:

1) 首先可以写出似然函数

$$L = c^n \theta^{-nc} \prod_{i=1}^n X_i^{c-1} \exp\left(-\frac{1}{\theta^c} \sum_{i=1}^n X_i^c\right).$$

而对数似然函数为

$$l = n \log c - nc \log \theta + (c-1) \sum_{i=1}^n \log X_i - \frac{1}{\theta^c} \sum_{i=1}^n X_i^c.$$

对 θ 求偏导, 并另其为0, 得到

$$\frac{\partial l}{\partial \theta} = -\frac{nc}{\theta} + \frac{c \sum_{i=1}^n X_i^c}{\theta^{c+1}} = 0.$$

解得MLE为

$$\hat{\theta} = \left(\frac{\sum_{i=1}^n X_i^c}{n} \right)^{1/c}.$$

2) 对于 $z > 0$, 可以计算,

$$\begin{aligned} P(X^c \leq z) &= \int_0^{z^{1/c}} c \theta^{-c} x^{c-1} \exp(-x^c/\theta^c) dx \\ &= - \int_0^{z^{1/c}} d \exp(-x^c/\theta^c) = 1 - \exp(-z/\theta^c). \end{aligned}$$

因此, $X^c \sim \text{Exp}(1/\theta^c)$. 从而 $E(X^c) = \theta^c$.

于是我们知道,

$$E(\hat{\theta}^c) = \frac{\sum_{i=1}^n E(X_i^c)}{n} = \theta^c.$$

3. (15分) 假设总体 $X \sim N(\mu, \sigma_0^2)$, 其中 σ_0 已知. 对于给定的 $\mu_0 < \mu_1$, 考虑检验问题

$$H_0: \mu = \mu_0 \quad \text{v.s.} \quad H_1: \mu = \mu_1.$$

我们考虑一系列的检验统计量 $\bar{X}_k = \sum_{i=1}^k X_i/k$, $k = 1, 2, \dots, n$.

- 1) (5分) 假设显著水平指定为 α . 对于每个 k , 采用 $\bar{X}_k$ 为检验统计量, 给出符合直观的显著水平为 α 的拒绝域。

2) (5分) 对于1)中得到的一系列拒绝域, 比较它们的功效。

3) (5分) 对于某一个 k , 若不指定显著水平, 求出拒绝域的临界值, 使得犯两类错误之和达到最小。

答案:

1) 可以知道, 拒绝域为

$$\left\{ \frac{\bar{X}_k - \mu_0}{\sigma_0/\sqrt{k}} \geq z_\alpha \right\}.$$

2) 对于某个 k , 可以计算拒绝域的功效为

$$\begin{aligned} P\left(\frac{\bar{X}_k - \mu_0}{\sigma_0/\sqrt{k}} \geq z_\alpha \mid \mu = \mu_1\right) &= P\left(\frac{\bar{X}_k - \mu_1}{\sigma_0/\sqrt{k}} \geq z_\alpha - \frac{\mu_1 - \mu_0}{\sigma_0/\sqrt{k}} \mid \mu = \mu_1\right) \\ &= 1 - \Phi\left(z_\alpha - \frac{\mu_1 - \mu_0}{\sigma_0/\sqrt{k}}\right). \end{aligned}$$

很显然, 此功效随着 k 的增加而增加。

3) 取拒绝域

$$\left\{ \frac{\bar{X}_k - \mu_0}{\sigma_0/\sqrt{k}} \geq C \right\}.$$

则两类错误之和为

$$\begin{aligned} &P\left(\frac{\bar{X}_k - \mu_0}{\sigma_0/\sqrt{k}} \geq C \mid \mu = \mu_0\right) + P\left(\frac{\bar{X}_k - \mu_0}{\sigma_0/\sqrt{k}} < C \mid \mu = \mu_1\right) \\ &= 1 - \Phi(C) + \Phi\left(C - \frac{\mu_1 - \mu_0}{\sigma_0/\sqrt{k}}\right). \end{aligned}$$

对 C 求导, 并令导数为0, 可得

$$-\phi(C) + \phi\left(C - \frac{\mu_1 - \mu_0}{\sigma_0/\sqrt{k}}\right) = 0,$$

其中 $\phi(\cdot) = \Phi'(\cdot)$ 为 $N(0, 1)$ 的p.d.f.. 根据 $\phi(\cdot)$ 的对称性可知

$$-C = C - \frac{\mu_1 - \mu_0}{\sigma_0/\sqrt{k}},$$

即

$$C = \frac{1}{2} \frac{\mu_1 - \mu_0}{\sigma_0/\sqrt{k}}.$$

此时拒绝域为

$$\left\{ \bar{X}_k \geq \frac{\mu_0 + \mu_1}{2} \right\}.$$

4. (12分) 假设中国成年人的身高服从正态分布 $N(\mu, \sigma^2)$, 其中 μ, σ 均未知。20年前中国成年人的平均身高是 $\mu_0 = 168\text{cm}$ 。我们要检验现在中国人的身高相比于20年前是不变还是有统计意义上的显著提高。现在随机抽取100人, 测得平均身高为 $\bar{x} = 170.04\text{cm}$, 样本标准差为 $s = 12.0\text{cm}$ 。

1) (6分) 请用学过的假设检验方法来推断, 在5%的显著水平下, 现在中国人身高的总体均值是否显著超过了20年前。

2) (6分) 计算1)中拒绝域的 p -值。用 p -值法判断, 当显著水平取5%时, 检验的结论应是怎样的? 如果显著水平取10%, 检验的结论应是怎样的?

答案:

1) 检验问题为

$$H_0: \mu = \mu_0 \quad \text{v.s.} \quad H_1: \mu > \mu_0.$$

采用 t -检验, 拒绝域应为

$$\left\{ \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \geq t_{0.05}(99) \right\}.$$

可以算出,

$$\frac{\bar{x} - \mu_0}{s/\sqrt{n}} = 1.7 > t_{0.05}(99) = 1.66.$$

因此应该接受 H_1 , 即认为身高有显著提高。

2) 可以知道 p -值为

$$P\left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} \geq \frac{\bar{x} - \mu_0}{s/\sqrt{n}}\right) = 1 - G(1.7).$$

根据1)中的结论, 此 p -值应该小于0.05, 因此应该接受 H_1 . 对于显著水平0.1, 也应该接受 H_1 .

5. (14分) 假设总体 $X \sim N(\mu_0, \sigma^2)$, 其中 μ_0 已知。样本为 $X_1, \dots, X_n$, 其中 n 充分大。考虑 σ^2 的五个估

计量:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$U = \frac{1}{n-1} \sum_{i=1}^n (X_i - \mu_0)^2$$

$$V = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2$$

$$W = n(\bar{X} - \mu_0)^2.$$

1) (4分) 判断其中无偏的估计量。

2) (10分) 利用均方误差 (Mse) 为准则, 将五个估计量由好到差排序。

答案:

1) 显然, S^2 , V , W 均为无偏估计量, 而 B_2 与 U 为有偏的。

2) 讲义中已经推出

$$\text{Mse}(S^2) = \frac{2\sigma^4}{n-1} > \text{Mse}(B_2) = \frac{2n-1}{n^2} \sigma^4.$$

我们知道 $nV/\sigma^2 \sim \chi^2(n)$. 因此

$$\text{Mse}(V) = \text{Var}(V) = \frac{\sigma^4}{n^2} \text{Var}(nV/\sigma^2) = \frac{\sigma^4}{n^2} \cdot 2n = \frac{2\sigma^4}{n}.$$

而 $U = nV/(n-1)$, 故 U 的偏差为 $\sigma^2/(n-1)$, 方差为

$$\text{Var}(U) = \frac{n^2}{(n-1)^2} \text{Var}(V) = \frac{2n\sigma^4}{(n-1)^2}.$$

因此

$$\text{Mse}(U) = \frac{\sigma^4}{(n-1)^2} + \frac{2n\sigma^4}{(n-1)^2} = \frac{(2n+1)\sigma^4}{(n-1)^2}.$$

又可以知道 $W/\sigma^2 \sim \chi^2(1)$. 因此

$$\text{Mse}(W) = \text{Var}(W) = \sigma^4 \text{Var}(W/\sigma^2) = 2\sigma^4.$$

经排序可知,

$$\text{Mse}(B_2) < \text{Mse}(V) < \text{Mse}(S^2) < \text{Mse}(U) < \text{Mse}(W).$$

6. (10分) 假设样本 $X_1, \dots, X_n$ 取自一个总体, 密度函数为

$$f(x; \theta) = \begin{cases} e^{-(x-\theta)}, & x > \theta, \\ 0, & x \leq \theta, \end{cases}$$

其中参数 $\theta \in (-\infty, \infty)$. 试用 $X_{(1)} = \min \{X_1, \dots, X_n\} - \theta$ 作为枢轴量, 求得一个置信水平为 $1 - \alpha$ 的最短长度置信区间。

答案:

首先, 令 $Y_i = X_i - \theta$, 则 Y_i 为 $\text{Exp}(1)$ 分布。这是因为对于任意 $y > 0$, 我们有

$$P(Y_i > y) = P(X_i > \theta + y) = e^{-y}.$$

其次 $X_{(1)} = \min_{1 \leq i \leq n} X_i - \theta = \min_{1 \leq i \leq n} Y_i$, 而其分布为 $\text{Exp}(n)$, 这是因为对于任意 $y > 0$, 我们有

$$P(\min_{1 \leq i \leq n} Y_i > y) = P(Y_1 > y, \dots, Y_n > y) = P(Y_1 > y) \cdots P(Y_n > y) = e^{-ny}.$$

$X_{(1)}$ 的密度函数为

$$g(y) = ne^{-ny}, \quad y > 0.$$

我们取 c, d 使得

$$P(c \leq X_{(1)} \leq d) = \int_c^d ne^{-ny} dy = 1 - \alpha.$$

由于 $g(y)$ 单调递减, 为使区间长度最短, 应取 $c = 0, d = -\log \alpha / n$. 因此 θ 的置信区间为

$$\left(\min_{1 \leq i \leq n} X_i + \frac{\log \alpha}{n}, \min_{1 \leq i \leq n} X_i \right).$$