

第3节-条件概率与贝叶斯公式

三、条件概率与贝叶斯公式

3.1 条件概率公式及其几何解释

3.1.1 什么是条件概率？

条件概率表示：在已知某个事件发生的前提下，另一个事件发生的概率是多少。

数学定义：

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad \text{前提：} P(B) > 0$$

含义：

$P(A|B)$ ：在 B 已经发生的前提下，A 也会发生的可能性。

- 分子 $P(A \cap B)$ ：A 和 B 同时发生的概率。
- 分母 $P(B)$ ：B 本身发生的概率。

举个例子：

- A：某人“喜欢数学”；
- B：这个人是“大学生”。

那：

$$P(A|B) = \text{在大学生中，喜欢数学的比例}$$

这就意味着我们不是在全人群中看“喜欢数学”的人有多少，而是只在“大学生”这群人里看他们中喜欢数学的比例。

3.1.2 为何是这个形式？

我们假设有一个总人群 Ω ，其总概率是 1。

- 假设我们“只保留”事件 B 发生的部分（我们 **限制了我们的观察范围**）。
- 然后在 B 的内部，看有多少是同时也满足 A 的。

于是：

- “A 且 B 同时发生”那部分就是 $A \cap B$
- “限制在 B 里看”就意味着要用 $P(B)$ 来归一化

所以最终得出：

$$P(A|B) = \frac{\text{在 B 中也发生 A 的那一部分}}{\text{整个 B 的大小}} = \frac{P(A \cap B)}{P(B)}$$

3.1.3 几何解释（集合与面积视角）

想象样本空间 Ω 是一个大圆（或长方形）：

- 事件 B：一个区域（蓝色）
- 事件 A：另一个区域（红色）

$A \cap B$ ：两者的重叠部分（紫色）

$P(A|B)$ 就是紫色区域在整个蓝色区域中所占的比例

数学上是：

$$P(A|B) = \frac{\text{紫色面积}}{\text{蓝色面积}}$$

3.1.4 再举一个例子

假设：

- 有 1000 个人
- 其中 300 人是大学生（事件 B， $P(B) = 0.3$ ）
- 在这 300 人中，有 180 人喜欢数学（事件 A）

那么：

$$P(A \cap B) = \frac{180}{1000} = 0.18$$
$$P(B) = \frac{300}{1000} = 0.3$$

所以：

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{0.18}{0.3} = 0.6$$

意思是：在大学生中，有 60% 喜欢数学。

3.1.5 乘法公式（延展公式）

从定义反推，我们可以得出：

$$P(A \cap B) = P(B) \cdot P(A|B)$$

也可以写成：

$$P(A \cap B) = P(A) \cdot P(B|A)$$

也就是，联合概率（A 和 B 同时发生的概率）= 边缘概率 × 条件概率


它在很多实际推理中非常重要，尤其是贝叶斯公式的推导。

3.1.6 概率树图解释（流程可视化）

以以下场景为例：

有 40% 的人抽烟（事件 B），其中有 10% 得肺病（事件 A）；
不抽烟的人中有 2% 得肺病。

可以画成概率树：



计算抽烟人中得肺病的概率：

$$P(\text{肺病}|\text{抽烟}) = 0.1$$

而如果要求联合概率：

$$P(\text{肺病} \cap \text{抽烟}) = 0.4 \times 0.1 = 0.04$$

3.1.7 常见误区

错误理解	正确认识
$P(A B) = P(B A)$	错，只有在 A 和 B 概率相同或对称时才相等
条件概率只在理论里有用	实际应用非常广，如医疗、推荐系统、语音识别等

条件概率是“乘出来”的	它是一个独立定义，通过交集 / 归一化得到
-------------	-----------------------

3.1.8 实际应用场景

场景	用到的条件概率
医学诊断	在病人已呈现症状的条件下，患某疾病的概率
金融欺诈检测	给定某种行为特征，属于欺诈的概率
搜索排序	在某用户点击的前提下，预测商品喜欢的概率
自然语言处理	给定上下文，预测下一个词

3.1.9 公式总结

名称	公式	含义
条件概率	$P(A B) = \frac{P(A \cap B)}{P(B)}$	在 B 已发生的前提下，A 的可能性
联合概率展开	$P(A \cap B) = P(A) \cdot P(B A) = P(B) \cdot P(A B)$	联合概率可以用条件概率展开
全概率公式	$P(A) = \sum_i P(A B_i)P(B_i)$	通过所有条件路径合成边缘概率

3.1.10 小结

模块	核心要点
定义	条件概率是“在已知事件 B 发生时，事件 A 发生的概率”
几何解释	就是在 B 区域中，A 的比例
推导基础	建立在交集和归一化的思想上
工具	可用集合图、面积、概率树等方式解释
应用场景	广泛出现在统计推断、医疗、推荐、NLP等领域

3.2 全概率公式与贝叶斯反演

3.2.1 前置知识：条件概率的定义

设 A 与 B 是两个事件，且 $P(B) > 0$ ，则：

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

这是条件概率的定义。它是“在已知事件 B 发生的前提下，事件 A 发生的概率”。

同理也有：

$$P(B | A) = \frac{P(A \cap B)}{P(A)}$$

这两者结合，构成了后续贝叶斯反演的核心。

3.2.2 全概率公式

背景：多种“原因”导致某一结果

假设一个事件 A 的发生可以由多个互斥且完备的事件引起。比如：

- 一个病人咳嗽（事件 A ），可能是由流感、过敏、哮喘等原因导致。
- 每个“原因”是一个事件 B_i ，这些事件满足：
 - 两两互不相交： $B_i \cap B_j = \emptyset$ （互斥性）
 - 并集覆盖全集： $\bigcup_i B_i = \Omega$ （完备性）

全概率公式内容

设 $B_1, B_2, \dots, B_n$ 构成一组**完备事件划分**，且 $P(B_i) > 0$ ，则对任意事件 A 有：

$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i)$$

推导过程

我们从集合的角度看，事件 A 可以被划分为若干个互不重合的子事件：

$$A = (A \cap B_1) \cup (A \cap B_2) \cup \dots \cup (A \cap B_n)$$

由于 B_i 两两互斥，上面的交集也是互斥的，所以：

$$P(A) = \sum_{i=1}^n P(A \cap B_i)$$

再根据条件概率的定义 $P(A \cap B_i) = P(A | B_i) P(B_i)$ ，得到：

$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i)$$

这就是**全概率公式**。

3.2.3 贝叶斯反演公式

背景：我们知道结果，想推测原因

贝叶斯公式的场景是：

- 我们观察到了一个结果（比如症状 A ）。
- 我们想知道这个结果最可能是由哪个原因（事件 B_i ）导致的。

这就是**反演**。

在贝叶斯公式中：

$P(B_j)$ 是**先验概率**，表示在没有观察结果 A 时，我们对原因 B_j 的信念；

$P(A | B_j)$ 是**似然**，表示若已知 B_j 发生，观察到 A 的可能性；

分母是“所有路径” 概率总和；

$P(B_j | A)$ 是**后验概率**，表示观察到 A 后对 B_j 的更新信念。

贝叶斯公式内容

设 $B_1, \dots, B_n$ 是一组互斥完备事件，且 $P(B_i) > 0, P(A) > 0$ ，那么：

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{\sum_{i=1}^n P(A | B_i)P(B_i)}$$

推导过程

我们用条件概率定义：

$$P(B_j | A) = \frac{P(B_j \cap A)}{P(A)}$$

分子可以写成：

$$P(B_j \cap A) = P(A | B_j)P(B_j)$$

分母 $P(A)$ 用全概率公式展开：

$$P(A) = \sum_{i=1}^n P(A | B_i)P(B_i)$$

于是：

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{\sum_{i=1}^n P(A | B_i)P(B_i)}$$

这就是贝叶斯公式。它将“结果已知”时，“原因的**概率**”进行反转计算。

3.2.4 实际应用举例：医学诊断

场景

疾病为 D ，检查为阳性结果 T 。

已知：

- $P(D) = 0.01$ ：有病人群占比
- $P(T | D) = 0.99$ ：有病的人检测为阳性

- $P(T | \neg D) = 0.05$ ：无病的人误判为阳性
- 求：一个人检测阳性后，实际上有病的概率 $P(D | T)$ ？

解题步骤

使用贝叶斯公式：

$$P(D | T) = \frac{P(T | D)P(D)}{P(T | D)P(D) + P(T | \neg D)P(\neg D)}$$

代入：

$$P(D | T) = \frac{0.99 \times 0.01}{0.99 \times 0.01 + 0.05 \times 0.99} = \frac{0.0099}{0.0099 + 0.0495} \approx 0.167$$

结果：只有约 16.7% 的可能性是真正得病。尽管检测是阳性！

因为本身罕见（先验概率低），即使测试准确率很高，也难以“翻转”结论。

3.2.5 结构关系小结

- **全概率公式**：从多个“原因”推出一个“结果”的总概率。
- **贝叶斯公式**：已知“结果”，反推出某个“原因”发生的可能性。
- 二者通过条件概率 $P(A \cap B) = P(A | B)P(B)$ 紧密连接。
- 在机器学习中，朴素贝叶斯分类器、EM算法等都依赖这一推理方式。

与频率派不同，贝叶斯方法不仅关注“事件是否发生”，更关心**我们对参数的信念如何随着观察数据不断更新**。

3.3 案例：朴素贝叶斯分类器

3.3.1 应用场景：文本分类、垃圾邮件过滤、情感分析等

你有一组特征 $X = (x_1, x_2, \dots, x_n)$ ，想判断它属于哪个类别 C_k 。

例如：

- 邮件文本内容（特征），判断它是否是垃圾邮件（类别）
- 一段影评中的词汇（特征），判断是否是正面评价（类别）

3.3.2 问题形式化：后验概率最大分类

我们要找：

$$\hat{C} = \arg \max_{C_k} P(C_k | x_1, x_2, \dots, x_n)$$

由贝叶斯公式：

$$P(C_k | x_1, \dots, x_n) = \frac{P(x_1, \dots, x_n | C_k)P(C_k)}{P(x_1, \dots, x_n)}$$

由于分母在不同类别下是一样的，所以我们只需要比较：

$$\hat{C} = \arg \max_{C_k} P(x_1, \dots, x_n | C_k) P(C_k)$$

3.3.3 关键假设：“朴素”独立性

朴素贝叶斯的核心是假设**所有特征在给定类别下相互独立**，即：

$$P(x_1, \dots, x_n | C_k) = \prod_{i=1}^n P(x_i | C_k)$$

这个假设简化了联合概率的计算。虽然现实中独立性不总是成立，但实际效果仍非常好。

实际中，特征之间往往不完全独立。比如在文本中，“buy”和“cheap”经常一起出现，但朴素贝叶斯仍然假设它们独立。

这种简化虽然违背事实，但在大量文本特征下，**独立性假设反而起到了正则化的作用**，避免过拟合。

3.3.4 最终形式：分类器表达式

所以朴素贝叶斯分类器实际使用的是：

$$\hat{C} = \arg \max_{C_k} P(C_k) \prod_{i=1}^n P(x_i | C_k)$$

这就是我们要实现的分类器。

3.3.5 模型训练与估计

类别概率 $P(C_k)$

用训练集中某类别样本所占比例估计：

$$P(C_k) = \frac{\text{类别为 } C_k \text{ 的样本数}}{\text{总样本数}}$$

条件概率 $P(x_i | C_k)$

对离散特征（如词汇）：

$$P(x_i = w | C_k) = \frac{\text{类别 } C_k \text{ 中包含词 } w \text{ 的文档数} + \alpha}{\text{类别 } C_k \text{ 的总文档数} + \alpha V}$$

其中 α 是拉普拉斯平滑项， V 是词表大小。

对连续特征（如温度），可以假设为高斯分布：

$$P(x_i | C_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right)$$

3.3.6 小例子：文本分类

文本	类别
"buy cheap now"	spam

"limited offer"	spam
"hello friend"	ham

我们构造词表：{buy, cheap, now, limited, offer, hello, friend}

估计：

$$P(\text{spam}) = \frac{2}{3}, P(\text{ham}) = \frac{1}{3}$$
$$P(\text{buy} \mid \text{spam}) = \frac{1+1}{6+7} = \frac{2}{13} \quad (\text{加了平滑})$$

给新文本："cheap offer now"，计算 spam 和 ham 下的概率并归一化。

3.3.7 优点与局限

- 优点：速度快，对高维稀疏数据（如文本）表现好。
- 缺点：独立性假设过于强硬；概率估计不够精准。

3.4 案例：A/B测试更新推理

3.4.1 问题背景

你正在运行一个 A/B 实验：

- A：原始页面，点击率为 θ_A
- B：新页面，点击率为 θ_B

目标：判断哪一个页面更好？即 $P(\theta_B > \theta_A \mid \text{数据})$

3.4.2 贝叶斯建模过程

步骤 1：为每个组建立参数模型

- 点击次数服从二项分布： $x_A \sim \text{Binomial}(n_A, \theta_A)$
- 给定先验： $\theta_A, \theta_B \sim \text{Beta}(\alpha, \beta)$

Beta 分布是二项分布的共轭先验，便于更新。

步骤 2：观察数据，更新后验

比如：

- A：1000人中点击 200 次
- B：1000人中点击 220 次

更新后验：

$$\theta_A \sim \text{Beta}(200 + \alpha, 800 + \beta)$$
$$\theta_B \sim \text{Beta}(220 + \alpha, 780 + \beta)$$

步骤 3：后验推断：计算 $P(\theta_B > \theta_A)$

由于无法直接解析计算，可以用蒙特卡洛模拟：

```
1  import numpy as np
2
3  # 假设先验为 Beta(1, 1)
4  alpha, beta = 1, 1
5  theta_A_samples = np.random.beta(201, 801, 10000)
6  theta_B_samples = np.random.beta(221, 781, 10000)
7
8  # 计算后验概率：B 比 A 好
9  prob_B_better = np.mean(theta_B_samples > theta_A_samples)
10 print(f"P(θ_B > θ_A) ≈ {prob_B_better:.3f}")
```

若这个概率大于 95%，我们可判断：B 很可能更优。

3.4.3 贝叶斯与频率派 A/B 测试对比

方面	频率派	贝叶斯派
输出	p-value	后验概率 $P(\theta_B > \theta_A)$
不确定性	来自假设检验	通过先验和样本量建模
灵活性	固定样本量	可以逐步更新，实时监控

3.4.4 小结

- 贝叶斯 A/B 测试更适合实时决策、动态预算控制场景
- 朴素贝叶斯分类器是贝叶斯公式在特征独立假设下的直接应用

3.5 案例：步枪中靶问题中的先验更新

3.5.1 问题背景：射击命中率未知，如何不断更新判断？

设有一名新兵，正在进行射击训练。你作为教官，不知道该士兵的真实命中率 $\theta \in [0, 1]$ ，但你可以通过其多次射击的表现，来更新对他射击能力的**主观判断**。

实际问题：

1. 射击命中与否：每次开枪，要么命中（记作 1），要么不中（记作 0）；
2. 真实命中率未知，需从数据中学习；
3. 我们需要**边观察边更新**，形成越来越精准的估计。

3.5.2 贝叶斯建模思路

我们面对的是典型的**贝叶斯参数推断问题**：

参数变量：命中率 θ

我们假设：

- 每次射击独立；
- 命中服从伯努利分布：

$$x_i \sim \text{Bernoulli}(\theta)$$

先验分布：Beta 分布建模命中率

我们对 θ 的主观初始认知用 **Beta 分布** 来表示：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

该分布的密度函数为：

$$p(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}$$

α ：成功次数（命中）信念强度；

β ：失败次数（脱靶）信念强度；

$\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}$ ：先验期望。

若 $\alpha = 1, \beta = 1$ ，代表**完全无偏好**（均匀分布）。

3.5.3 观察数据后的贝叶斯更新

假设我们观察了 n 次射击，其中有 k 次命中。

似然函数

在贝叶斯推理中，似然函数是：

$$P(D \mid \theta) = \theta^k (1 - \theta)^{n-k}$$

这是在给定命中率 θ 情况下，观察到 k 次命中、 $n - k$ 次脱靶的概率。

后验分布：先验 $\times$ 似然

根据贝叶斯公式，后验分布是：

$$p(\theta \mid D) \propto p(D \mid \theta) \cdot p(\theta)$$

代入：

$$p(\theta \mid D) \propto \theta^k (1 - \theta)^{n-k} \cdot \theta^{\alpha-1} (1 - \theta)^{\beta-1} = \theta^{\alpha+k-1} (1 - \theta)^{\beta+n-k-1}$$

这仍然是一个 Beta 分布：

$$\theta \mid D \sim \text{Beta}(\alpha + k, \beta + n - k)$$

3.5.4 每一步解释

初始认知：先验 $\text{Beta}(\alpha, \beta)$

- 你一开始对新兵的命中率没有信息，设定 $\text{Beta}(1, 1)$ ：即从 0 到 1 每个命中率都一样可能；
- 若你觉得新兵之前训练较好，可设定 $\text{Beta}(5, 2)$ ：即你“相信”他更可能命中。

收集数据：命中次数 k ，脱靶次数 $n - k$

- 比如他连续射击 10 次，命中 6 次，则 $k = 6, n = 10$ 。


更新：新的后验

- 原本是 $\text{Beta}(\alpha, \beta)$
- 新的变成 $\text{Beta}(\alpha + k, \beta + n - k)$

你可以认为 α, β 就是“虚拟的历史数据”，观察的数据不断累加到先验中，构成更“精确”的估计。

3.5.5 Python 模拟实现

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  from scipy.stats import beta
4
5  # 初始先验
6  alpha_0 = 1
7  beta_0 = 1
8
9  # 观察数据：10 次射击，命中 6 次
10 k = 6
11 n = 10
12
13 # 后验参数
14 alpha_post = alpha_0 + k
15 beta_post = beta_0 + (n - k)
16
17 # 可视化先验和后验
18 theta = np.linspace(0, 1, 500)
19 prior = beta.pdf(theta, alpha_0, beta_0)
20 posterior = beta.pdf(theta, alpha_post, beta_post)
21
22 plt.plot(theta, prior, label="Prior Beta(1,1)", linestyle='--')
23 plt.plot(theta, posterior, label=f"Posterior Beta({alpha_post},{beta_post})")
24 plt.xlabel("命中率  $\theta$ ")
25 plt.ylabel("概率密度")
26 plt.legend()
27 plt.title("步枪中靶：贝叶斯更新过程")
28 plt.grid(True)
```



3.5.6 后验的用途

你得到了 $\theta \sim \text{Beta}(7, 5)$ ，我们可以用这个后验分布来做很多事情：

点估计

- 最大后验估计 (MAP) : $\hat{\theta}_{\text{MAP}} = \frac{\alpha - 1}{\alpha + \beta - 2}$
- 后验期望: $\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta} = \frac{7}{12} \approx 0.583$

区间估计

求出 95% 置信区间：

```
1 ci_lower, ci_upper = beta.ppf([0.025, 0.975], alpha_post, beta_post)
2 print(f"95%置信区间为 [{ci_lower:.3f}, {ci_upper:.3f}]")
```

决策支持

- 若你要决定是否让该士兵参加实战任务，你可以判断其后验期望是否大于某个标准值（如 60% 命中率）；
- 你也可以预测其下一次命中概率（后验预测分布）：

$$P(\text{命中}) = \mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}$$

3.5.7 总结

概念	含义
θ	命中率参数（我们要估计的）
先验 Beta(α, β)	初始主观信念
数据 $x_1, \dots, x_n$	实际射击结果
后验 Beta($\alpha + k, \beta + n - k$)	更新后的信念
后验均值 $\frac{\alpha + k}{\alpha + \beta + n}$	命中率估计
后验分布	用来判断能力、支持决策、给出置信区间