

第4节-常见概率分布

四、常见概率分布

4.1 离散分布：Bernoulli、Binomial、Poisson

4.1.1 Bernoulli 分布（伯努利分布）

伯努利分布用于建模一个只有两种可能结果的随机事件，比如：

- 投一次硬币（正面/反面）
- 一个用户是否点击广告（点击/不点击）
- 某个实验是否成功（成功/失败）

设随机变量 X 表示这类事件：

$$X \sim \text{Bernoulli}(p)$$

其中：

$X \in 0, 1$ ，1 代表“成功”，0 代表“失败”

$p = P(X = 1)$ 是事件成功的概率

$1 - p = P(X = 0)$ 是失败的概率

概率质量函数（PMF）

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}$$

直观解释：

- 当 $x = 1$: $P(X = 1) = p$
- 当 $x = 0$: $P(X = 0) = 1 - p$

数学性质

- 期望: $E[X] = p$
- 方差: $\text{Var}(X) = p(1 - p)$

示例应用

- 是否中奖（中或不中）
- 二分类模型（是/否，病/非病）

Python 模拟

```

1  from scipy.stats import bernoulli
2  import matplotlib.pyplot as plt
3
4  p = 0.3
5  x = [0, 1]
6  probs = bernoulli.pmf(x, p)
7
8  plt.bar(x, probs, tick_label=["失败(0)", "成功(1)"])
9  plt.title("Bernoulli 分布 (p=0.3)")
10 plt.ylabel("概率")
11 plt.show()

```

4.1.2 Binomial 分布（二项分布）

Binomial 分布是 n 次独立的伯努利试验中成功的次数总和。

记：

$$X \sim \text{Binomial}(n, p)$$

含义：

- 进行 n 次独立的伯努利试验（每次成功概率为 p ）

X 是总共成功的次数（ $0 \leq X \leq n$ ）

概率质量函数

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n$$

解释：

$\binom{n}{k}$ ：在 n 次试验中选出 k 次成功的方法数

p^k : 这 k 次成功的概率

$(1 - p)^{n-k}$: 剩下 $n - k$ 次失败的概率

数学性质

- 期望: $E[X] = np$
- 方差: $\text{Var}(X) = np(1 - p)$

应用场景

- 抛 10 枚硬币, 看正面出现几次
- 某广告展示 100 次, 点击了几次
- 工厂每批产品中有几个次品

Python 模拟

```
1  from scipy.stats import binom
2  import numpy as np
3
4  n = 10
5  p = 0.3
6  x = np.arange(0, n+1)
7  probs = binom.pmf(x, n, p)
8
9  plt.bar(x, probs)
10 plt.title("Binomial 分布 (n=10, p=0.3)")
11 plt.xlabel("成功次数 k")
12 plt.ylabel("概率")
13 plt.grid(True)
14 plt.show()
```

4.1.3 Poisson 分布（泊松分布）

泊松分布用于建模单位时间或单位空间内, 某事件发生的次数, 这些事件是稀疏的、独立的, 如:

- 1 小时内顾客到达数
- 1 平方米土地中的植物数量
- 一天内网页的点击次数

设随机变量 X 表示单位时间内的事件发生次数:

$$X \sim \text{Poisson}(\lambda)$$

其中:

$\lambda > 0$ 是单位时间内事件发生的平均次数

概率质量函数

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

解释：

$\lambda^k / k!$ 是“精确发生 k 次”的组合权重

$e^{-\lambda}$ 保证所有概率加起来为 1

数学性质

- 期望： $E[X] = \lambda$
- 方差： $\text{Var}(X) = \lambda$

应用场景

- 某网站每天收到的请求数
- 医院每小时急诊人数
- 电话呼叫中心每分钟的呼叫量

与 Binomial 的关系

限制条件 “ $n \rightarrow \infty$ ， $p \rightarrow 0$ ，且 $np = \lambda$ 固定”，“ p 不能太大”，则：

$$\text{Binomial}(n, p) \approx \text{Poisson}(\lambda)$$

这是泊松近似二项的来源，泊松分布适合建模“稀有事件”的计数，它是 Binomial 的极限形式。

Python 模拟

```
1  from scipy.stats import poisson
2
3  λ = 4
4  x = np.arange(0, 15)
5  probs = poisson.pmf(x, λ)
6
7  plt.bar(x, probs)
8  plt.title("Poisson 分布 (λ=4)")
9  plt.xlabel("事件次数 k")
10 plt.ylabel("概率")
11 plt.grid(True)
12 plt.show()
```

4.1.4 对比表

分布	参数	含义	变量取值	应用示例

Bernoulli	p	成功概率	0, 1	投一次硬币
Binomial	n, p	n 次伯努利试验	0 到 n	抛 n 次硬币
Poisson	λ	单位时间平均次数	非负整数 (0, 1, 2, ...)	某时段内点击数

4.2 应用：异常检测

4.2.1 目标概述

异常检测的目标是：在数据中找出“不符合常规”的点，例如：

- 某天的网页点击数**异常高或异常低**；
- 一台机器的故障次数远高于正常范围；
- 某人行为明显偏离过往模式。

这种任务核心是：**如何判断某个观测值“异常”**？

4.2.2 为什么用离散分布进行异常检测？

现实中很多事件都是**计数型的**，也就是说，它们：

- **只能取整数值**（比如点击次数、电话数、事故数）；
- **往往发生次数不大**（稀疏数据）；
- **随时间/空间而变化**（按天、按区域）；

对于这些场景，使用**Poisson、Binomial、Bernoulli 分布**建模是非常合适的。

4.2.3 逐一分析如何利用这些分布进行异常检测

1. Bernoulli 分布：单次行为是否异常

场景：是否点击广告？

- 对于每一个用户，当他看到广告时，我们可以记录他是否点击（1）或不点击（0）；
- 这种行为属于**二值行为**，可用 **Bernoulli 分布建模**；
- 若某用户点击率远高于平均水平，我们可以认为“他不正常”（可能是刷量）。

建模方法：

1. 收集大量用户的平均点击率 p ；
2. 对新用户点击行为建模为 $X \sim \text{Bernoulli}(p)$ ；
3. 如果观测值远离 p （如连续10次点击），可判断为异常。

Python 示例：

```

1  from scipy.stats import bernoulli
2
3  p = 0.05  # 平均点击率
4  obs = 1   # 观察到点击
5
6  prob = bernoulli.pmf(obs, p)
7  print(f"用户点击的概率为: {prob:.5f}")
8
9  if prob < 0.001:
10     print("→ 这是一个异常点击行为")

```

2. Binomial 分布：在 n 次中是否“太多”成功

场景：点击广告 100 次中点击了 20 次，正常吗？

- 每次点击是一次 Bernoulli 试验；
- 总共 n 次尝试中成功 k 次 $\rightarrow$ Binomial 分布；
- 可计算这个事件的概率： $P(X \geq 20)$ 如果非常小，就认为**异常活跃**。

建模步骤：

1. 模型： $X \sim \text{Binomial}(n = 100, p = 0.05)$ ；
2. 观测到： $k = 20$ ；
3. 计算尾部概率 $P(X \geq 20)$ ；
4. 若概率过小（如 < 0.01 ），说明这个用户很可能不“正常”。

Python 示例：

```

1  from scipy.stats import binom
2
3  n = 100
4  p = 0.05
5  k_obs = 20
6
7  # 计算右尾概率
8  p_value = 1 - binom.cdf(k_obs - 1, n, p)
9  print(f"P(X ≥ {k_obs}) = {p_value:.5f}")
10
11 if p_value < 0.01:
12     print("→ 异常点击行为")

```

3. Poisson 分布：单位时间内异常多事件

场景：某网站一小时内收到 35 次访问，正常吗？

- 正常访问次数为 $\lambda = 10$;
- 可以用泊松分布建模事件发生的“平均频率” ;
- 如果我们观测到 $X = 35$, 但 $P(X = 35)$ 非常小 $\rightarrow$ 是异常。

建模方法:

1. 建模: $X \sim \text{Poisson}(\lambda = 10)$;
2. 观测值: $k = 35$;
3. 计算尾部概率: $P(X \geq 35)$;
4. 若远小于 0.01, 认为异常。

Python 示例:

```

1  from scipy.stats import poisson
2
3  λ = 10
4  k_obs = 35
5
6  # 计算右尾概率
7  p_value = 1 - poisson.cdf(k_obs - 1, λ)
8  print(f"P(X ≥ {k_obs}) = {p_value:.8f}")
9
10 if p_value < 0.001:
11     print("→ 异常访问行为")

```

4.2.4 如何设定“异常”的阈值?

通常有以下几种方式:

- **固定阈值法**: 比如设定显著性水平 $\alpha = 0.01$, 即 1% 的尾部概率为异常;
- **经验法**: 观测历史数据, 计算 95% 分位数作为上界;
- **Z-score 方法** (近似): 若满足中心极限定理, 可以近似用正态分布计算。

4.2.5 异常检测流程总结

输入: n 次观测数据 (点击数、请求数等)

↓

模型选择:

- Bernoulli (0/1 事件)
- Binomial (n 次中的 k 次成功)
- Poisson (单位时间内计数)

↓

计算概率： $P(X = k)$ 或 $P(X \geq k)$

↓

判断：

- 若 P 值非常小（如 < 0.01 ），则判为异常

其中， $P(X \geq k)$ ：“右尾概率”代表“事件比这个观测值还极端的可能性”。

4.2.6 真实场景应用举例

场景	分布	异常含义
网站广告点击行为	Bernoulli / Binomial	异常点击（刷量）
某服务每分钟请求数	Poisson	攻击、暴涨流量
设备错误日志频率	Poisson	机器即将故障
医疗检测阳性率	Binomial	某区域疾病异常爆发

4.2.7 小结对比：分布的适配性

分布	是否支持 n 次观测	是否用于稀疏事件	是否能表达“频率”
Bernoulli	单次	否	是
Binomial	是（固定 n ）	否	是
Poisson	是（平均频率）	是	是

4.3 连续分布：Uniform、Exponential、Gaussian

4.3.1 Uniform 分布（均匀分布）

连续均匀分布 表示某个区间内的所有值出现的概率“相等”，没有偏好，代表对所有可能性完全无信息。

均匀分布是“最没有偏好”的分布，代表对所有可能性完全无信息。

如果随机变量 X 在区间 $[a, b]$ 内服从均匀分布，记作：

$$X \sim \text{Uniform}(a, b)$$

其概率密度函数（PDF）为：

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{otherwise} \end{cases}$$

面积解释

整个区间 $[a, b]$ 上的面积必须为 1:

$$\int_a^b \frac{1}{b-a} dx = \frac{1}{b-a} (b-a) = 1$$

累积分布函数 (CDF)

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$$

期望与方差

- 期望 (均值):

$$\mathbb{E}[X] = \frac{a+b}{2}$$

- 方差:

$$\text{Var}(X) = \frac{(b-a)^2}{12}$$

4.3.2 Exponential 分布 (指数分布)

指数分布用来描述 **事件发生之间的时间间隔**。如顾客到达时间、服务器请求响应间隔。

若随机变量 T 服从参数为 $\lambda > 0$ 的指数分布, 记作:

$$T \sim \text{Exponential}(\lambda)$$

其中:

λ : 事件的发生率 (单位时间内事件发生的**平均次数**)

- 单位通常是「次/分钟」、「次/小时」

指数分布的概率密度函数 (PDF) 定义如下:

$$f(t) = \begin{cases} \lambda e^{-\lambda t}, & t \geq 0 \\ 0, & t < 0 \end{cases}$$

为什么是这个形式?

我们希望满足两个条件:

1. **非负**: 时间不能为负, 所以定义域是 $t \geq 0$
2. **越久越不可能**: 等待时间越长, 该事件还没发生的可能性应该越小 - 这就是**指数衰减**

因此使用 $e^{-\lambda t}$ 来描述: 时间越长, 概率密度越低。

然后乘以 λ ，是为了保证总面积为 1（概率总和为 1）。

面积验证

验证 $f(t)$ 是一个有效的概率密度函数，需满足：

$$\int_0^{\infty} f(t) dt = 1$$

带入 PDF：

$$\int_0^{\infty} \lambda e^{-\lambda t} dt = \lambda \int_0^{\infty} e^{-\lambda t} dt$$

$$\begin{aligned} \text{令 } u = \lambda t, \text{ 则 } du = \lambda dt \Rightarrow dt &= \frac{du}{\lambda} \\ &= \lambda \int_0^{\infty} e^{-u} \cdot \frac{1}{\lambda} du = \int_0^{\infty} e^{-u} du = [-e^{-u}]_0^{\infty} = 1 \end{aligned}$$

所以， $f(t)$ 是一个有效的 PDF。

CDF 表示在时间 t 之前事件已经发生的概率：

$$F(t) = P(T \leq t) = \int_0^t \lambda e^{-\lambda x} dx$$

我们来积分：

$$\int_0^t \lambda e^{-\lambda x} dx = [-e^{-\lambda x}]_0^t = -(e^{-\lambda t} - 1) = 1 - e^{-\lambda t}$$

所以：

$$F(t) = 1 - e^{-\lambda t}$$

表示时间 t 之后事件还没有发生的概率：

$$S(t) = P(T > t) = 1 - F(t) = e^{-\lambda t}$$

特点：无记忆性，这是指数分布的最大特色：

$$P(T > s + t \mid T > s) = P(T > t)$$

这意味着：如果你已经等了 s 时间还没发生，下次等多久和过去等了多久没有关系。

左边是条件概率：

$$P(T > s + t \mid T > s) = \frac{P(T > s + t)}{P(T > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(T > t)$$

所以无记忆性成立！

$$P(T > s + t \mid T > s) = P(T > t)$$



意思是：过去发生了什么，不影响未来的剩余时间。

Python实现：指数分布的 PDF 和 CDF

```

1  import numpy as np
2  import matplotlib.pyplot as plt
3  from scipy.stats import expon
4
5   $\lambda = 1.5$  # 事件发生率
6  t = np.linspace(0, 5, 500)
7
8  # PDF 和 CDF
9  pdf = expon.pdf(t, scale=1/ $\lambda$ ) # 注意 scale 是 1/ $\lambda$ 
10 cdf = expon.cdf(t, scale=1/ $\lambda$ )
11
12 # 可视化
13 plt.figure(figsize=(12, 5))
14
15 plt.subplot(1, 2, 1)
16 plt.plot(t, pdf, label='PDF:  $\lambda=1.5$ ')
17 plt.title('Exponential PDF')
18 plt.xlabel('t')
19 plt.ylabel('f(t)')
20 plt.grid(True)
21 plt.legend()
22
23 plt.subplot(1, 2, 2)
24 plt.plot(t, cdf, color='orange', label='CDF:  $\lambda=1.5$ ')
25 plt.title('Exponential CDF')
26 plt.xlabel('t')
27 plt.ylabel('F(t)')
28 plt.grid(True)
29 plt.legend()
30
31 plt.tight_layout()
32 plt.show()

```



期望与方差

- 期望:

$$\mathbb{E}[T] = \int_0^{\infty} t \lambda e^{-\lambda t} dt = \frac{1}{\lambda}$$

- 方差:

$$\text{Var}(T) = \frac{1}{\lambda^2}$$

4.3.3 Gaussian 分布（正态分布）

正态分布，又称 **高斯分布**，是最重要的概率分布之一，适用于自然界大多数噪声和误差。

若随机变量 X 服从均值为 μ ，方差为 σ^2 的正态分布，记作：

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

其概率密度函数为：

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

特征图像

- 对称钟型曲线，以 μ 为中心；
- 68% 的值落在 $[\mu - \sigma, \mu + \sigma]$ 内；
- 曲线下面积为 1。

期望与方差

- 期望:

$$\mathbb{E}[X] = \mu$$

- 方差:

$$\text{Var}(X) = \sigma^2$$

标准正态分布

若 $\mu = 0, \sigma^2 = 1$ ，则 $X \sim \mathcal{N}(0, 1)$ ，其 PDF 简化为：

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

标准化操作：

$$Z = \frac{X - \mu}{\sigma} \Rightarrow Z \sim \mathcal{N}(0, 1)$$

这在机器学习的特征归一化中至关重要。

4.3.4 高阶性质比较表格

分布类型	支持区间	参数	期望	方差	特点
Uniform	$[a, b]$	a, b	$\frac{a + b}{2}$	$\frac{(b - a)^2}{12}$	概率均匀分布； 建模无偏先验或初始化
Exponential	$[0, \infty)$	λ	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	描述等待时间； 无记忆性； Poisson 过程间隔
Gaussian	$(-\infty, \infty)$	μ, σ^2	μ	σ^2	中心极限定理核心； 误差建模； 形状对称

4.3.5 应用小结

场景	常用分布	理由说明
传感器初始化误差	Gaussian	测量误差常为正态分布
数据归一化	Gaussian	使用标准正态进行中心化与标准化
网络初始化	Uniform	初始化权重以打破对称性
客户点击等待时间	Exponential	满足无记忆性假设
随机森林中阈值选取	Uniform	随机划分候选特征区间
MCMC 中的采样（Metropolis）	Gaussian / Uniform	为候选状态生成扰动

4.4 应用：生命周期建模、特征归一化

4.4.1 生命周期建模

什么是生命周期建模？

生命周期建模（又叫“生存分析”或“存续建模”）用于分析一个对象从“诞生”到“终止”的时间，比如：

- 用户在平台上的活跃时间（粘性分析）
- 产品使用寿命（设备维护）
- 广告点击后转化所需时间（营销漏斗建模）
- 客户离网（churn）时间预测

目标是构造某种概率分布来**建模事件发生的时间**。

使用指数分布建模“事件时间”

在生命周期建模中，**最常见的基础分布**是指数分布，因为它具有：

- 简洁的形式
- 记忆无关性（未来和过去无关）
- 能捕捉“时间间隔”的结构

指数分布形式：

$$f(t; \lambda) = \lambda e^{-\lambda t}, \quad t \geq 0$$

$\lambda > 0$ ：单位时间内事件发生的概率（风险率、故障率）

t ：事件（如用户流失）在时间 t 发生

生存函数和危险函数

生命周期建模中，两个核心函数：

生存函数：

$$S(t) = P(T > t) = \int_t^{\infty} f(u) du$$

表示：**对象在时间 t 之后仍然“活着”的概率**

对于指数分布：

$$S(t) = \int_t^{\infty} \lambda e^{-\lambda u} du = e^{-\lambda t}$$

危险函数：

$$h(t) = \frac{f(t)}{S(t)} = \frac{\lambda e^{-\lambda t}}{e^{-\lambda t}} = \lambda$$

恒定的危险率说明**无记忆性**：过去不影响未来。

最大似然估计的推导（含删失）

如果我们观察 n 个用户的“存活时间”，设数据为 t_i ：

$$\mathcal{L}(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda t_i} \Rightarrow \log \mathcal{L}(\lambda) = n \log \lambda - \lambda \sum t_i$$

最大化后得到：

$$\hat{\lambda} = \frac{1}{\bar{t}}$$

如果部分数据被“删失”（right-censored），即有些用户在观察期间未离开，加入删失指示变量 δ_i ：

$$\log \mathcal{L}(\lambda) = \sum_{i=1}^n [\delta_i \log \lambda - \lambda t_i] \Rightarrow \hat{\lambda} = \frac{\sum \delta_i}{\sum t_i}$$

生命周期建模的扩展：Weibull分布

指数分布的危险率是恒定的。但现实中：

- 某些设备用得越久越容易坏（风险增加）
- 某些新用户越早流失越容易流失（风险下降）

用 Weibull 分布建模更灵活：

$$f(t) = \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1} e^{-(t/\lambda)^k}, \text{ 定义域: } t \geq 0$$

$k > 1$ ：危险率随时间上升

$k < 1$ ：危险率下降

$k = 1$ ：退化为指数分布

应用案例：用户粘性分析

假设我们通过平台日志统计了用户的活跃时长（单位天）：

用户编号	活跃天数 t_i	是否流失 δ_i
U1	3	1
U2	5	1
U3	6	0
U4	2	1
U5	6	0

最大似然估计（含删失）：

$$\hat{\lambda} = \frac{\sum \delta_i}{\sum t_i} = \frac{3}{22} \approx 0.136 \Rightarrow \text{平均寿命} = \frac{1}{\hat{\lambda}} \approx 7.35\text{天}$$

4.4.2 特征归一化

为什么需要归一化？

在机器学习中，不同特征的取值尺度差异可能会：

- 影响梯度更新速度（尤其是深度学习）
- 让距离计算（如 KNN, SVM）失真
- 导致模型偏向某些“数值大”的特征

示例：

- 特征 A：年龄 $\in [0, 100]$

- 特征 B：点击率 $\in [0, 1]$

如果直接用欧氏距离计算，会被年龄主导。

常见归一化方法及其分布假设

Min-Max 归一化（适合 Uniform 假设）

假设特征近似服从均匀分布，可使用：

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \in [0, 1]$$

适用于树模型、可视化任务等。

Z-Score 标准化（适合 Gaussian 假设）

假设特征服从高斯分布：

$$x' = \frac{x - \mu}{\sigma} \Rightarrow \text{标准化后均值为0，方差为1}$$

广泛用于：

- 线性模型
- SVM、逻辑回归
- 神经网络（BatchNorm）

Log变换（适合 Exponential 或 Heavy-tail 分布）

对于正偏态、指数增长的数据（如访问量、收入）：

$$x' = \log(x + \epsilon)$$

可以使其更接近对称或高斯形态。

示例应用：CTR 特征标准化

点击率（Click-through rate）本质上是概率：

- 范围在 $(0, 1)$ ，通常服从偏态（Exponential-like）分布
- 大量样本集中在 < 0.1 之间

适合使用 **log 变换** 或 **分位数归一化**：

$$x' = \log(x + \epsilon), \quad \text{或} \quad x' = \Phi^{-1}(F_n(x))$$

其中 Φ^{-1} 是标准正态逆函数， F_n 是经验分布函数。

4.4.3 对比

场景	分布假设	模型	归一化方法
生命周期	Exponential / Weibull	生存分析	$\hat{\lambda} = \frac{1}{t}$
		16	

年龄、分数等特征	Gaussian	SVM / LR	Z-Score
CTR / 收入等	Exponential-like	GBDT / 神经网络	log 变换、分位归一化
图像灰度	Uniform	CNN	Min-Max