中金公司基于 Loop Engineering 的自动化因子发现引擎

组员姓名及学号：不告诉你

课程名称：《金融科技导论》期中作业

摘要

因子挖掘是量化投资的核心环节，传统上高度依赖研究员手工提出假设、编写代码、回测验证，存在效率低、易同质化、易过拟合等痛点。2026 年 3 月以来，以 Karpathy 的 autoresearch 和微软 RD-Agent 为代表的”Auto-Research” 范式兴起，证明智能体可以自主完成” 提出假设—执行实验—反馈迭代” 的科研闭环。本文以中金公司研究部 2026 年 8 月发布的” 基于 Loop Engineering 的自动化因子发现引擎” 为案例，按” 背景与业务场景—原有业务痛点—金融科技解决方案—应用效果与创新价值—风险分析” 五个部分展开。该系统在 3 天无人值守运行中完成 581 轮迭代、测试 16,939 个候选因子，最终保留 69 个独立因子；Top 5 因子等权复合年化超额收益 18.3%，夏普比率 3.14，全程零人工干预。研究表明，因子挖掘的流程性工作已具备智能体自动化可行性，但” 自动化发现” 与” 自动化可信” 之间仍需质量闸门与经济学含义审查来弥合。

关键词：金融科技；量化投资；因子挖掘；大语言模型；智能体；Loop Engineering

一、背景与业务场景

（一）案例概况

本案例研究对象为中金公司（CICC）研究部于 2026 年 8 月 3 日发布的《大模型系列（7）：基于 Loop Engineering 的自动化因子发现引擎》（郑文才、周萧潇、刘均伟）[1]。该应用属于量化投资业务中的**因子挖掘环节**（投资研究的上游），服务于 A 股多因子选股体系，目标是用大模型智能体替代研究员完成价量因子的自动化发现、筛选与入库。

（二）行业背景之一：Auto-Research——因子挖掘能否依靠智能体自动化？

这一问题在 2026 年初得到了标志性回答。2026 年 3 月，OpenAI 创始成员、特斯拉前 AI 总监 Andrej Karpathy 开源了 autoresearch 项目：给 AI 智能体一个真实的 LLM 训练环境和三个核心文件（只读的评估脚本 prepare.py、可被智能体修改的训练脚本 train.py、人类编写的指令文件 program.md），智能体即可彻夜自主循环” 改代码 → 跑 5 分钟实验

→ 看指标 → 保留或丢弃”，人类不再触碰底层代码，只需编写” 研究组织代码”[2][3]。实测中，智能体两天内自主完成 276 次实验、筛出 29 项有效改进，将模型训练效率提升约 11%，全程零人工干预，项目上线数天即获数万 GitHub 星标 [3]。这一” 人类定策略、AI 做执行” 的闭环范式，与量化因子挖掘” 提出假设—回测—筛选” 的流程高度同构，直接启发了金融场景的智能体化改造。

在金融垂直领域，最具代表性的是**微软亚洲研究院开源的 RD-Agent**。其方法论由” 研究（R）” 与” 开发（D）” 两类智能体构成，把每轮因子研究抽象为” 假设生成 → 任务分解 → 代码实现 → 执行回测 → 反馈生成” 五步循环；代码实现引擎 CoSTEER 支持最多 10 轮” 写代码—测试—修正” 自动调试，并以微软 Qlib 作为量化基础设施底座负责数据与回测 [4]。其量化分支 RD-Agent-Quant 被 NeurIPS 2025 收录，公开实测以约 10 美元/轮的运行成本实现相对基线约 2 倍的年化收益提升 [4]。国联民生证券 2026 年 5 月的实测报告进一步验证：RD-Agent 预估有效因子产出约 900 个/月，效率可达人工的数十倍，但运行稳定性、LLM 代码质量、IC 优化目标与实盘收益脱钩等问题仍使其只能定位为” 辅助因子研究工具”，候选因子最终入库仍需研究员把关 [5]。

结论：因子挖掘的流程性工作（假设、回测、筛选、记录）具备智能体自动化的可行性，但” 自动化发现” 与” 自动化可信” 之间仍有鸿沟——质量闸门与经济学含义审查成为落地的关键。中金方案的切入点正是这一鸿沟 [1]。

（三）行业背景之二：因子挖掘智能体在各金融机构中的使用

智能体化因子挖掘已成为 2025—2026 年金融机构的普遍实践，呈现三类路径：

1. 开源框架与平台生态。微软 RD-Agent 之外，开源社区已演化出 AlphaAgent（2025 年 2 月，Idea/Factor/Eval 三 Agent 架构，关注因子差异性与样本外稳定性）、QuantaAlpha（2026 年 2 月，借鉴遗传规划并在 RD-Agent 流程上加入演化控制器）等框架，开源证券在专题报告中对三者进行了系统对比 [6]。国际上，WorldQuant 的 BRAIN 平台以” 众包 + 平台化回测” 模式让全球开发者提交 Alpha 表达式，开创了因子生产的平台化先河 [7]。

2. 券商金工：从遗传规划到 LLM 智能体。华泰证券早在 2021 年即构建” 遗传规划自动挖掘因子 + 机器学习合成” 的全流程 AI 选股体系，合成因子 RankIC 均值 8.87%，叠加传统模型后中证 500 增强组合年化超额平均提升 1.38%[8]。2026 年以来，国联民生、开源证券等密集发布 RD-Agent 实测与 AI 赋能投研系列报告 [5][6]；截至 2026 年 6 月，国泰海通、华泰、中信建投、中金、广发、银河、国信等多家券商已上线覆盖” 因子分析” 等场景的金融 Skills，券商 AI 竞争从” 谁有大模型” 转向” 谁有可调用的专业能力”[9]。中金自身除本案例外，还于 2026 年 7 月发布了基于多智能体辩论（Multi-Agent Debate）的基本面因子挖掘框架，模拟” 提出假设—同行质疑—修正方案” 的研究流程 [10]。

3. 量化私募的算力与数据路线。幻方、九坤等头部私募长期投入 AI 算力平台（幻方” 萤火二号” 投入约 10 亿元、万张 A100），从另类数据中提取信号，其因子生产更依赖” 算力 + 深度学习”，与券商”LLM 智能体 + 可解释表达式” 的路线形成互补。

二、原有业务痛点

在应用该引擎之前，因子挖掘业务存在四个典型痛点：

1. 效率瓶颈与人力成本高。量化研究包含大量流程性工作：提出假设、执行回测、筛选审查。研究员日常” 洗数据、对特征、调代码” 等杂活占用约八成时间，真正用于策略思考不足两成 [3]；单人月产因子规模有限，且优秀因子的发现与个人知识结构强相关，难以系统化复用 [1]。

2. 传统自动化方法质量缺陷明显。遗传规划、暴力搜索等算法虽能批量生成因子，但只优化单一 IC 等指标，极易产出无经济学含义的” 统计巧合” 因子，过拟合风险高（Goodhart 定律）；且每轮搜索相互独立，无状态传递、无失败学习，历史试错经验被白白浪费 [1][6]。

3. 搜索同质化。缺乏多样性约束的搜索会迅速收敛到少数” 富矿” 结构上，因子库高度冗余，IC 相关性居高不下，难以构建分散化的可用因子库 [1]。

4. 质量评判维度单一。传统筛选只看 IC 等单维指标，无法同时兼顾统计显著性、年度稳定性、风险调整收益、近期持续性与因子独立性，导致入选因子样本外衰减快 [1]。

三、金融科技解决方案及改变

中金将整套流程封装为基于大模型 Loop 机制的自动化价量因子发现系统。其核心理念来自 Anthropic Claude Code 团队提出的 Loop Engineering 范式：不再追求把单句提示词写得更好，而是把一次性交互改造为” 触发—执行—校验—记录” 的自动化闭环，由定时调度驱动模型持续迭代、硬性校验把控产出质量、状态文件在轮次之间传递进度 [1]。

（1）” 生成—审查—验证” 三步闭环。生成环节由五种演化策略供给候选：变异 25%、交叉 25%、参数扰动 15%、随机探索 15%、LLM 机制引导 20%；审查环节先经四道规则过滤，再抽样交由 LLM 子代理精判边界条件；验证环节在硬编码回测引擎上以 5 日换仓（单边千一成本）计算 Spearman 秩 IC，通过 11 项联合过滤（|IC|>0.03、2025 及 2026 年超额 >0、夏普 >0.5、Calmar>1.0、IC 相关性 <0.70 等）后入库并更新检查点。每 5 分钟由定时任务触发一轮，检查点文件保证任意中断后可断点续跑 [1]。

（2）五项机制改造如何解决痛点。其一，LLM 机制引导生成（占预算 20%）让大模型按 13 个机制族提出自然语言假设，评判因子的经济学含义，避免无意义统计因子，解决痛点 2；其二，11 项联合过滤与多维评分替代单一 IC 指标，并允许自定义优化方向，解决痛点 4；其三，FSA（频繁子树规避）定期抽象因子结构，使用超过 15% 阈值

的骨架被禁止复用，配合失败模式库，强制搜索向新方向扩展，抑制同质化，解决痛点 3；其四，Skill 模块化将算子、字段、回测参数固化为可复用模块，扩展至另类数据、高频数据只需修改 Skill 文件；其五，生成与审查由独立子代理（Sub-agents）执行，与硬编码验证端隔离，降低单一模型” 自我说服” 风险 [1]。整套系统无人值守运行，直接缓解痛点 1。

四、应用效果与创新价值

1. 效率的规模化验证。系统从零因子冷启动，3 天无人值守运行 581 轮迭代，累计测试 16,939 个候选因子，保留 21 大类 69 个独立因子，成功率 0.41%[1]。同等体量的人工挖掘通常需要数月，效率提升达数量级。

2. 搜索过程呈现三次自动自适应转向。冷启动期系统自动识别” 富矿”（跳空溢价类骨架）并加大开采；450 轮后 FSA 触发冻结，搜索自动向影线、振幅、价格结构等新信号源扩散——三次转向均无需人工设定规则 [1]。

3. 因子质量与收益表现。最终因子平均超额夏普 1.60，2025 年以来平均年化超额 11.7%，平均 IC 绝对值 5.0%，因子间 IC 相关性均低于 0.70，可解释性强（如” 振幅扩张与跳空溢价” 因子刻画隔夜溢价的” 有质高开”）。Top 5 因子等权复合后 IC 达 0.081，**年化超额收益 18.3%（费后），夏普比率 3.14，优于任一单因子**，且在风格切换年份通过分散个体噪声进一步降低波动 [1]。

4. 行业创新价值。该案例证明了三点：Loop 机制（检查点持久化 + 失败学习 + 动态预算）使搜索效率随迭代累积提升，区别于简单的 for 循环调用 LLM；硬编码验证闸门 +LLM 精判的” 人机分工” 架构为金融机构提供了可复制的合规友好范式；工程化闭环让单个研究员拥有” 自动化因子工厂”，行业竞争要素从人力规模转向闭环系统的设计水平 [1][6]。

五、风险分析

1. 模型与过拟合风险（最突出）。回测数据仅覆盖 2024 年初至 2026 年 7 月约 600 个交易日，且联合过滤条件直接以 2025、2026 年分段收益为门槛，存在对测试区间隐式过拟合的风险；样本外收益无法保证。搜索时间仅 3 天，FSA 冻结后新方向因子夏普均值（0.92）显著低于核心家族（1.68），系统尚未在替代信号源上建立同等质量。中金在报告风险提示中也明确承认上述局限 [1]。

2. 信号源集中与数据维度天花板。69 个因子中 overnight 字段出现率 85%，趋势动量、反转等 8 个机制方向仍在探索初期；数据限于日频价量，未引入基本面与另类数据，搜索空间受限于输入维度 [1]。

3. 算法与运行风险。大模型产出具有随机性；LLM 可能生成边界条件有误的表达式，虽有抽样精判但仍非完备验证；无人值守循环存在死循环、状态膨胀等工程风险，需检查点与硬闸门兜底 [1][5]。

4. 数据安全与合规。行情数据与因子库属于机构核心资产，智能体接入外部 LLM API 可能带来数据泄露风险，需要私有化部署与审计日志；若相关因子用于资管产品，还需关注因子来源的可解释性披露与模型风险管理。目前业界的应对方式是" 自动化发现 + 人工入库把关"，即在制度层面保留人类最终决策权 [5]，该方案的风险缓释总体充分但依赖流程执行，建议补充强制样本外验证期与跨期相关性控制。

参考文献

[1] 中金公司研究部. 大模型系列（7）：基于 Loop Engineering 的自动化因子发现引擎 [R]. 郑文才, 周萧潇, 刘均伟, 2026-08-03.

[2] Karpathy A. autoresearch: AI agents running research on single-GPU nanochat training automatically[EB/OL]. GitHub, 2026-03. `https://github.com/karpathy/autoresearch`.

[3] InfoQ. 两天推翻 Karpathy 20 年工作习惯！百行代码开源项目" 封神"[EB/OL]. 2026-03-17.

[4] Microsoft Research Asia. R&D-Agent: An LLM-Agent Framework Towards Autonomous Data Science[R]. 2025；另见 Collaborative Evolving Strategy for Automatic Data-Centric Development, arXiv:2407.18690, 2024.

[5] 国联民生证券. RD-Agent 实测：AI 驱动的因子挖掘框架 [R]. 2026-05-20.

[6] 开源证券. 开源量化评论（129）：AI 赋能投研体系——因子挖掘篇 [R]. 2026-09-13.

[7] WorldQuant. WorldQuant Launches BRAIN Platform and Inaugural Global Alphathon Competition [EB/OL]. 2022-08-02. https://www.worldquant.com/ideas/worldquant-launches-brain-platform-and-inaugural-global-alphathon-competition/.

[8] 华泰证券. 人工智能系列之二十八：基于量价的人工智能选股体系概览 [R]. 2020.

[9] 财联社. 券商密集上线 Skills，重构服务颗粒度 [EB/OL]. 2026-06-21.

[10] 中金公司研究部. Multi-Agent 如何辩论出基本面 Alpha？[R]. 2026-07-29.

附录：小组设计与 AI 辅助复现实践

（一）我们设计并实现的因子挖掘助手

在完成案例分析的基础上，我们进一步设计了 **Loop Research（因子发现实验室）**，并使用 AI 编程助手辅助开发，将研报中的 Loop Engineering 思路实现为可访问、可操作的课程研究网站。我们希望通过亲自搭建“生成—审查—验证—反馈”的流程，观察一个候选公式如何形成、为什么被拒绝，以及研究结果如何进入下一轮迭代。网站已经部署在 Railway，提供研究概览、原理与方法、实验记录、实时挖掘和网页研究演示等入口。[1]

小组负责研究设计与需求判断，AI 辅助完成工程实现。我们确定复现目标、页面结构、现场操作方式、实验规模和结果展示口径，再借助 AI 编程助手编写前后端代码、调试接口、补充测试和处理部署问题。开发过程中，我们还将网页候选规模扩展到最多 1,200 个，并调整了研究演示的组织方式。这里需要区分：AI 编程助手参与的是**系统开发**；网站中的 DeepSeek 模型参与的是**运行时的候选生成与逻辑审查**。



图 1: 小组网站首页：将提出假设、审查表达、验证信号与反馈迭代组织为研究闭环。

实现上，我们采用 Python/FastAPI、SQLite 与 React/TypeScript 构建轻量系统。模型通过独立的生成和审查上下文提出、检查候选，固定程序负责计算与筛选，任务状态和检查点负责保存过程。**本项目定位为依据公开描述开展的独立方法与工程复现**，数据、股票池及部分指标口径与中金原实验不同；正文中的机构回测数字仍属于研报披露结果。

演示站点：

`https://cicc-loop-reproduction-production.up.railway.app/`

[1]项目代码及功能说明：404NWF3/cicc-loop-reproduction。本附录网站截图采集于 2026 年 10 月 26 日。

（二）复现的研究闭环与网页操作

我们把研报中的机制拆成可检查的程序步骤，既呈现公式的生成过程，也保留失败与筛选依据。网站的“实时挖掘”是**在固定历史快照上当场计算**，使用 50 只股票的历史数据；“实时”指任务进度的更新，不代表接入实时行情。

1. **生成候选**。围绕五类搜索策略构造受限公式；本地模式先复算 6 个归档种子，再探索新候选。DeepSeek 模式逐批提出候选，并接收开发期失败原因等反馈。
2. **审查表达式**。检查允许的字段、算子、量纲、复杂度与回看长度，拒绝不合法或重复结构；模型审查使用与生成分开的上下文，FSA 机制限制高频骨架的重复探索。
3. **固定规则验证**。以收盘后信号、下一交易日开盘成交、5 日调仓及单边 0.1% 成本等口径计算结果，并展示 11 项本地联合过滤条件及未通过的原因。
4. **保存并反馈**。候选记录与检查点一并保存，支持暂停、刷新后继续、停止及研究结果导出；历史失败保留在记录中，供后续分析和迭代使用。



图 2: 实时挖掘配置页：本地搜索与模型引导两种入口，最多 1,200 个候选，并设置时间上限。

课堂展示时，可以先浏览 14 页网页研究演示，再进入实时挖掘页，查看候选的公式、开发期净值和筛选记录。**归档种子复算与新候选入库分别计数**，以免把重复得到的已知结果当作新发现。模型调用另受演示口令、单次预算与累计预算约束；浏览归档结果和本地搜索不会触发模型付费调用。[2]

[2]网页功能及演示流程：网页研究演示与现场挖掘说明。

（三）我们得到的实验结果与复现边界

项目在 2026 年 10 月 15 日归档了一轮扩大实验，采用 StockNet 的 **50 只美股**，将 2012 年 9 月至 2013 年设为发现期，2014—2015 年设为开发筛选期，2016 年 1 月至 2017 年 9 月 1 日设为留出期。实验共记录 **6,637 次尝试、966 次完整回测**，统一去相关后有 **23 个因子通过开发筛选**。[3]

公式、方向和排序冻结后，23 个因子中只有 **1 个**在留出期取得正的年化超额收益。按开发筛选期夏普预先选定的前 5 个因子构成等权排名组合，其留出期**费后年化超额收益为** −3.18%，**超额夏普为** −0.51。图3保留了全部 23 个因子的开发期与留出期对照。这组结果说明，扩大搜索能够产生通过开发门槛的候选，但本次实验尚未获得稳定样本外盈利的证据。



图 3: 网站研究演示中的留出检验：同一因子的开发期与留出期表现配对展示，保留负向结果。

（四）实践带来的理解

通过这次设计与复现，我们更具体地理解了 Loop Engineering 的价值：把研究判断变成明确的接口、筛选条件、反馈和可追溯记录，才能让连续搜索得到可解释的结果。AI 辅助开发降低了我们搭建研究工具的门槛，但研究人员仍需决定数据如何切分、如何计算成本，以及什么证据足以支持结论。

本次采用小规模美股历史样本，并存在事后选样、历史复权非当时可得快照及反复使用开发集等限制；也不能凭各搜索分支最终入库的数量判断某种方法具有因果优势。**我们的实践成果是一个能够展示、运行并记录因子研究过程的助手**。若要进一步检验投资价值，需要冻结当前方案，在新的未见数据上继续验证；已展示的留出期不能再次充当独立测试集。

[3]协议、结果及复核记录：StockNet 扩大实验报告（2026-10-15）。这里引用项目既有归档结果。