Assignment 1

Due at 22:00 on Thursday, October 8
Total is 150 points

Problem 1. (15 pts) 对于样本$(x_1, y_1), \ldots, (x_n, y_n)$使用最小二乘法得到估计$\hat{\beta}_0, \hat{\beta}_1$. 假设拟合值为$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$. 试证明以下结论：

1. $\sum_{i=1}^n \hat{y}_i/n = \bar{y}$.
2. $\text{SSreg} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$.
3. $R^2 = r_{XY}^2$, 其中$r_{XY}^2 = \text{SXY}^2/(\text{SXX} \cdot \text{SYY})$.

Problem 2. (10 pts) 假设有一个没有截距的线性模型

$$y_i = \beta^* x_i + e_i, \quad i = 1, \ldots, n,$$

其中$e_1, \ldots, e_n$为i.i.d. $N(0, \sigma_*^2)$的随机变量. 考虑β^*的最小二乘估计量$\hat{\beta}$ (最小二乘法中也不考虑截距), 以及另一个估计量$\widetilde{\beta} = \bar{y}/\bar{x}$.

1. 证明$\hat{\beta}$与$\widetilde{\beta}$均为β^*的无偏估计.
2. 试比较$\hat{\beta}$与$\widetilde{\beta}$哪个方差更小.

Problem 3. (30 pts). 考虑一个简单线性回归模型. 已知$n = 25$, $\bar{x} = 2.8$, $\bar{y} = -3.4$, $\text{SXX} = 586$, $\text{SXY} = -1725$, $\text{SYY} = 5099$, $\text{RSS} = 21.06$.

1. 计算$\hat{\beta}_0$, $\hat{\beta}_1$, $\hat{\sigma}^2$.
2. 计算 $\text{se}(\hat{\beta}_0)$, $\text{se}(\hat{\beta}_1)$.
3. 对于一个新的样本，我们观测到自变量值为$x_{\text{new}} = 5$，用$\hat{y}_{\text{new}} = \hat{\beta}_0 + \hat{\beta}_1 x_{\text{new}}$作为因变量的预测值。试计算其标准误$\text{se}(\hat{y}_{\text{new}})$. (提示: 可先按照公式$\text{Var}(\hat{\beta}_0 + \hat{\beta}_1 x_{\text{new}}) = \text{Var}(\hat{\beta}_0) + x_{\text{new}}^2 \text{Var}(\hat{\beta}_1) + 2x_{\text{new}} \text{Cov}(\hat{\beta}_0, \hat{\beta}_1)$求其方差以及标准差, 再将标准差中的$\sigma^*$换成$\hat{\sigma}$即得到标准误.)

(此题不是代码题，写清计算过程及结果即可。)

Problem 4. (15 pts). 假设一个多元线性回归模型中 $n = 153$, $p = 2$, SYY $= 1067.3$, RSS $= 600$. 另外知道

$$(\mathbf{X}^T\mathbf{X})^{-1} = \begin{pmatrix} 4.42654 & -1.46 & 0.36 \\ -1.46 & 0.50 & -0.20 \\ 0.36 & -0.20 & 0.40 \end{pmatrix}, \ \mathbf{X}^\top\mathbf{Y} = \begin{pmatrix} 10679 \\ 34196 \\ 7512 \end{pmatrix}$$

1. 求出估计量$\hat{\beta}_1$, 以及β_1^*置信度为95%的置信区间。

2. 在1%的显著水平下检验β_2^*与是否显著非零。

3. 计算回归的R^2.

(此题不是代码题，写清计算过程及结果即可。)

Problem 5. (10 pts) 假设有两个自变量, 一个因变量, 观测到的样本为$(x_{11}, x_{12}, y_1), \ldots, (x_{n1}, x_{n2}, y_n)$. 首先做最小二乘法, 即求

$$\min_{\beta_0,\beta_1,\beta_2} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2})^2$$

假设回归的RSS记为rss, R^2记为r^2.
其次, 只将第一个自变量包含进来做最小二乘法, 即求

$$\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_{i1})^2 .$$

假设如此做得到的RSS为rss_0, R^2为r_0^2.

1. 比较rss与rss_0的大小.

2. 比较r^2与r_0^2的大小.

Problem 6. (20 pts) 考虑n个样本p个变量的多元线性回归问题, 样本为$\mathbf{X} \in \mathbb{R}^{n\times(p+1)}$, $\mathbf{Y} \in \mathbb{R}^n$. 对于一个$(p+1)$维常数向量$\mathbf{c} \in \mathbb{R}^{p+1}$.

1. 请找出$\mathbf{c}^\top\boldsymbol{\beta}$的极大似然估计, 并证明其无偏.

2. 请计算1中得到的估计量的方差.

Problem 7. (10 pts) (过拟合, overfitting) 考虑一个线性模型

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta}^* + \mathbf{e}.$$

由于不知道以上的真实模型，我们在做线性回归时可能会加入一些无关变量。假设我们加入了另外的q个变量，它们的样本值为

$$\mathbf{X}' = \begin{bmatrix} x_{1(p+1)} & \cdots & x_{1(p+q)} \\ \vdots & \vdots & \vdots \\ x_{n(p+1)} & \cdots & x_{n(p+q)} \end{bmatrix}.$$

我们让

$$\mathbf{Z} = [\mathbf{X} \quad \mathbf{X}'],$$

即把所有$p+q+1$个变量都放进来，形成一个$n \times (p+q+1)$的矩阵。同时在$\boldsymbol{\beta}^*$后面加入q个0，得到$\mathbf{b}^* = (\beta_0^*, \beta_1^*, \ldots, \beta_p^*, 0, \ldots, 0)^\top$. 那么原模型可以等价地表示为

$$\mathbf{Y} = \mathbf{Z}\mathbf{b}^* + \mathbf{e}.$$

1. 按照我们对变量的选择，最小二乘的目标为最小化

   $$\|\mathbf{Y} - \mathbf{Z}\mathbf{b}\|^2$$

   试计算由此得到的一个$\mathbf{b}^*$的估计量$\widetilde{\mathbf{b}}$.

2. 让$\widetilde{\boldsymbol{\beta}}$为$\widetilde{\mathbf{b}}$的前$p+1$个分量组成的向量，试证明$\widetilde{\boldsymbol{\beta}}$为$\boldsymbol{\beta}^*$的无偏估计量。 (提示：将$\mathbf{Y} = \mathbf{Z}\mathbf{b}^* + \mathbf{e}$代入1的结果中，再求期望。)

Problem 8. (10 pts) Exercise 3.6 in Weisberg.

Problem 9. (30 pts). Boston.csv 收集了可能影响波士顿房价的因素，其中MEDV是自有住房的房价中位数，CRIM是城镇人均犯罪率等。假设Y表示MEDV，自变量为其他特征，考虑多元线性回归模型。

1. 计算回归的结果，计算并解释回归总结中t-值的含义。
2. 选取三个自变量，查看针对这三个自变量以及因变量绘制的散点图矩阵 (scatterplot matrix)。
3. 分析自变量中有没有多重共线性的情况。如果有，试着去掉某个/某些自变量，比较回归效果。