Assignment 2

Due at 22:00 on Thursday, October 29, 2026
Total is 130 points

数据与说明。本次使用 Weisberg 的 *Applied Linear Regression*, 4th edition 配套数据：`salary.csv`、`wblake.csv`、`ais.csv`、`turkey.csv`，均导出自 `alr4`。请使用提供的文件及原始行序，提交必要的代码、结果和简要解释。第 1–6、8–9 题的模型均含截距；第 7、10 题按各自定义拟合。涉及预测误差时，统一使用 $\mathrm{MSE} = m^{-1}\sum_{i=1}^{m}(y_i - \hat{y}_i)^2$。随机运算使用 `set.seed(2026)`。

Problem 1. (15 pts) `salary.csv` 记录了某学院 52 名教师的薪资与背景信息。取年薪 `salary` 为因变量，职称 `rank` 与最高学位 `degree` 为两个分类自变量 F_1, F_2。

1. 统计两个因子的类别及各类别样本数。含截距时，各需引入多少个虚拟变量？ (4 pts)
2. 以 `Asst`、`Masters` 为参照，写出主效应模型，估计全部系数。 (7 pts)
3. 解释职称与学位的系数含义。若改变参照类别，拟合值与 RSS 是否改变？说明原因。 (4 pts)

Problem 2. (10 pts) `wblake.csv` 包含 439 条小口黑鲈的测量记录，`Length` 为捕获时鱼长（mm），`Scale` 为鱼鳞半径（mm）。取 $Y =$ `Length`、$x =$ `Scale`。

1. 分别拟合 1 至 5 阶多项式回归，报告系数、RSS 与调整后的 R^2，在散点图上叠加拟合曲线（按 x 排序或用等距网格绘图）。可用正交多项式，但应注明基底。 (6 pts)
2. 用 BIC 选择阶数，结合曲线解释选择结果，并说明为什么不能仅凭训练 RSS 选模型。 (4 pts)

Problem 3. (20 pts) 仍使用 `wblake.csv`，取 `Length` 为因变量、`Scale` 为自变量。

1. 分别拟合三次多项式、三次回归样条、自然三次样条和平滑样条。两个回归样条的内部结点取 `Scale` 的 25%、50%、75% 分位数，边界结点取其最小值与最大值；平滑样条用 GCV 选择平滑参数。 (10 pts)
2. 在同一横轴范围内展示四条拟合曲线，报告 RSS；报告两类回归样条设计矩阵的列数（含截距）与平滑样条的有效自由度。结合曲线讨论灵活性与边界行为，并解释 RSS 最小是否足以说明模型最好。 (10 pts)

Problem 4. (10 pts) `ais.csv` 记录了 202 名运动员的身体测量及血液指标。取体脂百分比 `Bfat` 为因变量，自变量仅使用

`Ht, Wt, BMI, RCC, WCC, Hc, Hg, Ferr, SSF.`

其中 `Ht, Wt, BMI` 为身高、体重、身体质量指数；`RCC, WCC, Hc, Hg, Ferr` 为血液指标；`SSF` 为皮褶厚度总和。

1. 对九个自变量中心化并按样本标准差标准化，计算前三个主成分的载荷、各自及累计解释方差比例。说明为什么此处需要标准化。 (5 pts)
2. 用前三个主成分得分拟合线性模型，报告系数和 R^2，解释自变量的方差解释比例与对因变量的解释程度有何区别。 (5 pts)

Problem 5. (10 pts) 使用 `salary.csv`，取 $Y=$ `salary`，$A=$ `sex`、$B=$ `rank`、$C=$ `degree`，均按分类变量处理。考虑以下七个模型：

M_0	$Y \sim 1$（只有截距）
M_1	$Y \sim A + B + C$
M_2	$Y \sim A + B + C + A{:}B$
M_3	$Y \sim A + B + C + B{:}C$
M_4	$Y \sim A + B + C + A{:}C$
M_5	$Y \sim A + B + C + A{:}B + B{:}C + A{:}C$
M_6	$Y \sim A + B + C + A{:}B + B{:}C + A{:}C + A{:}B{:}C$

1. 统计因子类别数、总样本数及交叉列联表，报告各模型的 RSS 和设计矩阵秩 q（含截距）。若存在空单元格，说明对参数可识别性的影响。 (5 pts)
2. 分别按调整后的 R^2、AIC、BIC 选择模型并比较结果。比较时使用实际秩：

$$R^2_{\text{adj}} = 1 - \frac{\text{RSS}/(n-q)}{\text{TSS}/(n-1)}, \quad \text{AIC} = n\log(\text{RSS}/n) + 2q, \quad \text{BIC} = n\log(\text{RSS}/n) + q\log n.$$

   AIC、BIC 略去各模型共同的常数；并列最佳时报告并列结果。 (5 pts)

Problem 6. (15 pts) 使用 `ais.csv`，取 `Bfat` 为因变量，候选主效应为第 4 题的九个连续变量及分类变量 `Sex`（0 为男性、1 为女性）。不使用 `LBM`、`Label` 或 `Sport`。

1. 统一以 BIC 为准则，分别用前向选择（FS，从截距模型开始）、后向剔除（BE，从全部候选变量开始）、双向逐步选择（FS+BE，从截距模型开始）选择模型。给出进入或删除变量的过程、最终模型与 BIC。 (10 pts)
2. 比较三种方法的结果，说明它们是否保证找到所有子集中的最优模型；将 `Sex` 作为一个完整因子项进入或删除。 (5 pts)

Problem 7. (10 pts) 在一个回归问题中，$n = 5$、$p = 2$，$\bar{x}_1 = 2$、$\bar{x}_2 = -1$、$\bar{y} = 3$。中心化后的数据为

$$X = \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 0 & 0 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}, \qquad Y = \begin{pmatrix} 3 \\ -4 \\ 1 \\ 2 \\ -2 \end{pmatrix}.$$

本题不再标准化 X，截距不受惩罚。定义

$$\hat{\beta}^{\mathrm{OLS}} = \arg\min_{\beta} \tfrac{1}{2}\|Y - X\beta\|_2^2, \quad \hat{\beta}^{\mathrm{ridge}} = \arg\min_{\beta} \left\{ \tfrac{1}{2}\|Y - X\beta\|_2^2 + \tfrac{\lambda}{2}\|\beta\|_2^2 \right\},$$

$$\hat{\beta}^{\mathrm{lasso}} = \arg\min_{\beta} \left\{ \tfrac{1}{2}\|Y - X\beta\|_2^2 + \lambda\|\beta\|_1 \right\}.$$

1. 取 $\lambda = 5$，手算三种方法的斜率，并用 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}_1 - \hat{\beta}_2\bar{x}_2$ 恢复截距。写清计算过程。(8 pts)
2. 结合结果说明岭回归与 lasso 在系数收缩及变量选择上的差异。 (2 pts)

Problem 8. (20 pts) 使用 `ais.csv`，因变量与十个候选自变量同第 6 题。将 `Sex` 编码为 0/1 虚拟变量。配套 `ais_split.csv` 的 `row_id` 对应原始数据行号，`set` 指定 150 条训练记录及 52 条测试记录，`fold` 指定训练集中的五折划分。

岭回归与 lasso 均使用 `glmnet` 的高斯模型（分别取 `alpha=0` 和 `alpha=1`），按同一 `fold` 进行五折 CV，用验证 MSE 选择 `lambda.min`。令 `standardize=TRUE`，保留不受惩罚的截距；不手动标准化因变量。其目标函数约定为

$$\frac{1}{2n_{\mathrm{tr}}} \sum_{i \in \mathrm{tr}} (y_i - \beta_0 - x_i^{\top}\beta)^2 + \lambda \left\{ \frac{1-\alpha}{2}\|\beta\|_2^2 + \alpha\|\beta\|_1 \right\},$$

其中惩罚作用于标准化后的自变量系数；此处 λ 的尺度与第 7 题不同。

1. 拟合岭回归，绘制 CV 误差曲线，报告选定的 λ、原始量纲上的系数与测试 MSE。 (6 pts)
2. 拟合 lasso，报告同样结果及非零斜率的个数。比较两种方法的测试误差。 (6 pts)
3. 在原始量纲上组合两种方法的预测：

$$\hat{y}_i^{\mathrm{combo}}(\omega) = \omega\hat{y}_i^{\mathrm{ridge}} + (1-\omega)\hat{y}_i^{\mathrm{lasso}}, \quad \omega = 0, 0.1, \ldots, 1.$$

绘制测试 MSE 随 ω 的变化并描述结果；说明该曲线的最小值为何不能作为经独立测试验证的调参结果。若需要选择 ω，应在哪个数据集上进行? (8 pts)

Problem 9. (20 pts) 自学 group lasso，并用于 `ais.csv`。使用与第 8 题相同的因变量、训练/测试划分及五折编号，将十个自变量按以下顺序排列并分组：

组别	自变量	含义
1	`Ht, Wt, BMI`	身体尺寸
2	`RCC, Hc, Hg`	红细胞相关指标
3	`WCC, Ferr`	其他血液指标
4	`SSF`	皮褶厚度
5	`Sex`	性别（0/1）

即 `groupid=c(1,1,1,2,2,2,3,3,4,5)`。请用训练集的均值及样本标准差标准化每一列（包括 `Sex`），并将同一变换应用于测试集。因变量保持原始量纲，截距不受惩罚，组惩罚权重取各组大小的平方根。按此训练集变换后的设计矩阵进行五折 CV；测试集不参与任何参数选择。

可使用 R 包 `gglasso`（以下示例按 1.6 版，`L2` 对应均方误差）：

```
cv.gglasso(x, y, group=groupid, loss="ls",
  pred.loss="L2", foldid=foldid, nfolds=5)
gglasso(x, y, group=groupid, loss="ls", lambda=lambda)
predict(object, newx=x.test)
```

请报告软件包版本；使用其他版本时核对 `pred.loss` 的实际定义，确认用于调参的是平方预测误差；也可自行实现五折 MSE 验证。

1. 绘制 CV 误差曲线，用最小 CV MSE 选择 λ，报告截距、标准化量纲上的系数及保留的组。(12 pts)
2. 计算测试 MSE，与第 8 题比较；说明 group lasso 的组选择与普通 lasso 的变量选择有何不同。(8 pts)

参考：`https://cran.r-project.org/web/packages/gglasso/gglasso.pdf`。