2023 Fall: High-dimensional Data Analysis

Midterm Exam

无答案版

说明：

1. 期中考试时间为 2023 年 11 月 6 日 10:05-12:05。
2. 总共 6 道大题，总分 100 分。
3. 除笔以外，不允许带任何其它工具（包括自己的草稿纸）。手机请一律交到讲台上。
4. 请将答案统一写在答题纸上。
5. 步骤分将占有重要比例，请写清楚解题过程。

Problem 1 (20 pts). 判断题，请判断以下说法为正确（T）或者错误（F）。

1) 对于简单线性回归，拟合的回归线一定经过数据的中心点 $(\bar{x}, \bar{y})$。(　　)

2) 回归 $Y \sim X_1$ 的 RSS 一定不大于 $Y \sim X_1 + X_2$ 的 RSS。(　　)

3) 对于多元线性回归，RSS 符合一个卡方分布。(　　)

4) 若 F 为一个 d 个类别的 factor，则回归 $Y \sim F$ 的 t-统计量的自由度为 d。(　　)

5) 向前选变量法（forward selection）不适用于 $p > n$ 的情况。(　　)

6) 一般来说，模型的灵活度越高，预测时方差越小，偏差越大。(　　)

7) 对于线性回归的 lasso 方法，随着 tuning parameter λ 的增加，选出的变量个数会逐渐减少。(　　)

8) 非线性回归的 Gauss-Newton 法一定可以收敛到似然函数的极大值点。(　　)

9) 对于 logistic 回归模型，回归的 G^2（deviance）越小，说明模型拟合得越好。(　　)

10) 在 logistic 回归中，若 Y 为因变量，θ 为成功概率，那么 odds of success $\theta/(1-\theta)$ 可以表示为自变量的线性函数。(　　)

Problem 2 (20 pts). 假设一个多元线性模型，$n = 8$，$p = 3$，样本值在表 1 中给出。另外知道 t-分布的上分位数 $t_{0.025}(4) = 2.78$。

表 1：样本值

样本	X_1	X_2	X_3	Y
1	$1/\sqrt{8}$	$1/\sqrt{8}$	$1/\sqrt{8}$	-1
2	$1/\sqrt{8}$	$1/\sqrt{8}$	$-1/\sqrt{8}$	-1
3	$1/\sqrt{8}$	$-1/\sqrt{8}$	$1/\sqrt{8}$	2
4	$1/\sqrt{8}$	$-1/\sqrt{8}$	$-1/\sqrt{8}$	2
5	$-1/\sqrt{8}$	$1/\sqrt{8}$	$1/\sqrt{8}$	-1
6	$-1/\sqrt{8}$	$1/\sqrt{8}$	$-1/\sqrt{8}$	-1
7	$-1/\sqrt{8}$	$-1/\sqrt{8}$	$1/\sqrt{8}$	2
8	$-1/\sqrt{8}$	$-1/\sqrt{8}$	$-1/\sqrt{8}$	-2

1) (7 pts) 请求出最小二乘估计量 $\widehat{\boldsymbol{\beta}}$。

2) (7 pts) 请求出 β_1^* 置信水平为 95% 的置信区间。

3) (6 pts) 若采用 $\lambda = 2$ 的 lasso，请求出估计量 $\widehat{\boldsymbol{\beta}}^{\text{lasso}}$。

Problem 3 (16 pts). 假设一个线性回归模型可能包含两个自变量 X_1, X_2。若只包含 X_1，得到 $\text{RSS}_1 = 21$。若只包含 X_2，得到 $\text{RSS}_2 = 24$。若同时包含 X_1, X_2，则得到 $\text{RSS}_3 = 15$。另外已知 $n = 10$。

1) (8 pts) 根据 AIC 的定义

$$\text{AIC} = n \log\left(\frac{\text{RSS}}{n}\right) + 2(k+1),$$

试用 AIC 作为准则，决定应该使用哪个模型。（已知：$e^{0.2} = 1.221$）

2) (8 pts) 根据 Adjusted R^2 的定义

$$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}(1 - R^2),$$

试用 Adjusted R^2 作为准则，决定应该使用哪个模型。

Problem 4 (18 pts). 有一批信用卡数据，样本量为 $n = 300$，数据包含了每位用户的以下信息：

- X：收入，为连续变量；
- F：教育程度，为分类变量，共分为“高等（A）”、“中等（B）”、“初等（C）”三个级别；
- Y：是否存在逾期行为，为 0/1 变量。若存在逾期行为，则取值为 1；反之则取值为 0。

现在拟合一个 logistic 回归模型 $Y \sim X + F + X : F$，得到表 2 中的 summary 结果。我们忽略关于系数显著性的检验结果，即 summary 中所有变量都用上。

表 2：Summary table

	Estimate	Std. Error	z value	$\Pr(>\|z\|)$
(Intercept)	2.02	1.53	1.32	0.19
X	−2.07	1.05	−1.97	0.05
B	1.47	**(a)**	4.44	0.00
C	0.28	1.83	0.15	0.88
$X : B$	−1.68	0.66	−2.54	0.01
$X : C$	−1.82	0.96	−1.89	0.06
Null Deviance: 255.97 on 399 degrees of freedom				
Residual deviance: 132.11 on **(b)** degrees of freedom				

1) (6 pts) 将表中的 (a)(b) 用给出的数字补充完整，可以只列式不计算。另外请仅用表中数字给出变量 X 的系数 β_1^* 置信水平为 95% 的置信区间。

2) (6 pts) 若有一个新用户，其收入为 $x_{\text{new}} = 20{,}000$，教育水平为“中等”。试用表中的数据给出其逾期的概率。可以只列式不计算。

3) (6 pts) 如果把 Y 的定义颠倒，即若存在逾期行为，则 Y 取 0，反之则 Y 取 1。再拟合 logistic 回归模型时，是否所有的回归系数恰好为原来值的相反数？请说明理由。

Problem 5 (14 pts). 假设一个简单线性模型

$$y_i = \beta_0^* + \beta_1^* x_i + e_i, \qquad 1 \le i \le n,$$

其中 $e_i \overset{\text{i.i.d.}}{\sim} N(0, \sigma_*^2)$。假设用最小二乘法得出的估计值为 $\widehat{\beta}_0, \widehat{\beta}_1$，回归的 R^2 记为 r^2。假设我们对数据进行如下变换

$$y_i' = \frac{y_i - c_1}{d_1}, \qquad x_i' = \frac{x_i - c_2}{d_2}.$$

然后用数据 $(x_1', y_1'), \ldots, (x_n', y_n')$ 进行最小二乘估计，得到估计值 $\widehat{\beta}_0', \widehat{\beta}_1'$，以及 R^2 的值 r'^2。

1) (7 pts) 试推出 $\widehat{\beta}_0', \widehat{\beta}_1'$ 与 $\widehat{\beta}_0, \widehat{\beta}_1$ 的关系。

2) (7 pts) 证明 $r^2 = r'^2$。

Problem 6 (12 pts). 假设有 q 个随机变量组成的一个随机向量 $\boldsymbol{W} = (W_1, \ldots, W_q)^\mathsf{T}$，它的协方差矩阵为 $\mathrm{Cov}(\boldsymbol{W}) = \Sigma$。

1) (4 pts) 从 $\boldsymbol{W}$ 出发，我们构造 p 个自变量 $X_1, \ldots, X_p$，其中 $p > q$。具体如下：

$$\begin{aligned} X_1 &= a_{11}W_1 + \cdots + a_{1q}W_q \\ &\cdots \\ X_p &= a_{p1}W_1 + \cdots + a_{pq}W_q, \end{aligned}$$

其中 a_{ij} 均为取定的常数。
记 $\boldsymbol{X} = (X_1, \ldots, X_p)^\mathsf{T}$，同时记

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1q} \\ & \cdots & \\ a_{p1} & \cdots & a_{pq} \end{bmatrix} \in \mathbb{R}^{p \times q}.$$

注意到 $\boldsymbol{X}$ 的协方差矩阵为 $\mathrm{Cov}(\boldsymbol{X}) = A\Sigma A^\mathsf{T}$。现在对这 p 个自变量 $X_1, \ldots, X_p$ 进行主成分分析。试证明：只存在 q 个有效的主成分（即前 q 个主成分代表了自变量的全部信息）。

2) (4 pts) 现在假设 1) 中 $\boldsymbol{X}$ 对 $\boldsymbol{W}$ 的依赖关系中有一些随机扰动：

$$\begin{aligned} X_1 &= a_{11}W_1 + \cdots + a_{1q}W_q + \epsilon_1 \\ &\cdots \\ X_p &= a_{p1}W_1 + \cdots + a_{pq}W_q + \epsilon_p, \end{aligned}$$

其中 $\epsilon_1, \ldots, \epsilon_p$ 为 i.i.d. $N(0, \tau^2)$ 分布的随机变量，且均与 $\boldsymbol{W}$ 互相独立。此时再对这 p 个自变量 $X_1, \ldots, X_p$ 进行主成分分析。试证明：此时 $\mathrm{Cov}(\boldsymbol{X})$ 的前 q 个特征值为

$$\lambda_1 + \tau^2 \geq \cdots \geq \lambda_q + \tau^2,$$

其中 $\lambda_1 \geq \cdots \geq \lambda_q$ 为 $A\Sigma A^\mathsf{T}$ 的前 q 个特征值。

3) (4 pts) 延续 2) 中的设定。试证明：前 q 个主成分代表的信息占总信息的比例为

$$\frac{\sum_{i=1}^q \lambda_i + q\tau^2}{\sum_{i=1}^q \lambda_i + p\tau^2}.$$