2025 Fall: High-dimensional Data Analysis

Midterm Exam

无答案版

说明：

1. 期中考试时间为 2025 年 11 月 14 日 10:05-12:05。
2. 总共七道大题，前两道为判断选择题，后面五道为计算题。总分 100 分。
3. 除笔以外，不允许带任何其它工具（包括自己的草稿纸）。手机请一律交到讲台上。
4. 请将答案统一写在答题纸上。
5. 步骤分将占有重要比例，请写清楚解题过程。

Problem 1 (10 pts). 判断题，请判断以下说法为正确（T）或者错误（F）。

1) 简单线性回归中，若用最小二乘（OLS）估计，则数据的中心点 $(\bar{x}, \bar{y})$ 一定落在估计出的回归线上。(　　)

2) 在包含 p 个自变量的线性回归 $Y \sim X_1 + \cdots + X_p$ 中，用最小二乘法估计回归系数，则 $\widehat{\sigma}^2 = \mathrm{RSS}/(n-p-1)$ 是 σ_*^2 的无偏估计。(　　)

3) 对于一个有 d 个水平的类别型变量 F，做线性回归 $Y \sim F$。若采用虚拟变量法引入 $(d-1)$ 个虚拟变量，则所有虚拟变量的回归系数都代表该类别与 Y 的总样本均值 $\bar{y} = \sum_{i=1}^{n} y_i/n$ 的差异。(　　)

4) 在 logistic 回归，回归的 G^2（deviance）越小，说明模型拟合得越好。(　　)

5) 非线性回归的 Gauss-Newton 算法一定保证收敛到全局最优解。(　　)

Problem 2 (16 pts). 单选题，每题只有一个正确答案。

1) 在多元线性回归中，加入一个与因变量完全不相关但与其他自变量高度相关的变量，最可能导致(　　)

   (A) 新变量的系数会非常显著（即 p-值很小）

   (B) 所有变量系数的标准误都会减小

   (C) 原来自变量的系数出现变化，甚至由显著变得不显著

   (D) 模型的 R^2 显著提高

2) 以下关于 R^2_{adj} 的说法中，正确的是(　　)

   (A) 其唯一目标是提升模型在训练数据上的拟合优度

   (B) 它可以帮助我们避免过拟合

   (C) 它确保了模型中所有变量的系数都是统计显著的

   (D) 当选取的变量数 k 固定时，R^2_{adj} 就完全确定了

3) 关于 lasso 和岭回归的说法，错误的是(　　)

(A) lasso 可以将某些系数压缩至 0，从而实现变量选择；而岭回归通常做不到

(B) 两者都可以用于处理变量数量多于样本数量（$p > n$）的情况

(C) 两者估计出的回归系数都是有偏的

(D) 对于每一个自变量，lasso 生成的回归系数的长度（即绝对值）一定比岭回归要小

4) 关于主成分分析，以下说法错误的是(　　)

(A) 主成分是原始变量的线性组合，且各主成分之间相互正交

(B) 通常需要保留所有特征值大于 0 的主成分

(C) 载荷表示主成分中每个变量的权重

(D) 得分表示每个样本点在主成分方向上的值

Problem 3 (15 pts). 在一个简单线性回归中，样本数量为 $n = 14$，计算出 SYY $= 20$，SXX $= 20$，SXY $= 10$，RSS $= 15$。

1. (5 pts) 斜率的最小二乘估计 $\widehat{\beta}_1$。
2. (5 pts) 求出可决系数 R^2。
3. (5 pts) 构造 t-检验来判断 β_1^* 是否显著非 0。这里显著水平选 $\alpha = 0.05$，已知 $t(12)$-分布的上分位数 $t_{\alpha/2}(12) = 2.45$。

Problem 4 (14 pts). 假设一个线性回归中，有一个连续自变量为 X 和一个分类自变量 F，F 有 3 个类别。样本量为 $n = 10$。我们从一个只有截距的模型开始，用向前选变量法做了三步，其中 F 生成的虚拟变量整组一起加进来。表 1 给出了过程中拟合的四个模型以及相应的 RSS。注意模型 (2)、(3)、(4) 也都自然包含了截距。

表 1

序号	模型	RSS
(1)	$Y \sim 1$（只有截距的模型）	100
(2)	$Y \sim X$	48
(3)	$Y \sim X + F$	24
(4)	$Y \sim X + F + X : F$	18

1. (7 pts) 我们知道，adjusted R^2 的定义为

$$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}(1 - R^2),$$

其中 k 为模型中包含的自变量个数。试用此准则选出合适的模型。

2. (7 pts) 已知 AIC 的定义为

$$\text{AIC} = n \log\left(\frac{\text{RSS}}{n}\right) + 2(k+1).$$

试用此准则选出合适的模型。(已知：$e^{0.2} \approx 1.2$，$e^{0.4} \approx 1.5$。)

Problem 5 (14 pts). 一次商业推广活动中，商家统计了一些用户的基本信息，以及每位用户是否最后有购买行为。我们通过 logistic 回归来分析用户的购买行为受哪些因素影响。我们选用的数据样本量为 $n = 500$，每位用户的信息包括

- X：收入（万元），为连续变量；
- A：性别，为分类变量，分为 “女性（F）”、“男性（M）”；
- Y：是否购买，为 0/1 变量。若存在购买行为，则取值为 1；反之则取值为 0。

现在拟合一个 logistic 回归模型 $Y \sim X + A + X : A$，得到表 2 中的 summary 结果。

表 2：Summary table

	Estimate	Std. Error	z value	$\Pr(>\|z\|)$
(Intercept)	1.55	1.20	1.32	0.19
X	0.47	0.22	2.11	0.035
M	−1.66	0.53	−3.15	0.0016
$X : M$	0.35	0.40	0.88	0.38
Null Deviance: 188.50 on 499 degrees of freedom				
Residual deviance: 43.12 on 496 degrees of freedom				

1) (5 pts) 对于一个收入为 $x_{\text{new}} = 1.5$ 的女性新用户，试用表中的数据给出其购买的概率。可以只列式不计算。

2) (5 pts) 我们比较女性用户与男性用户的购买 odds（即购买概率/不购买概率）。固定收入水平 $x = 1$, 构建一个全模型和一个主效应模型。在这两个模型之下, 分别说明两性用户的购买 odds 之间的关系。

3) (4 pts) 在未来的商业推广活动中，对用户群体购买行为的预测决定了营销策略的方向。经理 A 说：“我们应该不要漏掉可能的客户，即使这样会使我们在未来的商业推广活动中产生更高的费用。” 经理 B 说：“我们应该跟专注特定的用户群体进行精准营销，这样可以节省营销成本。” 针对两个经理的话，我们分别应该怎么去预测下次营销活动中新用的购买行为?

Problem 6 (16 pts). 对于线性回归，我们令 $A = (\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top \in \mathbb{R}^{(p+1)\times n}$，则最小二乘估计量可以写为 $\widehat{\boldsymbol{\beta}} = A\boldsymbol{Y}$。现在给定任何一个满足 $\widetilde{A}\boldsymbol{X} = I$ 的常数矩阵 $\widetilde{A} \in \mathbb{R}^{(p+1)\times n}$，考虑一个估计量 $\widetilde{\boldsymbol{\beta}} = \widetilde{A}\boldsymbol{Y}$。

1. (4 pts) 证明：$\widetilde{\boldsymbol{\beta}}$ 为 $\boldsymbol{\beta}^*$ 的无偏估计量。
2. (4 pts) 对于任何常数向量 $\boldsymbol{c} \in \mathbb{R}^{p+1}$，令 $u_1 = \boldsymbol{c}^\top\widehat{\boldsymbol{\beta}}$，$u_2 = \boldsymbol{c}^\top\widetilde{\boldsymbol{\beta}}$。证明：$u_1, u_2$ 均为 $\boldsymbol{c}^\top\boldsymbol{\beta}^*$ 的无偏估计量。
3. (4 pts) 证明：$\mathrm{Cov}(u_1, u_2) = \mathrm{Var}(u_1)$。
4. (4 pts) 利用 3 的结论，证明 $\mathrm{Var}(u_1) \le \mathrm{Var}(u_2)$。

Problem 7 (15 pts). 假设两个自变量 Z_1, Z_2 分别有一列样本值 $\boldsymbol{Z}_1 = (z_{11}, \ldots, z_{n1})^\mathsf{T} \in \mathbb{R}^n$，$\boldsymbol{Z}_2 = (z_{12}, \ldots, z_{n2})^\mathsf{T} \in \mathbb{R}^n$，它都已中心化、标准化，并且互相正交。即

$$\sum_{i=1}^n z_{i1}/n = \sum_{i=1}^n z_{i2}/n = 0, \qquad \|\boldsymbol{Z}_1\|^2 = \|\boldsymbol{Z}_2\|^2 = 1, \qquad \boldsymbol{Z}_1^\mathsf{T}\boldsymbol{Z}_2 = 0.$$

另外有因变量 Y 的样本值 $\boldsymbol{Y} = (y_1, \ldots, y_n)^\mathsf{T}$，也已做好中心化，即 $\sum_{i=1}^n y_i/n = 0$。

1. (5 pts) 考虑简单回归 $Y \sim Z_1$，由于变量都已中心化，可以不用加入截距。此时最小二乘的目标为

   $$\min_{\gamma_1} \|\boldsymbol{Y} - \gamma_1 \boldsymbol{Z}_1\|^2 .$$

   证明：此时回归的 R^2 等于 ρ_1^2，其中

   $$\rho_1 = \frac{\boldsymbol{Z}_1^\mathsf{T}\boldsymbol{Y}}{\|\boldsymbol{Z}_1\|\,\|\boldsymbol{Y}\|}$$

   为 Z_1 与 Y 的样本相关系数。

2. (5 pts) 考虑二元回归 $Y \sim Z_1 + Z_2$，同样不用加入截距。证明：用最小二乘法估计出的两个斜率为

   $$\widehat{\gamma}_1 = \boldsymbol{Z}_1^\mathsf{T}\boldsymbol{Y}, \qquad \widehat{\gamma}_2 = \boldsymbol{Z}_2^\mathsf{T}\boldsymbol{Y}.$$

3. (5 pts) 假设变量 $X_1 = Z_1$，$X_2 = Z_1 + Z_2$，其样本即为 $\boldsymbol{X}_1 = \boldsymbol{Z}_1$，$\boldsymbol{X}_2 = \boldsymbol{Z}_1 + \boldsymbol{Z}_2$。现在用 X_1, X_2 作为自变量，做回归 $Y \sim X_1 + X_2$（不加截距），并用岭回归做正则化，即求解

   $$\min_{\beta_1,\beta_2} \|\boldsymbol{Y} - \beta_1\boldsymbol{X}_1 - \beta_2\boldsymbol{X}_2\|^2 + \lambda(\beta_1^2 + \beta_2^2).$$

   请求出岭回归的解，将其写成依赖于 $\widehat{\gamma}_1, \widehat{\gamma}_2, \lambda$ 的表达式。