2026 Fall: High-dimensional Data Analysis

Sample Midterm Exam 2

无答案版

说明：本样卷供同学们参考。正式考试中的风格和难度与此样卷类似。

Problem 1 (10 pts). 判断题，请判断以下说法为正确（T）或者错误（F）。

1) 回归 $Y \sim X_1$ 的 RSS 一定不小于 $Y \sim X_1 + X_2$ 的 RSS。(　　)

2) 对于线性回归模型来说，模型包含的变量越多，则预测误差越小。(　　)

3) 在线性回归的岭回归方法中，tuning parameter λ 越大，则预测时方差越大，偏差平方越小。(　　)

4) 对非线性回归模型来说，参数估计的 Gauss-Newton 算法总是能够收敛到全局最优解。(　　)

5) 当 n 较大时，BIC 对于变量数的惩罚比 AIC 更加严厉（换句话说，BIC 选出的变量数一般不会多于 AIC)。(　　)

Problem 2 (16 pts). 单选题，每题只有一个正确答案。

1) 在线性回归中，下面哪一个量仅依赖于自变量，而不依赖于因变量? (　　)

(A) 最小二乘估计量 $\widehat{\boldsymbol{\beta}}$

(B) 第一个主成分的载荷（loadings）

(C) 残差平方和 RSS

(D) R^2

2) 下面哪种变量选择方法不适用于 $p > n$ 的情形? (　　)

(A) 向前选变量法（forward selection）

(B) 向后选变量法（backward elimination）

(C) 岭回归（ridge regression）

(D) lasso

3) 下列哪个模型可以直接转化为一个线性模型?（其中 θ_1^*, θ_2^* 为未知参数）(　　)

(A) $y_i = \theta_1^* + \exp(\theta_2^* + \log x_i) + e_i$

(B) $y_i = \theta_1^* + \exp(\theta_2^* \log x_i) + e_i$

(C) $y_i = \theta_1^* + \log(\theta_2^* + x_i) + e_i$

(D) $y_i = \theta_1^* \exp(\theta_2^* x_i) + e_i$

4) 下列关于 logistic 回归的说法正确的是(　　)

(A) 自变量只允许是连续型的

(B) 因变量只能是 0-1 变量

(C) 成功概率为自变量的一个线性组合

(D) 回归的 G^2（deviance）越小，说明模型拟合得越好

Problem 3 (14 pts). 假设如下回归模型

$$y_i = \beta_0^* + \beta_1^* x_i + \beta_2^*(3x_i^2 - 2) + e_i, \qquad i = 1, 2, 3.$$

其中 $e_i \overset{\text{i.i.d.}}{\sim} N(0, \sigma^{*2})$。我们给定自变量的值 $x_1 = -1$, $x_2 = 0$, $x_3 = 1$, 而因变量的值则用 y_1, y_2, y_3 表示。

1) (8 pts) 求出 $\beta_0^*, \beta_1^*, \beta_2^*$ 的最小二乘估计量。

2) (6 pts) 证明：当已知 $\beta_2^* = 0$ 时，β_0^*, β_1^* 的最小二乘估计量保持不变。

Problem 4 (16 pts). 在一个线性回归中有连续因变量 Y，有一个连续自变量 X 与一个分类变量 F，其中 F 有两个类别 $\{A, B\}$。样本数为 $n = 8$。我们分别拟合三个模型，得到如下结果：

表 1：模型 1：$Y \sim X$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	32.31	2.00	16.16	3.58E-06
X	14.32	0.70	20.46	8.87E-07
R-squared: 0.34				

表 2：模型 2：$Y \sim X + F$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	29.66	2.04	14.54	1.39E-05
X	14.57	0.69	21.12	2.21E-06
B	3.83	0.74	5.18	1.77E-03
R-squared: 0.50				

表 3：模型 3：$Y \sim X + F + X : F$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	30.36	2.86	10.62	2.22E-04
X	14.33	0.98	14.62	6.36E-05
B	2.47	3.96	0.62	0.28
$X : B$	0.48	1.38	0.35	0.37
R-squared: 0.64				

1) (4 pts) 从模型的基本设定方面，简述三个模型在回归的截距以及 X 的斜率上有何区别。

2) (4 pts) 对于模型 2，请构建 X 回归系数的一个 95% 置信水平的置信区间（允许用符号表示 t-分布的分位数）。判断 0 是否被包含在这个置信区间之内。

3) (4 pts) 如果用 t-检验的显著性为判断依据来选择模型，最合理的模型应该是什么样的?

4) (4 pts) 如果用 R^2_{adj} 为判断依据来选择，应该用哪一个模型?

Problem 5 (15 pts). 在一个 logistic 回归中，因变量 Y 是一个 0-1 变量，有三个连续型自变量 X_1, X_2, X_3。我们拟合模型 $Y \sim X_1 + X_2 + X_3$，得到如表 4 的结果。

表 4：Logistic 模型 $Y \sim X_1 + X_2 + X_3$ 的结果

	Estimate	Std. Error	z value	$\Pr(>\|z\|)$
(Intercept)	-15.55	7.29	-2.13	0.033
X_1	-0.59	0.36	(a)	0.10
X_2	0.56	0.33	1.70	0.089
X_3	1.96	(b)	2.23	(c)
Residual deviance: 14.18 on 16 degrees of freedom				

1) (5 pts) 用表 4 中给出的数字计算缺失的 (a)-(c) 值。只需要给出计算式，不要求计算结果。

2) (5 pts) 假设 $x_1 = 5$，$x_2 = 25$。根据表 4 的结果，我们需要选定怎样的 x_3 值才能使得 $y = 1$ 的概率为 40%？只需要给出计算式，不要求计算结果。

3) (5 pts) AIC 一般定义为

$$\text{AIC} = -2\log(\text{maximum likelihood}) + 2 \cdot \text{number of parameters}.$$

现在我们拟合一个不含 X_1 的模型，得到如表 5 的结果。如果用 AIC 作为模型选择准则，应该选用哪个模型？

表 5：Logistic 模型 $Y \sim X_2 + X_3$ 的结果

	Estimate	Std. Error	z value	$\Pr(>\|z\|)$
(Intercept)	-7.60	4.44	-1.71	0.087
X_2	0.087	0.14	0.60	0.55
X_3	1.53	0.68	2.25	0.024
Residual deviance: 18.16 on 17 degrees of freedom				

（提示：Residual deviance 即 logistic 回归的 deviance，定义为 $G^2 = 2(l^s - \widehat{l})$，其中 l^s 与 $\widehat{l}$ 分别为饱和模型以及 logistic 模型的最大对数似然函数值。）

Problem 6 (15 pts). 考虑一个简单线性模型

$$y_i = \beta_0^* + \beta_1^* x_i + e_i, \qquad i = 1, \ldots, n,$$

其中 $e_i \overset{\text{i.i.d.}}{\sim} N(0, \sigma^{*2})$。现在对于某给定函数 $g(x)$，定义 $z_i = g(x_i)$。让 $\bar{z} = \sum_{i=1}^n z_i/n$。考虑 β_1^* 的一个估计量

$$\widetilde{\beta}_1 = \frac{\sum_{i=1}^n (z_i - \bar{z}) y_i}{\sum_{i=1}^n (z_i - \bar{z}) x_i}.$$

1) (5 pts) 证明：$\widetilde{\beta}_1$ 是无偏的。

2) (5 pts) 证明：

$$\mathrm{Var}(\widetilde{\beta}_1) = \frac{\sum_{i=1}^n (z_i - \bar{z})^2}{\left\{\sum_{i=1}^n (z_i - \bar{z}) x_i\right\}^2} \sigma^{*2}.$$

3) (5 pts) 记 β_1^* 最小二乘估计量为 $\widehat{\beta}_1$。我们知道，

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x}) x_i}.$$

证明：

$$\mathrm{Var}(\widehat{\beta}_1) \le \mathrm{Var}(\widetilde{\beta}_1).$$

（提示：可以利用柯西-施瓦茨不等式

$$\left\{\frac{1}{n}\sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})\right\}^2 \le \left\{\frac{1}{n}\sum_{i=1}^n (z_i - \bar{z})^2\right\}\left\{\frac{1}{n}\sum_{i=1}^n (x_i - \bar{x})^2\right\}.$$

）

Problem 7 (14 pts). 假设有 $2m + n$ 个因变量的样本 $y_1, \ldots, y_{2m+n}$，分为三组，分别满足

$$\begin{aligned} y_i &= \theta^* + e_i, && 1 \le i \le m, \\ y_i &= \theta^* + \phi^* + e_i, && m+1 \le i \le 2m, \\ y_i &= \theta^* - 2\phi^* + e_i, && 2m+1 \le i \le 2m+n, \end{aligned}$$

其中 $e_i \overset{\text{i.i.d.}}{\sim} N(0, \sigma^{*2})$。

1) (7 pts) 求出 θ^* 与 ϕ^* 的最小二乘估计量 $\widehat{\theta}$ 与 $\widehat{\phi}$。

2) (7 pts) 证明：当 $m = 2n$ 时，1) 中求得的 $\widehat{\theta}$ 与 $\widehat{\phi}$ 相关系数为 0。