2026 Fall: High-dimensional Data Analysis

Sample Midterm Exam 1

说明：本样卷供同学们参考。正式考试中的风格和难度与此样卷类似。

Problem 1 (10 pts). 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1) 简单线性回归中，若用最小二乘 (OLS) 估计，则数据的中心点$(\bar{x}, \bar{y})$一定落在估计出的回归线上。（ T ）

2) 在包含p个自变量的线性回归$Y \sim X_1 + \cdots + X_p$中，用最小二乘法估计回归系数，则$\hat{\sigma}^2 = \text{RSS}/(n-p-1)$是$\sigma_*^2$的无偏估计。（ T ）

3) 对于一个有d个水平的类别型变量F，做线性回归$Y \sim F$. 若采用虚拟变量法引入$(d-1)$个虚拟变量，则所有虚拟变量的回归系数都代表该类别与Y的总样本均值$\bar{y} = \sum_{i=1}^{n} y_i/n$的差异。（ F ）

4) 在logistic回归，回归的G^2 (deviance) 越小，说明模型拟合得越好（ T ）

5) 非线性回归的Gauss-Newton算法一定保证收敛到全局最优解（ F ）

Problem 2 (16 pts). 单选题，每题只有一个正确答案。

1) 在多元线性回归中，加入一个与因变量完全不相关但与其他自变量高度相关的变量，最可能导致（ C ）

(A) 新变量的系数会非常显著 (即p-值很小)

(B) 所有变量系数的标准误都会减小

(C) 原来自变量的系数出现变化，甚至由显著变得不显著

(D) 模型的R^2显著提高

2) 以下关于R^2_{adj}的说法中，**正确**的是（ B ）

(A) 其唯一目标是提升模型在训练数据上的拟合优度

(B) 它可以帮助我们避免过拟合

(C) 它确保了模型中所有变量的系数都是统计显著的

(D) 当选取的变量数k固定时，R^2_{adj}就完全确定了

3) 关于lasso和岭回归的说法，**错误**的是（ D ）

(A) lasso可以将某些系数压缩至0，从而实现变量选择；而岭回归通常做不到

(B) 两者都可以用于处理变量数量多于样本数量 ($p > n$) 的情况

(C) 两者估计出的回归系数都是有偏的

(D) 对于每一个自变量，lasso生成的回归系数的长度 (即绝对值) 一定比岭回归要小

4) 关于主成分分析，以下说法**错误**的是（ B ）

(A) 主成分是原始变量的线性组合，且各主成分之间相互正交

(B) 通常需要保留所有特征值大于0的主成分

(C) 载荷表示主成分中每个变量的权重

(D) 得分表示每个样本点在主成分方向上的值

Problem 3 (15 pts). 在一个简单线性回归中，样本数量为$n = 14$, 计算出 SYY $= 20$, SXX $= 20$, SXY $= 10$, RSS $= 15$.

1. (5 pts) 斜率的最小二乘估计$\hat{\beta}_1$.
2. (5 pts) 求出可决系数R^2.
3. (5 pts) 构造t-检验来判断β_1^*是否显著非0。这里显著水平选$\alpha = 0.05$, 已知$t(12)$-分布的上分位数$t_{\alpha/2}(12) = 2.45$.

1. 斜率的最小二乘估计为

$$\hat{\beta}_1 = \frac{\text{SXY}}{\text{SXX}} = 0.5.$$

2. 可决系数为

$$R^2 = \frac{\text{SYY} - \text{RSS}}{\text{SYY}} = 0.25.$$

3. 首先算出$\hat{\sigma}^2 = \text{RSS}/(n-2) = 1.25$**. 从而**

$$\text{se}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{\text{SXX}}} = 0.25.$$

所以t**-统计量为**$\hat{\beta}_1/\text{se}(\hat{\beta}_1) = 2$**. 它小于**$t_{\alpha/2}(12)$**, 因此不显著非零。**

表 1

序号	模型	RSS
(1)	$Y \sim 1$ (只有截距的模型)	100
(2)	$Y \sim X$	48
(3)	$Y \sim X + F$	24
(4)	$Y \sim X + F + X : F$	18

Problem 4 (14 pts). 假设一个线性回归中，有一个连续自变量为X和一个分类自变量F, F有3个类别。样本量为$n = 10$. 我们从一个只有截距的模型开始，用向前选变量法做了三步，其中F生成的虚拟变量整组一起加进来。表1给出了过程中拟合的四个模型以及相应的RSS。注意模型(2), (3), (4)也都自然包含了截距。

1. (7 pts) 我们知道，adjusted R^2的定义为

$$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}(1-R^2),$$

其中k为模型中包含的自变量个数。试用此准则选出合适的模型。

2. (7 pts) 已知AIC的定义为

$$\text{AIC} = n \log\left(\frac{\text{RSS}}{n}\right) + 2(k+1).$$

试用此准则选出合适的模型。(已知：$e^{0.2} \approx 1.2$, $e^{0.4} \approx 1.5$.)

1. 可以算出

序号	模型	RSS	$k+1$	R^2	R^2_{adj}
(1)	$Y \sim 1$ (只有截距的模型)	100	1	0	0
(2)	$Y \sim X$	48	2	0.52	0.46
(3)	$Y \sim X + F$	24	4	0.76	0.64
(4)	$Y \sim X + F + X : F$	18	6	0.82	0.595

因此选择模型(3)。

2. 模型(1)与模型(2)对比，后者更好等价于

$$n \log\left(\frac{\text{RSS}_1}{n}\right) + 2 \geq n \log\left(\frac{\text{RSS}_2}{n}\right) + 4,$$

而这等价于

$$\frac{\text{RSS}_1}{\text{RSS}_2} \geq e^{0.2} \approx 1.2$$

条件满足，因此选模型(2)。

模型(2)与模型(3)对比，后者更好等价于

$$\frac{\mathrm{RSS}_2}{\mathrm{RSS}_3} \geq e^{0.4} \approx 1.5$$

条件满足，因此选模型(2)。

模型(3)与模型(4)对比，后者更好等价于

$$\frac{\mathrm{RSS}_3}{\mathrm{RSS}_4} \geq e^{0.4} \approx 1.5$$

条件不满足，因此选模型(3)。

Problem 5 (14 pts) 一次商业推广活动中，商家统计了一些用户的基本信息，以及每位用户是否最后有购买行为。我们通过logistic回归来分析用户的购买行为受哪些因素影响。我们选用的数据样本量为$n = 500$，每位用户的信息包括

- X: 收入 (万元)，为连续变量；
- A：性别，为分类变量，分为“女性 (F)”、“男性 (M)”；
- Y：是否购买，为0/1变量。若存在购买行为，则取值为1；反之则取值为0。

现在拟合一个logistic回归模型$Y \sim X + A + X : A$，得到表2中的summary结果。

表 2: Summary table

	Estimate	Std. Error	z value	Pr($>\|z\|$)
(Intercept)	1.55	1.20	1.32	0.19
X	0.47	0.22	2.11	0.035
M	-1.66	0.53	-3.15	0.0016
$X : M$	0.35	0.40	0.88	0.38
Null Deviance: 188.50 on 499 degrees of freedom				
Residual deviance: 43.12 on 496 degrees of freedom				

1) (5 pts) 对于一个收入为$x_{\text{new}} = 1.5$的女性新用户，试用表中的数据给出其购买的概率。可以只列式不计算。

2) (5 pts) 我们比较女性用户与男性用户的购买odds (即购买概率/不购买概率)。固定收入水平$x = 1$，构建一个全模型和一个主效应模型。在这两个模型之下，分别说明两性用户的购买odds之间的关系。

3) (4 pts) 在未来的商业推广活动中，对用户群体购买行为的预测决定了营销策略的方向。经理A说：“我们应该不要漏掉可能的客户，即使这样会使我们在未来的商业推广活动中产生更高的费用。”经理B说：“我们应该跟专注特定的用户群体进行精准营销，这样可以节省营销成本。”针对两个经理的话，我们分别应该怎么去预测下次营销活动中新用的购买行为？

答案:

1) 让$\eta =$,购买概率为

$$\frac{e^{1.55+0.47\times 1.5}}{1+e^{1.55+0.47\times 1.5}}.$$

2) 在全模型下，男性用户的**linear predictor**比女性用户高$-1.66+0.35=-1.31$，因此的购买**odds**是女性的$e^{-1.31}$倍。在主效应模型下，男性用户的**linear predictor**比女性用户高-1.66，因此购买**odds**是女性的$e^{-1.66}$倍。

3) 对于经理**A**，我们应该在预测时采用一个临界值$\bar{\theta}<0.5$。即当计算出用户的购买概率¿$\bar{\theta}$时，将用户预测为会购买，否则预测为不会购买。对于经理**B**，我们调整临界值至$\bar{\theta}>0.5$即可。

Problem 6 (16 pts). 对于线性回归，我们令$\mathbf{A}=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\in\mathbb{R}^{(p+1)\times n}$, 则最小二乘估计量可以写为$\widehat{\boldsymbol{\beta}}=\mathbf{AY}$. 现在给定任何一个满足$\widetilde{\mathbf{A}}\mathbf{X}=\mathbf{I}$的常数矩阵$\widetilde{\mathbf{A}}\in\mathbb{R}^{(p+1)\times n}$, 考虑一个估计量$\widetilde{\boldsymbol{\beta}}=\widetilde{\mathbf{A}}\mathbf{Y}$.

1. (4 pts) 证明：$\widetilde{\boldsymbol{\beta}}$为$\boldsymbol{\beta}^*$的无偏估计量。
2. (4 pts) 对于任何常数向量$\mathbf{c}\in\mathbb{R}^{p+1}$, 令$u_1=\mathbf{c}^\top\widehat{\boldsymbol{\beta}}$, $u_2=\mathbf{c}^\top\widetilde{\boldsymbol{\beta}}$. 证明：$u_1$, u_2均为$\mathbf{c}^\top\boldsymbol{\beta}^*$的无偏估计量。
3. (4 pts) 证明：$\mathrm{Cov}(u_1,u_2)=\mathrm{Var}(u_1)$.
4. (4 pts) 利用3的结论，证明$\mathrm{Var}(u_1)\le\mathrm{Var}(u_2)$.

1. 由于$\mathbf{Y}=\mathbf{X}\boldsymbol{\beta}^*+\mathbf{e}$以及$\mathbf{e}=\mathbf{0}$, 我们知道

$$\mathrm{E}(\widetilde{\boldsymbol{\beta}})=\mathrm{E}(\mathbf{AX}\boldsymbol{\beta}^*+\mathbf{Ae})=\mathbf{AX}\boldsymbol{\beta}^*+\mathbf{A}\mathrm{E}(\mathbf{e})=\boldsymbol{\beta}^*.$$

2. 根据1可得

$$\mathrm{E}(\mathbf{c}^\top\widetilde{\boldsymbol{\beta}})=\mathbf{c}^\top\mathrm{E}(\widetilde{\boldsymbol{\beta}})=\mathbf{c}^\top\boldsymbol{\beta}^*.$$

而$\widehat{\boldsymbol{\beta}}$是$\widetilde{\boldsymbol{\beta}}$的一种特殊情况。

3. 我们知道

$$\begin{aligned}\mathrm{Cov}(u_1,u_2)&=\mathrm{E}\left\{(u_1-\mathrm{E}(u_1))(u_2-\mathrm{E}(u_2))\right\}\\&=\mathrm{E}\left\{(\mathbf{c}^\top\mathbf{Ae})(\mathbf{c}^\top\widetilde{\mathbf{A}}\mathbf{e})^\top\right\}\\&=\mathbf{c}^\top\mathbf{A}\mathrm{E}(\mathbf{ee}^\top)\widetilde{\mathbf{A}}^\top\mathbf{c}\\&=\sigma_*^2\mathbf{c}^\top\mathbf{A}\widetilde{\mathbf{A}}^\top\mathbf{c}\end{aligned}$$

同理可得$\mathrm{Var}(u_1) = \mathrm{Cov}(u_1, u_1) = \sigma_*^2 \mathbf{c}^\top \mathbf{A}\mathbf{A}^\top \mathbf{c}$ 而

$$\mathbf{A}\widetilde{\mathbf{A}}^\top = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\widetilde{\mathbf{A}}^\top = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top = \mathbf{A}\mathbf{A}^\top,$$

因此$\mathrm{Cov}(u_1, u_2) = \mathrm{Var}(u_1)$.

4. 根据3,

$$\mathrm{Cov}(u_1, u_2 - u_1) = \mathrm{Cov}(u_1, u_2) - \mathrm{Cov}(u_1, u_1) = 0.$$

于是

$$\begin{aligned}\mathrm{Var}(u_2) &= \mathrm{Var}(u_1) + \mathrm{Var}(u_2 - u_1) + 2\mathrm{Cov}(u_1, u_2 - u_1)\\ &= \mathrm{Var}(u_1) + \mathrm{Var}(u_2 - u_1)\\ &\geq \mathrm{Var}(u_1).\end{aligned}$$

Problem 7 (15 pts). 假设两个自变量Z_1, Z_2分别有一列样本值$\mathbf{Z}_1 = (z_{11}, \ldots, z_{n1})^\top \in \mathbb{R}^n$, $\mathbf{Z}_2 = (z_{12}, \ldots, z_{n2})^\top \in \mathbb{R}^n$, 它都已中心化、标准化，并且互相正交。即$\sum_{i=1}^n z_{i1}/n = \sum_{i=1}^n z_{i2}/n = 0$, $\|\mathbf{Z}_1\|^2 = \|\mathbf{Z}_2\|^2 = 1$, $\mathbf{Z}_1^\top\mathbf{Z}_2 = 0$. 另外有因变量$Y$的样本值$\mathbf{Y} = (y_1, \ldots, y_n)^\top$, 也已做好中心化，即$\sum_{i=1}^n y_i/n = 0$.

1. (5 pts) 考虑简单回归$Y \sim Z_1$, 由于变量都已中心化，可以不用加入截距。此时最小二乘的目标为

$$\min_{\gamma_1} \|\mathbf{Y} - \gamma_1\mathbf{Z}_1\|^2.$$

证明：此时回归的R^2等于ρ_1^2, 其中

$$\rho_1 = \frac{\mathbf{Z}_1^\top\mathbf{Y}}{\|\mathbf{Z}_1\|\|\mathbf{Y}\|}$$

为Z_1与Y的样本相关系数。

2. (5 pts) 考虑二元回归$Y \sim Z_1 + Z_2$, 同样不用加入截距。证明：用最小二乘法估计出的两个斜率为

$$\hat{\gamma}_1 = \mathbf{Z}_1^\top\mathbf{Y}, \quad \hat{\gamma}_2 = \mathbf{Z}_2^\top\mathbf{Y}.$$

3. (5 pts) 假设变量$X_1 = Z_1$, $X_2 = Z_1 + Z_2$, 其样本即为$\mathbf{X}_1 = \mathbf{Z}_1$, $\mathbf{X}_2 = \mathbf{Z}_1 + \mathbf{Z}_2$. 现在用$X_1, X_2$作为自变量，做回归$Y \sim X_1 + X_2$ (不加截距), 并用岭回归做正则化，即求解

$$\min_{\beta_1,\beta_2} \|\mathbf{Y} - \beta_1\mathbf{X}_1 - \beta_2\mathbf{X}_2\|^2 + \lambda(\beta_1^2 + \beta_2^2).$$

请求出岭回归的解，将其写成依赖于$\hat{\gamma}_1, \hat{\gamma}_2, \lambda$的表达式。

1. 首先容易求得最小二乘估计$\hat{\gamma}_1 = \mathbf{Z}_1^\top \mathbf{Y}$. 残差平方和为

$$\mathrm{RSS} = \|\mathbf{Y} - \hat{\gamma}_1 \mathbf{Z}_1\|^2 = \|\mathbf{Y}\|^2 - 2\hat{\gamma}_1 \mathbf{Z}_1^\top \mathbf{Y} + \hat{\gamma}_1^2 = \|\mathbf{Y}\|^2 - \hat{\gamma}_1^2.$$

根据定义，

$$R^2 = \frac{\mathrm{SYY} - \mathrm{RSS}}{\mathrm{SYY}} = \frac{\hat{\gamma}_1^2}{\|\mathbf{Y}\|^2}.$$

2. 最小二乘的目标函数为

$$\|\mathbf{Y} - \gamma_1 \mathbf{Z}_1 - \gamma_2 \mathbf{Z}_2\|^2 = \gamma_1^2 - 2\gamma_1 \mathbf{Z}_1^\top \mathbf{Y} + \gamma_2^2 - 2\gamma_2 \mathbf{Z}_2^\top \mathbf{Y} + \mathbf{Y}^\top \mathbf{Y}$$

其最小值点为$\hat{\gamma}_1 = \mathbf{Z}_1^\top \mathbf{Y}$, $\hat{\gamma}_2 = \mathbf{Z}_2^\top \mathbf{Y}$.

3. 岭回归的目标函数为

$$\begin{aligned} f(\beta_1, \beta_2) &= \|\mathbf{Y} - \beta_1 \mathbf{X}_1 - \beta_2 \mathbf{X}_2\|^2 + \lambda(\beta_1^2 + \beta_2^2) \\ &= \|\mathbf{Y} - (\beta_1 + \beta_2)\mathbf{Z}_1 - \beta_2 \mathbf{Z}_2\|^2 + \lambda(\beta_1^2 + \beta_2^2) \\ &= (\beta_1 + \beta_2)^2 + \beta_2^2 - 2(\beta_1 + \beta_2)\mathbf{Z}_1^\top \mathbf{Y} - 2\beta_2 \mathbf{Z}_2^\top \mathbf{Y} + \lambda(\beta_1^2 + \beta_2^2) \\ &= (\beta_1 + \beta_2)^2 + \beta_2^2 - 2(\beta_1 + \beta_2)\hat{\gamma}_1 - 2\beta_2 \hat{\gamma}_2 + \lambda(\beta_1^2 + \beta_2^2). \end{aligned}$$

最小化的条件为

$$\begin{aligned} \frac{\partial f}{\partial \beta_1} &= 2(\beta_1 + \beta_2) - 2\hat{\gamma}_1 + 2\lambda\beta_1 = 0 \\ \frac{\partial f}{\partial \beta_2} &= 2(\beta_1 + \beta_2) + 2\beta_2 - 2\hat{\gamma}_1 - 2\hat{\gamma}_2 + 2\lambda\beta_2 = 0. \end{aligned}$$

可以解得

$$\begin{aligned} \hat{\beta}_1^{\mathrm{ridge}} &= \frac{(\lambda + 1)\hat{\gamma}_1 - \hat{\gamma}_2}{\lambda^2 + 3\lambda + 1}, \\ \hat{\beta}_2^{\mathrm{ridge}} &= \frac{\lambda\hat{\gamma}_1 + (\lambda + 1)\hat{\gamma}_2}{\lambda^2 + 3\lambda + 1}. \end{aligned}$$