模拟期中试卷 1

（按第 1–6 讲范围自编 • 无答案）

说明：本卷按照课程第 1–6 讲的范围自编（至 ridge / lasso / elastic net 为止，含 Stein 缩减；不含 logistic 回归与 Gauss–Newton），题型、分值与难度仿照样卷。判断题与单选题请把答案写在括号内。

Problem 1 (10 pts). 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1. 在简单线性回归中，$\mathrm{Cov}(\hat\beta_0, \hat\beta_1) = -\sigma^{*2}\bar{x}/SXX$，因此当 $\bar{x} = 0$ 时 $\hat\beta_0$ 与 $\hat\beta_1$ 不相关。（　　）

2. 训练集上的 RSS 越小，模型对新数据的预测误差一定越小。（　　）

3. 在岭回归中，tuning parameter λ 越大，回归系数估计的方差越小，偏差平方越大。（　　）

4. 三次样条在每个结点处函数值、一阶导数与二阶导数都连续，但三阶导数允许发生跳跃。（　　）

5. 主成分分析中，主成分的载荷（loadings）依赖于因变量 Y 的取值。（　　）

Problem 2 (16 pts). 单选题，每题只有一个正确答案。

1. 在包含 p 个自变量的线性回归中，σ^2_* 的无偏估计是（　　）
   (A) RSS/n　(B) $\mathrm{RSS}/(n-1)$　(C) $\mathrm{RSS}/(n-p-1)$　(D) $\mathrm{RSS}/(n-p)$

2. 已知某自变量 X_j 对其余自变量回归的 $R^2_j = 0.96$，则其方差膨胀因子 VIF_j 为（　　）
   (A) 4　(B) 12.5　(C) 25　(D) 96

3. 关于 AIC 与 BIC，下列说法正确的是（　　）
   (A) AIC 对变量个数的惩罚总是比 BIC 更重
   (B) 当 $n \geq 8$ 时，BIC 的惩罚比 AIC 更重，因此 BIC 选出的变量个数一般不会多于 AIC
   (C) AIC 与 BIC 都是预测误差的无偏估计
   (D) $\mathrm{BIC} = n\log(\mathrm{RSS}/n) + 2(k+1)$

4. 在正交设计（$X^\top X = I$）下，lasso 的解为软阈值 $\mathrm{sign}(z)(|z| - \lambda)_+$，岭回归的解为 $z/(1+\lambda)$。下列说法正确的是（　　）
   (A) lasso 对每个系数的压缩程度一定比岭回归大
   (B) lasso 可以把系数精确压缩为 0（从而实现变量选择），而岭回归不能
   (C) 岭回归也可以把系数精确压缩为 0
   (D) 两者的差别仅在于计算速度

Problem 3 (15 pts). 在一个简单线性回归中，样本数量为 $n = 25$，计算出 $\mathrm{SYY} = 40$，$\mathrm{SXX} = 50$，$\mathrm{SXY} = 25$，$\mathrm{RSS} = 30$。

1. (5 pts) 求斜率的最小二乘估计 $\hat\beta_1$。

2. (5 pts) 构造 β_1^* 的一个 95% 置信水平的置信区间（已知 $t_{0.025}(23) = 2.07$）。

3. (5 pts) 求出可决系数 R^2。

Problem 4 (14 pts). 假设一个线性回归中，有一个连续自变量 X 和一个分类自变量 F（F 有 3 个类别）。样本量为 $n = 12$。我们从一个只有截距的模型开始，用向前选变量法做了三步，其中 F 生成的虚拟变量整组一起加进来。表 1 给出了四个模型及相应的 RSS。注意模型 (2), (3), (4) 也都自然包含了截距。

表 1: Problem 4 的四个模型

序号	模型	RSS
(1)	$Y \sim 1$（只有截距的模型）	120
(2)	$Y \sim X$	60
(3)	$Y \sim X + F$	30
(4)	$Y \sim X + F + X : F$	24

1. (7 pts) 用 adjusted R^2 准则（$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}(1 - R^2)$，$k$ 为自变量个数）选出合适的模型。

2. (7 pts) BIC 的定义为 $\text{BIC} = n \log(\text{RSS}/n) + (k+1) \log n$。试用此准则选出合适的模型。（已知：$\log 12 \approx 2.5$，$e^{0.2} \approx 1.2$，$e^{0.4} \approx 1.5$，$e^{0.21} \approx 1.23$，$e^{0.42} \approx 1.52$。）

Problem 5 (15 pts). 设随机向量 $X = (X_1, X_2)^\top$ 的协方差矩阵为

$$\Gamma = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

1. (5 pts) 求 Γ 的两个特征值及对应的单位特征向量，并写出第一主成分的方向 u_1（载荷）。

2. (5 pts) 第一主成分解释的方差比例是多少？两个主成分各自解释的方差是多少？

3. (5 pts) 用 Lagrange 乘子法证明如下结论：$\max_{a:\|a\|=1} a^\top \Gamma a$ 的解必满足 $\Gamma a = \lambda a$（即 a 是特征向量），且目标函数的最大值恰为对应的特征值 λ。据此说明第一主成分为什么取最大特征值对应的特征向量。

Problem 6 (16 pts). 考虑已中心化的多元线性回归 $Y = X\beta^* + e$，$e \sim N(0, \sigma^{*2} I_n)$（不含截距项）。岭回归定义为

$$\min_b \ \|Y - Xb\|^2 + \lambda \|b\|^2, \qquad \lambda > 0.$$

1. (5 pts) 求出岭回归的闭式解，并证明 $X^\top X + \lambda I$ 恒为正定矩阵、必定可逆——哪怕 $p > n$（即 $X^\top X$ 本身奇异时）也成立。

2. (5 pts) 写出岭回归估计量的期望，证明当 $\lambda > 0$ 时它一般是有偏的，并指出偏差项的形式。

3. (6 pts) 现设正交设计 $X^\top X = I_p$。对某个分量写出岭回归估计的方差与偏差平方（均为 λ 的函数），并求出使预测误差 $\text{PE}(\lambda) = \text{Var} + \text{bias}^2 + \sigma^{*2}$ 最小的最优 λ（用 β_j^* 与 σ_*^2 表示）。

Problem 7 (14 pts). 设 $y_1, \dots, y_n \overset{i.i.d.}{\sim} N(\mu, 1)$（$n > 2$），要估计 μ 并预测新观测 $y_{\text{new}} = \mu + e_{\text{new}}$（$\text{Var}(e_{\text{new}}) = 1$，与样本独立）。考虑把样本均值再乘以系数 c（$0 \le c \le 1$）的估计量 $\hat{\mu}(c) = c\bar{y}$。

1. (7 pts) 写出 $\hat{\mu}(c)$ 的预测误差 $\text{PE}(c) = \text{Var} + \text{bias}^2 + 1$ 关于 c 的表达式，求出最优的 c^*（用 μ 与 n 表示），并验证 $\text{PE}(c^*) < \text{PE}(1)$（即 Stein 缩减现象）。

2. (7 pts) 考虑惩罚最小二乘 $\min_\beta \sum_{i=1}^n (y_i - \beta)^2 + \lambda\beta^2$。求出其解 $\hat{\beta}$（用 $\bar{y}$, n, λ 表示），并求出使该解恰好具有 Stein 形式 $\frac{\bar{y}^2}{\bar{y}^2 + 1/n}\,\bar{y}$ 的 λ（用 $\bar{y}$ 与 n 表示）。