模拟期中试卷 2

（按第 1–6 讲范围自编 • 无答案）

说明：本卷按照课程第 1–6 讲的范围自编（至 ridge / lasso / elastic net 为止，含 Stein 缩减；不含 logistic 回归与 Gauss–Newton），题型、分值与难度仿照样卷。判断题与单选题请把答案写在括号内。

Problem 1 (10 pts). 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1. 对因子变量更换基准类（baseline），回归的拟合值与 RSS 保持不变。（　　）
2. 向后剔除法（backward elimination）可以直接用于 $p > n$ 的情形。（　　）
3. 前 q 个主成分保留的方差比例为 $\sum_{j\le q}\lambda_j / \sum_j \lambda_j$，其中 λ_j 为协方差矩阵的特征值。（　　）
4. lasso 的 L1 惩罚项在 0 处是光滑的，因此不能将系数精确压缩为 0。（　　）
5. 用交叉验证选出模型之后，应当再用全部数据重新拟合一次，作为最终模型。（　　）

Problem 2 (16 pts). 单选题，每题只有一个正确答案。

1. 含有 K 个结点的三次样条，其自由度（即基函数的个数）为（　　）
   (A) $K+1$　(B) $K+2$　(C) $K+4$　(D) $4K$
2. 关于多重共线性，下列说法**错误**的是（　　）
   (A) $\mathrm{VIF}_j > 10$ 提示存在共线性
   (B) 共线性使 $X^\top X$ 的最小特征值接近 0，从而导致系数估计的方差变大
   (C) 岭回归可以缓解共线性带来的方差膨胀
   (D) 完全共线时最小二乘估计仍然唯一
3. 关于预测误差的分解 $\mathrm{PE} = \mathrm{Var} + \mathrm{bias}^2 + \sigma_*^2$，下列说法正确的是（　　）
   (A) 训练误差是预测误差的无偏估计
   (B) 模型 flexibility 增大时，方差增大、偏差平方减小
   (C) 不可消减误差 σ_*^2 可以通过增加自变量来消除
   (D) 预测误差随模型中变量个数的增加而单调下降
4. 关于逐步回归，下列说法正确的是（　　）
   (A) 向前选择每步删除一个变量
   (B) 向后剔除可以从截距模型出发
   (C) 向前选择与向后剔除都保证找到 2^p 个子集的全局最优
   (D) 向前选择不要求 $p < n$，而向后剔除要求全集模型可估

Problem 3 (14 pts). 某因子 F 有两个类别 $\{A, B\}$，每类各 3 个观测。拟合模型 $Y \sim F$（以 A 为基准类，设 $U_i = I\{F_i = B\}$），即

$$y_i = \beta_0^* + \beta_1^* u_i + e_i.$$

已知 A 组观测值为 $2, 4, 6$，B 组观测值为 $5, 7, 9$。

1. (7 pts) 写出设计矩阵 X（含截距列），并用最小二乘法求出 $\hat{\beta}_0$ 与 $\hat{\beta}_1$。

2. (7 pts) 若改用 B 为基准类，重新写出两个系数的估计值；并回答 RSS 是否改变，说明理由。

Problem 4 (16 pts). 一个线性回归中有连续自变量 X 与二分类变量 $F \in \{A, B\}$，样本数为 $n = 12$。分别拟合三个模型，结果如下。

表 1: 模型 1：$Y \sim X$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	10.20	1.00	10.20	1.2E-06
X	2.05	0.30	6.83	1.1E-04

R-squared: 0.60

表 2: 模型 2：$Y \sim X + F$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	8.90	1.10	8.09	1.7E-05
X	2.10	0.28	7.50	5.3E-05
B	4.50	0.90	5.00	1.1E-03

R-squared: 0.72

表 3: 模型 3：$Y \sim X + F + X : F$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	9.30	1.50	6.20	1.5E-04
X	2.02	0.40	5.05	1.0E-03
B	3.00	2.10	1.43	0.19
$X : B$	0.60	0.60	1.00	0.35

R-squared: 0.78

1. (4 pts) 从模型的基本设定方面，简述三个模型在回归的截距以及 X 的斜率上有何区别。

2. (4 pts) 对于模型 2，请构建 X 回归系数的一个 95% 置信水平的置信区间（允许用 $t_{0.025}(9)$ 表示分位数）。判断 0 是否被包含在这个置信区间之内。

3. (4 pts) 如果以 t-检验的显著性为判断依据来选择模型，最合理的模型是哪一个？

4. (4 pts) 如果以 R^2_{adj} 为判断依据来选择，应该用哪一个模型？（$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}(1-R^2)$。）

Problem 5 (14 pts). 考虑正交设计（$X^\top X = I$）下的正则化。记 $\hat\beta^{\text{ols}} = X^\top Y$ 的第 j 个分量为 z_j。

1. (5 pts) 写出 lasso 解的软阈值公式 $\hat\beta_j^{\text{lasso}} = \text{sign}(z_j)(|z_j| - \lambda)_+$。设 $z = (3, -1, 0.5)^\top$，$\lambda = 1$，求出三个系数。

2. (5 pts) 对 $z_1 = 3$，同一 λ 下岭回归的解为 $3/(1+\lambda)$。比较此时 lasso 与岭回归对该系数的压缩结果，并说明为什么 lasso 能做变量选择而岭回归不能（从惩罚函数在 0 处的几何性质回答）。

3. (4 pts) 写出 elastic net 在正交设计下的解（用 z_j, λ, α 表示），并验证 $\alpha = 1$ 时退化为 lasso、$\alpha = 0$ 时退化为岭回归。

Problem 6 (16 pts). 考虑异方差线性模型 $Y = X\beta^* + e$，其中 $e_1, \dots, e_n$ 相互独立，$\text{Var}(e_i) = \sigma_*^2/w_i$，权重 $w_i > 0$ 已知（记 $W = \text{diag}(w_1, \dots, w_n)$）。设 $y_i \sim N(x_i^\top\beta,\ \sigma^2/w_i)$。

1. (6 pts) 写出似然函数与对数似然，先对 σ^2 求最优（profile），再证明 β 的极大似然估计等价于加权最小二乘 $\min_\beta \sum_{i=1}^n w_i(y_i - x_i^\top\beta)^2$，并给出闭式解 $\hat\beta_W$。

2. (5 pts) 证明 $\hat\beta_W$ 无偏，并求出 $\text{Cov}(\hat\beta_W)$（化简到最简形式）。

3. (5 pts) 证明 Gauss–Markov 定理的加权版本：对任何满足 $\tilde A X = I$ 的常数矩阵 $\tilde A \in \mathbb{R}^{(p+1)\times n}$，以及任何常向量 c，都有

$$\text{Var}\big(c^\top\hat\beta_W\big) \le \text{Var}\big(c^\top\tilde\beta\big), \qquad \tilde\beta = \tilde A Y.$$

   并据此说明：在异方差下误用普通最小二乘，其方差不会小于 WLS。（提示：可模仿矩阵版 Gauss–Markov 的证明，把内积换成加权的 $\langle u, v\rangle_W = u^\top W v$。）

Problem 7 (14 pts). 给定两个结点 $\xi_1 < \xi_2$，考虑截断幂基

$$\big\{\,1,\ x,\ x^2,\ x^3,\ (x-\xi_1)_+^3,\ (x-\xi_2)_+^3\,\big\}, \qquad (x-\xi)_+ = \max(x-\xi, 0).$$

1. (6 pts) 用约束计数说明：为什么 K 个结点的三次样条有 $K+4$ 个自由度？具体到本题的 $K = 2$，自由度是多少？

2. (8 pts) 验证基函数 $h(x) = (x-\xi)_+^3$（ξ 为任意结点）确实是一个三次样条：分段为三次多项式，在 ξ 处函数值、一阶导数、二阶导数都连续，并求出其三阶导数在 ξ 处的左右极限，说明为什么三阶导数的跳跃是被允许的。