Sample Midterm Exam 1

（自测版 • 无答案）

说明：本样卷供同学们参考。正式考试中的风格和难度与此样卷类似。

Problem 1 (10 pts). 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1. 简单线性回归中，若用最小二乘 (OLS) 估计，则数据的中心点 $(\bar{x}, \bar{y})$ 一定落在估计出的回归线上。（　　）

2. 在包含 p 个自变量的线性回归 $Y \sim X_1 + \cdots + X_p$ 中，用最小二乘法估计回归系数，则 $\hat{\sigma}^2 = \mathrm{RSS}/(n-p-1)$ 是 σ_*^2 的无偏估计。（　　）

3. 对于一个有 d 个水平的类别型变量 F，做线性回归 $Y \sim F$。若采用虚拟变量法引入 $(d-1)$ 个虚拟变量，则所有虚拟变量的回归系数都代表该类别与 Y 的总样本均值 $\bar{y} = \sum_{i=1}^{n} y_i/n$ 的差异。（　　）

4. 在 logistic 回归，回归的 G^2 (deviance) 越小，说明模型拟合得越好。（　　）

5. 非线性回归的 Gauss-Newton 算法一定保证收敛到全局最优解。（　　）

Problem 2 (16 pts). 单选题，每题只有一个正确答案。

1. 在多元线性回归中，加入一个与因变量完全不相关但与其他自变量高度相关的变量，最可能导致(　　)

   (A) 新变量的系数会非常显著（即 p-值很小）　(B) 所有变量系数的标准误都会减小

   (C) 原来自变量的系数出现变化，甚至由显著变得不显著　(D) 模型的 R^2 显著提高

2. 以下关于 R^2_{adj} 的说法中，正确的是(　　)

   (A) 其唯一目标是提升模型在训练数据上的拟合优度　(B) 它可以帮助我们避免过拟合

   (C) 它确保了模型中所有变量的系数都是统计显著的　(D) 当选取的变量数 k 固定时，R^2_{adj} 就完全确定了

3. 关于 lasso 和岭回归的说法，错误的是(　　)

   (A) lasso 可以将某些系数压缩至 0，从而实现变量选择；而岭回归通常做不到

   (B) 两者都可以用于处理变量数量多于样本数量（$p > n$）的情况

   (C) 两者估计出的回归系数都是有偏的

   (D) 对于每一个自变量，lasso 生成的回归系数的长度（即绝对值）一定比岭回归要小

4. 关于主成分分析，以下说法错误的是(　　)

   (A) 主成分是原始变量的线性组合，且各主成分之间相互正交

   (B) 通常需要保留所有特征值大于 0 的主成分

   (C) 载荷表示主成分中每个变量的权重

   (D) 得分表示每个样本点在主成分方向上的值

Problem 3 (15 pts). 在一个简单线性回归中，样本数量为 $n = 14$，计算出 SYY $= 20$，SXX $= 20$，SXY $= 10$，RSS $= 15$。

1. (5 pts) 斜率的最小二乘估计 $\hat{\beta}_1$。
2. (5 pts) 求出可决系数 R^2。
3. (5 pts) 构造 t-检验来判断 β_1^* 是否显著非 0。这里显著水平选 $\alpha = 0.05$，已知 $t(12)$-分布的上分位数 $t_{\alpha/2}(12) = 2.45$。

Problem 4 (14 pts). 假设一个线性回归中，有一个连续自变量为 X 和一个分类自变量 F，F 有 3 个类别。样本量为 $n = 10$。我们从一个只有截距的模型开始，用向前选变量法做了三步，其中 F 生成的虚拟变量整组一起加进来。表 1 给出了过程中拟合的四个模型以及相应的 RSS。注意模型 (2), (3), (4) 也都自然包含了截距。

表 1: Problem 4 的四个模型

序号	模型	RSS
(1)	$Y \sim 1$（只有截距的模型）	100
(2)	$Y \sim X$	48
(3)	$Y \sim X + F$	24
(4)	$Y \sim X + F + X : F$	18

1. (7 pts) 我们知道，adjusted R^2 的定义为

$$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}\left(1 - R^2\right),$$

其中 k 为模型中包含的自变量个数。试用此准则选出合适的模型。

2. (7 pts) 已知 AIC 的定义为

$$\text{AIC} = n \log\left(\frac{\text{RSS}}{n}\right) + 2(k+1).$$

试用此准则选出合适的模型。（已知：$e^{0.2} \approx 1.2$，$e^{0.4} \approx 1.5$。）

Problem 5 (15 pts). 一次商业推广活动中，商家统计了一些用户的基本信息，以及每位用户是否最后有购买行为。我们通过 logistic 回归来分析用户的购买行为受哪些因素影响。我们选用的数据样本量为 $n = 500$，每位用户的信息包括

- X：收入（万元），为连续变量；
- A：性别，为分类变量，分为“女性 (F)”、“男性 (M)”；
- Y：是否购买，为 0/1 变量。若存在购买行为，则取值为 1；反之取值为 0。

现在拟合一个 logistic 回归模型 $Y \sim X + A + X : A$，得到表 2 中的 summary 结果。
Null Deviance: 188.50 on 499 degrees of freedom
Residual deviance: 43.12 on 496 degrees of freedom

表 2: Summary table

	Estimate	Std. Error	z value	Pr($>|z|$)
(Intercept)	1.55	1.20	1.32	0.19
X	0.47	0.22	2.11	0.035
M	−1.66	0.53	−3.15	0.0016
$X:M$	0.35	0.40	0.88	0.38

1. (5 pts) 对于一个收入为 $x_{\text{new}} = 1.5$ 的女性新用户，试用表中的数据给出其购买的概率。可以只列式不计算。

2. (5 pts) 我们比较女性用户与男性用户的购买 odds（即购买概率/不购买概率）。固定收入水平 $x = 1$，构建一个全模型和一个主效应模型。在这两个模型之下，分别说明两性用户的购买 odds 之间的关系。

3. (4 pts) 在未来的商业推广活动中，对用户群体购买行为的预测决定了营销策略的方向。经理 A 说：“我们应该不要漏掉可能的客户，即使这样会使我们在未来的商业推广活动中产生更高的费用。”经理 B 说：“我们应该更专注特定的用户群体进行精准营销，这样可以节省营销成本。”针对两个经理的话，我们分别应该怎么去预测下次营销活动中新用户的购买行为？

Problem 6 (16 pts). 对于线性回归，我们令 $A = (X^\top X)^{-1}X^\top \in \mathbb{R}^{(p+1)\times n}$，则最小二乘估计量可以写为 $\hat{\beta} = AY$。现在给定任何一个满足 $\tilde{A}X = I$ 的常数矩阵 $\tilde{A} \in \mathbb{R}^{(p+1)\times n}$，考虑一个估计量 $\tilde{\beta} = \tilde{A}Y$。

1. (4 pts) 证明：$\tilde{\beta}$ 为 β^* 的无偏估计量。

2. (4 pts) 对于任何常数向量 $c \in \mathbb{R}^{p+1}$，令 $u_1 = c^\top\hat{\beta}$，$u_2 = c^\top\tilde{\beta}$。证明：$u_1, u_2$ 均为 $c^\top\beta^*$ 的无偏估计量。

3. (4 pts) 证明：$\mathrm{Cov}(u_1, u_2) = \mathrm{Var}(u_1)$。

4. (4 pts) 利用 3 的结论，证明 $\mathrm{Var}(u_1) \le \mathrm{Var}(u_2)$。

Problem 7 (15 pts). 假设两个自变量 Z_1, Z_2 分别有一列样本值 $Z_1 = (z_{11}, \ldots, z_{n1})^\top \in \mathbb{R}^n$，$Z_2 = (z_{12}, \ldots, z_{n2})^\top \in \mathbb{R}^n$,它们都已中心化、标准化,并且互相正交。即 $\sum_{i=1}^n z_{i1}/n = \sum_{i=1}^n z_{i2}/n = 0$，$\|Z_1\|^2 = \|Z_2\|^2 = 1$，$Z_1^\top Z_2 = 0$。另外有因变量 Y 的样本值 $Y = (y_1, \ldots, y_n)^\top$，也已做好中心化，即 $\sum_{i=1}^n y_i/n = 0$。

1. (5 pts) 考虑简单回归 $Y \sim Z_1$，由于变量都已中心化，可以不用加入截距。此时最小二乘的目标为

$$\min_{\gamma_1} \|Y - \gamma_1 Z_1\|^2.$$

证明：此时回归的 R^2 等于 ρ_1^2，其中

$$\rho_1 = \frac{Z_1^\top Y}{\|Z_1\|\,\|Y\|}$$

为 Z_1 与 Y 的样本相关系数。

2. (5 pts) 考虑二元回归 $Y \sim Z_1 + Z_2$，同样不用加入截距。证明：用最小二乘法估计出的两个斜率为

$$\hat{\gamma}_1 = Z_1^\top Y, \qquad \hat{\gamma}_2 = Z_2^\top Y.$$

3. (5 pts) 假设变量 $X_1 = Z_1$，$X_2 = Z_1 + Z_2$，其样本即为 $X_1 = Z_1$，$X_2 = Z_1 + Z_2$。现在用 X_1, X_2 作为自变量，做回归 $Y \sim X_1 + X_2$（不加截距），并用岭回归做正则化，即求解

$$\min_{\beta_1,\beta_2} \|Y - \beta_1 X_1 - \beta_2 X_2\|^2 + \lambda\left(\beta_1^2 + \beta_2^2\right).$$

请求出岭回归的解，将其写成依赖于 $\hat{\gamma}_1, \hat{\gamma}_2, \lambda$ 的表达式。