Sample Midterm Exam 2

（自测版 • 无答案）

说明：本样卷供同学们参考。正式考试中的风格和难度与此样卷类似。

Problem 1 (10 pts). 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1. 回归 $Y \sim X_1$ 的 RSS 一定不小于 $Y \sim X_1 + X_2$ 的 RSS。（　　）
2. 对于线性回归模型来说，模型包含的变量越多，则预测误差越小。（　　）
3. 在线性回归的岭回归方法中，tuning parameter λ 越大，则预测时方差越大，偏差平方越小。（　　）
4. 对非线性回归模型来说，参数估计的 Gauss-Newton 算法总是能够收敛到全局最优解。（　　）
5. 当 n 较大时，BIC 对于变量数的惩罚比 AIC 更加严厉（换句话说，BIC 选出的变量数一般不会多于 AIC）。（　　）

Problem 2 (16 pts). 单选题，每题只有一个正确答案。

1. 在线性回归中，下面哪一个量仅依赖于自变量，而不依赖于因变量？（　　）
   (A) 最小二乘估计量 $\hat{\beta}$　(B) 第一个主成分的载荷 (loadings)
   (C) 残差平方和 RSS　(D) R^2
2. 下面哪种变量选择方法不适用于 $p > n$ 的情形？（　　）
   (A) 向前选变量法 (forward selection)　(B) 向后选变量法 (backward elimination)
   (C) 岭回归 (ridge regression)　(D) lasso
3. 下列哪个模型可以直接转化为一个线性模型？（其中 θ_1^*, θ_2^* 为未知参数）（　　）
   (A) $y_i = \theta_1^* + \exp(\theta_2^* + \log x_i) + e_i$　(B) $y_i = \theta_1^* + \exp(\theta_2^* \log x_i) + e_i$
   (C) $y_i = \theta_1^* + \log(\theta_2^* + x_i) + e_i$　(D) $y_i = \theta_1^* \exp(\theta_2^* x_i) + e_i$
4. 下列关于 logistic 回归的说法正确的是（　　）
   (A) 自变量只允许是连续型的　(B) 因变量只能是 0-1 变量
   (C) 成功概率为自变量的一个线性组合　(D) 回归的 G^2 (deviance) 越小，说明模型拟合得越好

Problem 3 (14 pts). 假设如下回归模型

$$y_i = \beta_0^* + \beta_1^* x_i + \beta_2^* \left(3x_i^2 - 2\right) + e_i, \qquad i = 1, 2, 3.$$

其中 $e_i \overset{i.i.d.}{\sim} N(0, \sigma_*^2)$。我们给定自变量的值 $x_1 = -1$，$x_2 = 0$，$x_3 = 1$，而因变量的值则用 y_1, y_2, y_3 表示。

1. (8 pts) 求出 $\beta_0^*, \beta_1^*, \beta_2^*$ 的最小二乘估计量。

2. (6 pts) 证明：当已知 $\beta_2^* = 0$ 时，β_0^*, β_1^* 的最小二乘估计量保持不变。

Problem 4 (16 pts). 在一个线性回归中有连续因变量 Y，有一个连续自变量 X 与一个分类变量 F，其中 F 有两个类别 $\{A, B\}$。样本数为 $n = 8$。我们分别拟合三个模型，得到如下结果：

表 1: 模型 1：$Y \sim X$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	32.31	2.00	16.16	3.58E-06
X	14.32	0.70	20.46	8.87E-07

R-squared: 0.34

表 2: 模型 2：$Y \sim X + F$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	29.66	2.04	14.54	1.39E-05
X	14.57	0.69	21.12	2.21E-06
B	3.83	0.74	5.18	1.77E-03

R-squared: 0.50

表 3: 模型 3：$Y \sim X + F + X:F$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	30.36	2.86	10.62	2.22E-04
X	14.33	0.98	14.62	6.36E-05
B	2.47	3.96	0.62	0.28
$X:B$	0.48	1.38	0.35	0.37

R-squared: 0.64

1. (4 pts) 从模型的基本设定方面，简述三个模型在回归的截距以及 X 的斜率上有何区别。

2. (4 pts) 对于模型 2，请构建 X 回归系数的一个 95% 置信水平的置信区间（允许用符号表示 t-分布的分位数）。判断 0 是否被包含在这个置信区间之内。

3. (4 pts) 如果用 t-检验的显著性为判断依据来选择模型，最合理的模型应该是什么样的？

4. (4 pts) 如果用 R^2_{adj} 为判断依据来选择，应该用哪一个模型？

Problem 5 (15 pts). 在一个 logistic 回归中，因变量 Y 是一个 0-1 变量，有三个连续型自变量 X_1, X_2, X_3。我们拟合模型 $Y \sim X_1 + X_2 + X_3$，得到表 4 的结果。

1. (5 pts) 用表 4 中给出的数字计算缺失的 (a)–(c) 值。只需要给出计算式，不要求计算结果。

表 4: Logistic 模型 $Y \sim X_1 + X_2 + X_3$ 的结果

	Estimate	Std. Error	z value	Pr($>|z|$)
(Intercept)	-15.55	7.29	-2.13	0.033
X_1	-0.59	0.36	(a)	0.10
X_2	0.56	0.33	1.70	0.089
X_3	1.96	(b)	2.23	(c)

Residual deviance: 14.18 on 16 degrees of freedom

2. (5 pts) 假设 $x_1 = 5$，$x_2 = 25$。根据表 4 的结果，我们需要选定怎样的 x_3 值才能使得 $y = 1$ 的概率为 40%？只需要给出计算式，不要求计算结果。

3. (5 pts) AIC 一般定义为

$$\text{AIC} = -2\log(\text{maximum likelihood}) + 2 \times \text{number of parameters}.$$

现在我们拟合一个不含 X_1 的模型，得到表 5 的结果。如果用 AIC 作为模型选择准则，应该选用哪个模型？

表 5: Logistic 模型 $Y \sim X_2 + X_3$ 的结果

	Estimate	Std. Error	z value	Pr($>|z|$)
(Intercept)	-7.60	4.44	-1.71	0.087
X_2	0.087	0.14	0.60	0.55
X_3	1.53	0.68	2.25	0.024

Residual deviance: 18.16 on 17 degrees of freedom

（提示：Residual deviance 即 logistic 回归的 deviance，定义为 $G^2 = 2(l_s - \hat{l})$，其中 l_s 与 $\hat{l}$ 分别为饱和模型以及 logistic 模型的最大对数似然函数值。）

Problem 6 (15 pts). 考虑一个简单线性模型

$$y_i = \beta_0^* + \beta_1^* x_i + e_i, \qquad i = 1, \ldots, n,$$

其中 $e_i \overset{i.i.d.}{\sim} N(0, \sigma_*^2)$。现在对于某给定函数 $g(x)$，定义 $z_i = g(x_i)$。令 $\bar{z} = \sum_{i=1}^n z_i/n$。考虑 β_1^* 的一个估计量

$$\tilde{\beta}_1 = \frac{\sum_{i=1}^n (z_i - \bar{z}) y_i}{\sum_{i=1}^n (z_i - \bar{z}) x_i}.$$

1. (5 pts) 证明：$\tilde{\beta}_1$ 是无偏的。

2. (5 pts) 证明：

$$\text{Var}(\tilde{\beta}_1) = \frac{\sum_{i=1}^n (z_i - \bar{z})^2}{\{\sum_{i=1}^n (z_i - \bar{z}) x_i\}^2} \sigma_*^2.$$

3. (5 pts) 记 β_1^* 最小二乘估计量为 $\hat{\beta}_1$。我们知道，

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x}) x_i}.$$

证明：

$$\mathrm{Var}(\hat{\beta}_1) \le \mathrm{Var}(\tilde{\beta}_1).$$

（提示：可以利用柯西-施瓦茨不等式

$$\left(\frac{1}{n}\sum_{i=1}^{n}(z_i-\bar{z})(x_i-\bar{x})\right)^2 \le \left(\frac{1}{n}\sum_{i=1}^{n}(z_i-\bar{z})^2\right)\left(\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2\right).$$

）

Problem 7 (14 pts). 假设有 $2m+n$ 个因变量的样本 $y_1,\ldots,y_{2m+n}$，分为三组，分别满足

$$y_i = \begin{cases} \theta^* + e_i, & 1 \le i \le m, \\ \theta^* + \phi^* + e_i, & m+1 \le i \le 2m, \\ \theta^* - 2\phi^* + e_i, & 2m+1 \le i \le 2m+n, \end{cases}$$

其中 $e_i \overset{i.i.d.}{\sim} N(0,\sigma_*^2)$。

1. (7 pts) 求出 θ^* 与 ϕ^* 的最小二乘估计量 $\hat{\theta}$ 与 $\hat{\phi}$。
2. (7 pts) 证明：当 $m=2n$ 时，1) 中求得的 $\hat{\theta}$ 与 $\hat{\phi}$ 相关系数为 0。